

Developing a robust method to detect and characterize the effect of mental stress and microsleep episodes on the electrocardiogram

Masterthesis

vorgelegt von

cand. el. Patrick Reichensperger



INSTITUT FÜR BIOMEDIZINISCHE TECHNIK
PROF. DR. RER. NAT. OLAF DÖSSEL
KARLSRUHER INSTITUT FÜR TECHNOLOGIE
2014

Betreuer: Dipl.-Ing. Gustavo Lenis

Eidesstattliche Erklärung

Hiermit erkläre ich an Eides statt, dass ich die vorliegende Arbeit selbstständig und ohne unzulässige fremde Hilfsmittel angefertigt habe. Wörtlich oder inhaltlich übernommene Stellen sind als solche kenntlich gemacht und die verwendeten Literaturquellen im Literaturverzeichnis vollständig angegeben. Die „Regeln zur Sicherung guter wissenschaftlicher Praxis im Karlsruher Institut für Technologie (KIT)“ in ihrer gültigen Form wurden beachtet.

Karlsruhe, den 13.8.2014

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation	1
1.2	Aufgabenstellung und Schwerpunkt der Arbeit	2
2	Grundlagen	3
2.1	Physiologische Grundlagen	3
2.1.1	Anatomie und Physiologie	3
2.1.2	Erregungsbildungs- und Erregungsleitungssystem	4
2.1.3	Das Elektrokardiogramm (EKG)	6
2.1.4	Das vegetative Nervensystem	9
2.2	Mathematische Grundlagen	10
2.2.1	Zeitkontinuierliche Signale	10
2.2.2	Energiesignale	10
2.2.3	Orthonormale Funktionensysteme	10
2.2.4	Fourier-Transformation	11
2.2.5	Faltung und Korrelation	11
2.2.6	Zeitdiskrete Signale	12
2.2.7	Diskrete Fourier-Transformation	13
2.2.8	Leistungsdichtespektrum	14
2.2.9	Unschärferelation	15
2.2.10	Wavelet-Transformation	16
2.2.11	Grundbegriffe der Statistik	22
3	State of the Art	25
4	Studien und Daten	29
4.1	Mental-Stress-Test	29
4.2	MSE-Experiment	31
5	Feature-Generierung	35
5.1	Prozessierung der EKG-Signale	35
5.2	Untersuchung der Morphologie	36
5.2.1	Template-Bildung	37
5.2.2	QRS-Komplex	40
5.2.3	T-Welle	41
5.2.4	ST-Strecke	43
5.2.5	P-Welle	43
5.3	HRV-Analyse	46
5.3.1	Parameter im Zeitbereich	46

5.3.2 Parameter im Frequenzbereich	47
5.3.3 Wavelet Packet Analyse (WPA)	50
6 Ergebnisse	59
6.1 Auswertung des Mental-Stress-Test	59
6.2 Auswertung des MSE-Experiments	67
7 Zusammenfassung und Ausblick	73
7.1 Mental-Stress-Test	74
7.1.1 Zusammenfassung und Diskussion der Ergebnisse	74
7.1.2 Ausblick	75
7.2 MSE-Experiment	76
7.2.1 Zusammenfassung und Diskussion der Ergebnisse	76
7.2.2 Ausblick	78
A Liste der HRV-Parameter	79
B Liste der Features aus dem QRS-Komplex	83
Literaturverzeichnis	89

1

Einleitung

1.1 Motivation

Unser heutiger Alltag wird durch den wachsenden Einfluss der digitalen Informations- und Kommunikationstechnologie immer stärker beschleunigt. Einerseits sorgen das Internet und Smartphones dafür, dass wir uns zu jeder Tageszeit an jedem Ort über jedes erdenkliche Thema informieren können. Andererseits soll man über das Internet ebenfalls zu jeder Tageszeit und an jedem Ort verfügbar sein. Die ständige Verfügbarkeit wird insbesondere in der Arbeitswelt immer stärker vorausgesetzt, sodass beispielsweise auch außerhalb der Arbeitszeiten E-Mails geschrieben und beantwortet werden. Die ständige Verfügbarkeit und weitere Faktoren sorgen dafür, dass immer mehr Arbeit in kürzerer Zeit erledigt werden muss. Der Druck auf die Arbeitnehmer wächst so immer weiter an. Dies hat dazu geführt, dass der Stress am Arbeitsplatz in den letzten Jahren signifikant angewachsen ist. Laut Statistiken des Bundesverbandes der Betriebskrankenkassen ist die Anzahl der Krankheitstage durch das Burnout-Syndrom von 2004 bis 2011 um das 18-Fache gestiegen [Grabitz & Wisdorff, 2013]. Demnach werden 14.1 % der Krankheitstage durch psychische Erkrankungen verursacht. Neben den steigenden Krankheitstagen wird Stress auch als eine häufige Ursache für Verkehrsunfälle genannt. In den Unfallstatistiken des statistischen Bundesamtes kann Stress nicht als Ursache quantitativ erfasst werden. Jedoch wird angenommen, dass Autofahrer unter Stress dazu neigen, zu schnell zu fahren, den Sicherheitsabstand nicht einzuhalten oder auch unaufmerksamer zu fahren. In diesem Zusammenhang werden Fahrassistenzsysteme gesucht, die helfen könnten, den Stress des Fahrers zu messen, um diesen auf seinen aktuellen "Stress-Level" aufmerksam zu machen. Das Elektrokardiogramm (EKG) könnte eine Möglichkeit bieten Stress zu messen. Aus dem EKG kann die Herzrate abgeleitet werden. Die Herzrate unterliegt ständigen Schwankungen, was als Herzratenvariabilität (HRV) bezeichnet wird. Die Analyse der HRV stellt dabei eine vielversprechende Variante zur Messung mentaler Beanspruchung dar, da mentaler Stress über das vegetative Nervensystem auf die HRV einwirkt [Malik et al., 1996],[Rajendra Acharya et al., 2006].

Eine weitere Unfallursache im Straßenverkehr stellt die Übermüdung der Fahrer dar. Das statistische Bundesamt stellte einen signifikanten Anstieg an Verkehrsunfällen am frühen Morgen zwischen 2 Uhr und 8 Uhr fest [Wilhelm et al., 2010]. Neben den Auswirkungen der Übermüdung wie die sinkende Aufmerksamkeit werden auch Mikroschlaf-Episoden (Microsleep-Episodes, MSE) für den Anstieg der Verkehrsunfälle verantwortlich gemacht. Bei einem MSE wird der Fahrer für wenige Sekunden in einen schlafähnlichen Zustand versetzt. Für die Überwachung des Fahrers kommen Kamerasysteme oder auch

Eye-Tracking-Systeme in Frage. Jedoch können diese Systeme keinen Aufschluss über die tatsächliche physiologische Verfassung des Fahrers geben. Auch hier könnte das EKG eine Möglichkeit bieten, das Auftreten von MSEs zu registrieren, um den Fahrer vor der Weiterfahrt zu warnen.

1.2 Aufgabenstellung und Schwerpunkt der Arbeit

Wie im vorherigen Abschnitt bereits angedeutet wurde, stellt das EKG ein vielversprechendes biologisches Signal dar, um mentale Beanspruchung oder auch MSEs zu messen. In dieser Arbeit sollte untersucht werden, inwiefern die mentale Beanspruchung und die MSEs Auswirkungen auf das EKG haben. Es sollten dazu robuste Methoden der Signalverarbeitung entwickelt werden, welche in der Lage sind, die Auswirkungen auf das EKG zu detektieren. Dabei stellte die Entwicklung und Anwendung innovativer Methoden zur Analyse der HRV einen zentralen Punkt der Arbeit dar.

In Abschnitt 2.1 werden zunächst einige physiologische Grundlagen aufgeführt, die den Zusammenhang zwischen den physiologischen Prozessen am Herzen und den untersuchten Signalen herstellen sollen. Dabei werden insbesondere die Entstehung des EKGs und die Einflüsse des vegetativen Nervensystems auf das EKG erläutert. Zudem wird die aus dem EKG abgeleitete RR-Zeitreihe eingeführt, die zur Analyse der HRV dient. In Abschnitt 2.2 werden dann einige mathematische Grundlagen aus der Signalverarbeitung eingeführt, die zum späteren Verständnis der entwickelten Methoden notwendig sind. Die wichtigste Methode dieser Arbeit stellt dabei die Wavelet Packet Analyse (WPA) dar, welche die RR-Zeitreihe in eine Zeit-Frequenz-Darstellung transformiert. In den mathematischen Grundlagen wird daher besonderer Wert auf ein tiefes Verständnis der WPA gelegt. Die in Kapitel 3 zusammengestellten Publikationen fassen den bisherigen Wissensstand zum Einfluss mentaler Beanspruchung auf das EKG zusammen. Zusätzlich werden hier einige Publikationen aufgeführt, die verschiedene Varianten der Wavelet-Transformation als innovative Methode zur HRV-Analyse vorgeschlagen und angewendet haben.

Das Institut für Arbeitswissenschaft und Betriebsorganisation (IFAB) des KIT hat zur Untersuchung der Auswirkungen von mentaler Beanspruchung auf das EKG eine Studie durchgeführt, die in Abschnitt 4.1 vorgestellt wird. Eine weitere Studie zur Untersuchung der MSEs wurde an der FH Schmalkalden durchgeführt. Die EKG-Signale beider Studien wurden im Rahmen dieser Arbeit analysiert. Dazu wurden aus den Signalen Features generiert. Die dazu verwendeten Methoden werden im Kapitel 5 vorgestellt. Dabei wird zunächst auf die Detektion der markantesten Punkte der EKG-Kurve eingegangen. Im nächsten Schritt werden die Methoden vorgestellt, welche die Morphologie der EKG-Kurve untersuchen. Dazu werden einige Features generiert, die Veränderungen der Morphologie messen sollen. Im letzten Schritt folgen die Methoden der HRV-Analyse. Dazu werden zunächst die in der Literatur bereits weit verbreiteten HRV-Parameter vorgestellt, welche in einer vorherigen Arbeit bereits verwendet wurden. Die Methoden der HRV-Analyse wurden um die WPA ergänzt, die in Abschnitt 5.3.3 vorgestellt wird. Aus der WPA wurden über 200 weitere Parameter generiert, die einen detaillierten Einblick in die HRV liefern sollen. In Kapitel 6 werden die wichtigsten Ergebnisse der Studien vorgestellt. Im Anschluss werden die gewonnenen Ergebnisse in Kapitel 7 diskutiert und zusammengefasst. Außerdem wird hier für die Messung der mentalen Beanspruchung und der MSEs noch ein kurzer Ausblick gegeben.

2

Grundlagen

2.1 Physiologische Grundlagen

2.1.1 Anatomie und Physiologie

Das Herz hat die Aufgabe die Blutversorgung aller Organe sicherzustellen. Dazu pumpt das Herz das Blut über das Kreislaufsystem durch den gesamten Körper. Das Gewicht des Herzens liegt je nach Alter, Geschlecht und Trainingszustand zwischen 250 g und 400 g und hat dabei in etwa die Größe einer geschlossenen Faust. Das Herz befindet sich im Mediastinum innerhalb der Brusthöhle. Während sich die Herzbasis mit den großen Blutgefäßen genau in der Mitte des Brustraums befindet, zeigt die Herzspitze nach links unten. Das Herz wird fast vollständig vom Perikard umschlossen. Der anatomische Aufbau des Herzens ist in Abb. 2.1 zu sehen. Das Herz ist ein Hohlmuskel, der aus dem rechten und linken Vorhof (Atrium) und der rechten und linken Herzkammer (Ventrikel) besteht. Die Vorhöfe werden durch das Vorhofseptum, die Kammern durch das Kammerseptum getrennt. Die Vorhöfe werden von den Kammern durch die Segelklappen getrennt. Die Taschenklappen trennen die Kammern von den abgehenden Arterien. Die innerste Schicht der Herzwand ist das Endokard, zu dem auch die Herzkappen gehören. Die darüberliegende Schicht besteht aus den spezialisierten Herzmuskelzellen, die das Myokard bilden. Die das Myokard umgebende Bindegewebschicht heißt Epikard [Schwegler & Lucius, 2011, S. 250-255].

Im Folgenden wird der Blutfluss innerhalb des Herzens genauer beschrieben. Zunächst strömt das sauerstoffarme Blut über die obere und untere Hohlvene in den rechten Vorhof. Über die Trikuspidalklappe strömt das Blut in die rechte Herzkammer und wird anschließend über die Pulmonalklappe in die Pulmonalarterien in Richtung der Lunge gepumpt (Abb. 2.1, links). Nachdem dem Blut in der Lunge Kohlenstoffdioxid entzogen und Sauerstoff hinzugefügt wurde, gelangt das Blut in den linken Vorhof. Schließlich strömt das Blut über die Mitralklappe in die linke Kammer, von der aus das Blut über die Aortenklappe in die Aorta und somit in den gesamten Körper gepumpt wird (Abb. 2.1, rechts). Das Herz selbst wird über die Koronargefäße mit Blut versorgt, die sich zwischen dem Epikard und dem Myokard befinden [Silbernagl, 2012, S. 202-203].

Die Funktion des Herzens lässt sich in vier Aktionsphasen unterteilen. Während der Entspannungsphase strömt das Blut in die beiden Vorhöfe. Alle Herzkappen sind dabei geschlossen. Die Muskulatur der Kammern ist vollständig erschlafft. Sobald der Druck innerhalb der Vorhöfe den der Kammern übersteigt, öffnen sich die Segelklappen zwischen den Vorhöfen und Kammern. Somit beginnt die Füllungsphase, in der das Blut in die Kammern einströmen kann. Am Ende der Füllungsphase kontrahieren die Vorhöfe um

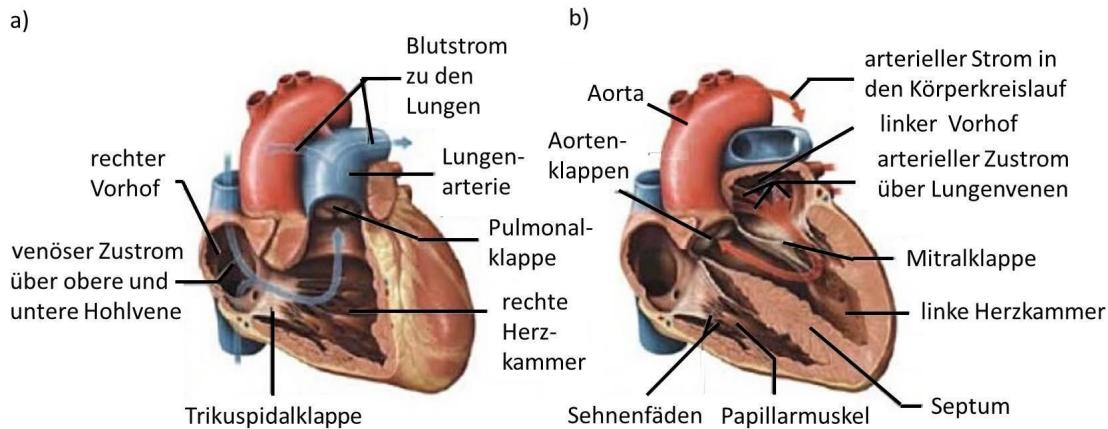


Abb. 2.1. Längsschnitt durch das Herz. Die Darstellung zeigt den anatomischen Aufbau des Herzens. Die Pfeile deuten die Richtung des Blutflusses an. a) zeigt den Blutfluss des sauerstoffarmen Blutes. b) zeigt den Blutfluss des sauerstoffreichen Blutes, modifiziert nach [Schwegler & Lucius, 2011, S. 252].

das Blutvolumen in den Kammern zu vergrößern. Die Entspannungs- und Füllungsphase werden gemeinsam als Diastole bezeichnet. Es beginnt nun die Anspannungsphase, in der die Muskulatur der Herzkammern kontrahiert. Dabei sind die Taschenklappen weiterhin geschlossen. Durch den steigenden Druck in den Kammern werden die Segelklappen geschlossen. Der Druck nimmt nun solange zu, bis er den Druck in den Arterien übersteigt und sich die Taschenklappen öffnen. Es beginnt die Austreibungsphase, in der das Blut in die Arterien gepumpt wird. Die Anspannungs- und Austreibungsphase werden gemeinsam als Systole bezeichnet [Silbernagl, 2012, S. 202-203].

2.1.2 Erregungsbildungs- und Erregungsleitungssystem

Jede Kontraktion eines Muskels benötigt eine elektrische Erregung. Im Gegensatz zur Skelettmuskulatur, in der die elektrische Erregung durch das somatische Nervensystem erzeugt und übertragen wird, wird die elektrische Erregung beim Herzen durch spezialisierte Herzmuskelzellen autonom erzeugt und weitergeleitet. Unter dem Erregungsbildungs- und Erregungsleitungssystem versteht man dabei alle beteiligten Herzmuskelzellen, die an der Erzeugung und Weiterleitung der elektrischen Erregung beteiligt sind [Schwegler & Lucius, 2011, S. 259] (Abb. 2.2).

Die elektrische Erregung beginnt normalerweise im Sinusknoten, der sich im oberen Bereich des rechten Vorhofes befindet. Der Sinusknoten enthält dabei sogenannte Schrittmacherzellen, die in der Lage sind spontan zu depolarisieren. Der Potentialverlauf der Schrittmacherzellen ist in Abb. 2.3 (a) dargestellt. An der Membran jeder Schrittmacherzelle liegt zunächst ein Ruhepotential an, dessen negativster Wert, das maximale diastolische Potential (MDP), etwa -70 mV beträgt [Silbernagl, 2012, S. 204]. Dieses Potential kommt durch die unterschiedliche Ionenverteilung zwischen dem intrazellulären und extrazellulären Raum zustande. Während der Ruhephase der Schrittmacherzelle sind die K^+ -Ionen überwiegend im intrazellulären Raum konzentriert, wogegen sich die Na^+ -Ionen mehrheitlich im extrazellulären Raum befinden [Schwegler & Lucius, 2011, S. 31]. Direkt nachdem das Schrittmacherpotential das MDP erreicht hat, beginnen sich die HCN-Kanäle (hyperpolarization-activated and cyclic nucleotide-gated ion channels) zu öffnen, sodass ein Ionenstrom Na^+ -Ionen in das Innere der Zelle transportieren kann.

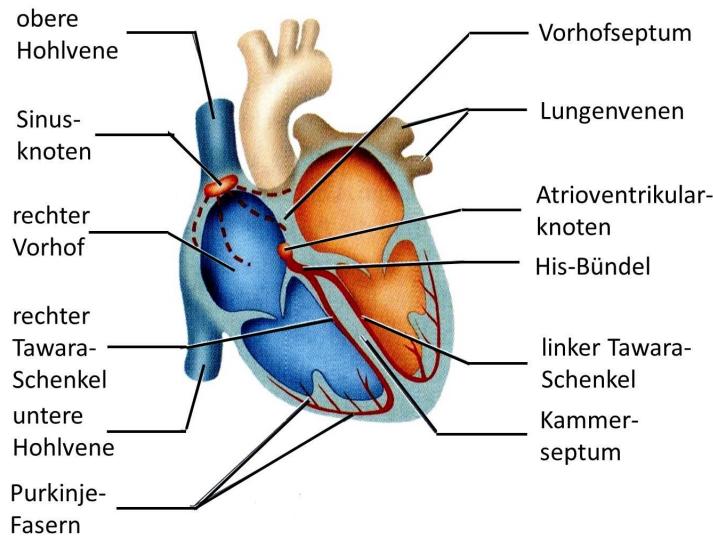


Abb. 2.2. Darstellung des Erregungsleitungssystems des Herzens, modifiziert nach [Schwegler & Lucius, 2011, S. 259].

Die Zelle beginnt sich langsam zu depolarisieren. Erreicht das Schrittmacherpotential das Schwellenpotential von etwa -40 mV , kommt es durch die Öffnung weiterer Ionenkanäle zu einem stark ansteigenden Ca^{2+} -Einstrom und damit zur vollständigen Depolarisation der Zelle. Es wird ein Aktionspotential ausgelöst. Das Schrittmacherpotential nimmt dabei sogar positive Werte an. Dadurch öffnen sich nun K^+ -Kanäle, die K^+ -Ionen in den extrazellulären Raum befördern. Das Schrittmacherpotential nimmt so wieder ab. Durch eine Natrium-Kalium-ATPase werden nun die Na^+ -Ionen wieder in den extrazellulären und die K^+ -Ionen in den intrazellulären Raum transportiert, sodass die Schrittmacherzelle wieder repolarisiert. Der Sinusknoten bestimmt in der Regel die Herzrate und wird daher als primärer Schrittmacher bezeichnet. Ohne externe Einflüsse werden dort Aktionspotentiale mit einer Rate von 60-100 bpm ausgelöst. Dies wird als Sinusrhythmus bezeichnet [Silbernagl, 2012, S. 204-205].

Das von der Schrittmacherzelle im Sinusknoten ausgelöste Aktionspotential beeinflusst die benachbarten Herzmuskelzellen des Myokards. Der Potentialverlauf der Herzmuskelzellen ist in Abb. 2.3 (b) dargestellt. Die Herzmuskelzellen enthalten spannungsgesteuerte Na^+ -Kanäle, die durch das Aktionspotential ihr Schwellenpotential überschreiten und schließlich ebenfalls depolarisieren und ein Aktionspotential auslösen. Auf diese Weise kann sich die elektrische Erregung über die gesamten Vorhöfe ausbreiten. Durch das positive Potential an der Membran der Herzmuskelzellen werden nun spannungsgesteuerte K^+ -Kanäle geöffnet, welche das Potential zunächst ausgleichen. Im Gegensatz zu den Schrittmacherzellen hat das Aktionspotential der Herzmuskelzellen ein vergleichsweise lang andauerndes Plateau. Dadurch kann sich die Erregungswelle nur in eine Richtung bewegen, da die bereits depolarisierten Herzmuskelzellen keine weiteren Aktionspotentiale mehr auslösen können. Die Repolarisation erfolgt über die Aktivierung spezifischer K^+ -Kanäle. Nach dem Aktionspotential wird das ursprüngliche Verhältnis der Na^+ - und K^+ -Konzentrationen mit der Natrium-Kalium-ATPase wiederhergestellt [Silbernagl, 2012, S. 204-205]. Über das Myokard der Vorhöfe erreicht die Erregungswelle schließlich den Atrioventrikulknoten (AV-Knoten). Der AV-Knoten befindet sich im Bereich des

Septums zwischen den Vorhöfen und den Kammern. Die Erregungswelle kann sich dabei nicht über die Herzwand auf die Kammern ausbreiten, sodass die Erregungswelle ausschließlich über den AV-Knoten in die Kammern geleitet wird. Der AV-Knoten verzögert die Erregungsausbreitung um etwa 20-60 ms [Schwegler & Lucius, 2011, S. 260]. Während dieser Zeit kontrahieren die Vorhöfe am Ende der Füllungsphase. Der AV-Knoten enthält ebenfalls Schrittmacherzellen, die jedoch mit einer langsameren Frequenz (40-55 bpm) Aktionspotentiale auslösen. Diese kommen nur dann zum Tragen, wenn die Erregung durch den Sinusknoten ausfällt [Silbernagl, 2012, S. 204].

Nach der Verzögerung im AV-Knoten breitet sich die Erregungswelle über das His-Bündel im Kammerseptum zu den Tawaraschenkeln aus, die ebenfalls im Kammerseptum beginnen und weiter bis zur Herzspitze verlaufen. Von dort aus erreicht die Erregungswelle über die Purkinje-Fasern die Zellen des Kammermyokards, wodurch die Kontraktion der Kammermuskulatur ausgelöst wird. Dabei verläuft die Erregung des Kammermyokards von innen nach außen und von der Herzspitze in Richtung Basis. Das His-Bündel, die Tawaraschenkel und die Purkinje-Fasern enthalten ebenfalls Schrittmacherzellen mit Frequenzen zwischen 25 und 40 bpm, die beim Ausfall der vorherigen Schrittmacher-Zentren einspringen können [Schwegler & Lucius, 2011, S. 260], [Silbernagl, 2012, S. 204].

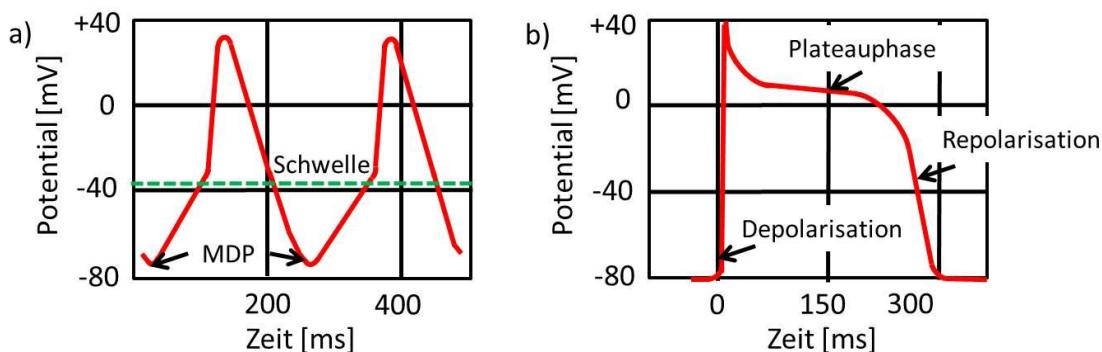


Abb. 2.3. Darstellung der Potentialverläufe der Schrittmacherzellen (a) und der Herzmuskelzellen des Myokards (b), modifiziert nach [Klinke et al., 2005, S. 150, S.153].

2.1.3 Das Elektrokardiogramm (EKG)

Die im vorherigen Abschnitt beschriebenen elektrischen Vorgänge werden durch das EKG in Form einer zeitabhängigen Spannungskurve aufgezeichnet. Dazu bringt man Elektroden in bestimmten Positionen auf der Haut an, die die auftretenden Potentialdifferenzen aufzeichnen. Diese Potentialdifferenzen entstehen durch die unterschiedlichen Ladungszustände zwischen den depolarisierten und nicht depolarisierten Herzmuskelzellen während der Erregungsausbreitung und der Erregungsrückbildung. Die zwischen den verschiedenen Potentialen entstehenden elektrischen Felder unterscheiden sich dabei in ihrer Richtung und Stärke. Während die Richtung der Feldlinien von der Ausbreitungsrichtung der Erregungswelle abhängig ist, ist die Stärke von der Anzahl der beteiligten Herzmuskelzellen abhängig. Das an den Elektroden erfasste elektrische Feld entsteht dann durch die Superposition aller elektrischen Felder, die zeitlich und räumlich variieren. Je nachdem wie die Elektroden zu den elektrischen Feldlinien ausgerichtet sind, ergeben sich positive oder negative Spannungen im EKG [Silbernagl, 2012, S. 208]. Die verschiedenen Anordnungen

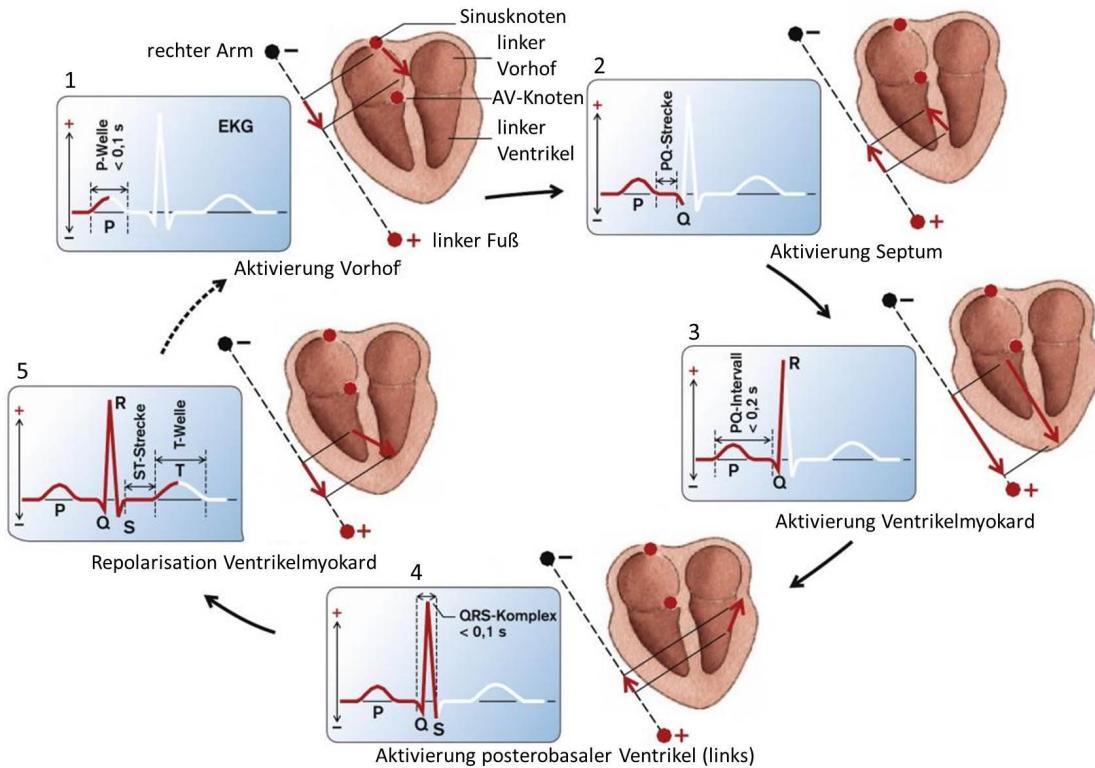


Abb. 2.4. Sequenz der Erregungsausbreitung und deren Zuordnung zu den im EKG sichtbaren Abschnitten. Die Pfeile deuten die Ausbreitungsrichtung der Erregungswelle und deren Projektion auf die hier verwendete Ableitung an, modifiziert nach [Klinke et al., 2005, S. 166].

der Elektroden werden als Ableitungen bezeichnet. Weiterhin zu beachten ist, dass im EKG nur die elektrischen Felder des Myokards messbar sind, da das Myokard eine deutlich größere Masse besitzt, als das Erregungsleitungssystem [Schwegler & Lucius, 2011, S. 260].

Die Entstehung der EKG-Kurve ist in Abb. 2.4 zu sehen. Die zuerst erscheinende P-Welle wird durch die Depolarisation im Vorhof verursacht. Nachdem die Erregung vom Sinusknoten ausgelöst wurde, breitet sich die Erregungswelle über den rechten und etwas verzögert über den linken Vorhof aus. Der aufsteigende Verlauf der P-Welle entspricht daher der Depolarisation des rechten Vorhofs, der abfallende Verlauf der P-Welle dagegen der Depolarisation im linken Vorhof. Die Dauer der P-Welle beträgt unter 100 ms. Die Verzögerung im AV-Knoten und die Überleitung über das His-Bündel zu den Tawaraschenkeln ist im EKG nicht messbar. Es zeigt sich eine isoelektrische Linie, die als PQ-Strecke bezeichnet wird. Das PQ-Intervall beginnt mit der P-Welle und endet mit der Q-Zacke. Das PQ-Intervall entspricht der atrioventrikulären Überleitungszeit und beträgt unter 200 ms. Die Depolarisation der Kammern beginnt mit dem Kammerseptum, die sich in der EKG-Kurve mit der Q-Zacke zeigt. Die darauf folgende R-Zacke hat üblicherweise den höchsten Spannungswert im EKG, da hier die meisten Herzzellen des Kammermyokards depolarisieren. Nachdem die Erregungswelle die Herzspitze erreicht hat, verläuft diese über die linke und rechte Kammer in Richtung Basis, was sich im EKG mit der S-Zacke zeigt. Die gesamte Depolarisation der Kammern wird in der EKG-Kurve als QRS-Komplex bezeichnet und beträgt unter 100 ms. Zur gleichen Zeit findet die Repolarisation der Vorhöfe

statt, die jedoch durch den QRS-Komplex nicht sichtbar ist. Nachdem die Kammern nun vollständig depolarisiert sind, folgt erneut eine isoelektrische Linie, die ST-Strecke. Die Dauer der ST-Strecke hängt stark von der Herzfrequenz ab. Die T-Welle gibt die Repolarisation der Kammern wieder. Da die zuletzt depolarisierten Herzzellen schneller repolarisieren, erfolgt die Repolarisation der Kammern in umgekehrter Richtung. Daher zeigt die T-Welle normalerweise in die gleiche Richtung wie der QRS-Komplex. Das QT-Intervall entspricht dem gesamten Depolarisierungs- und Repolarisierungsvorgang der Kammern. Die Dauer des QT-Intervalls hängt von der Herzfrequenz ab und beträgt bei 75 bpm etwa 350-400 ms [Silbernagl, 2012, S. 208]. Der typische Verlauf einer EKG-Kurve ist in Abb. 2.5 dargestellt.

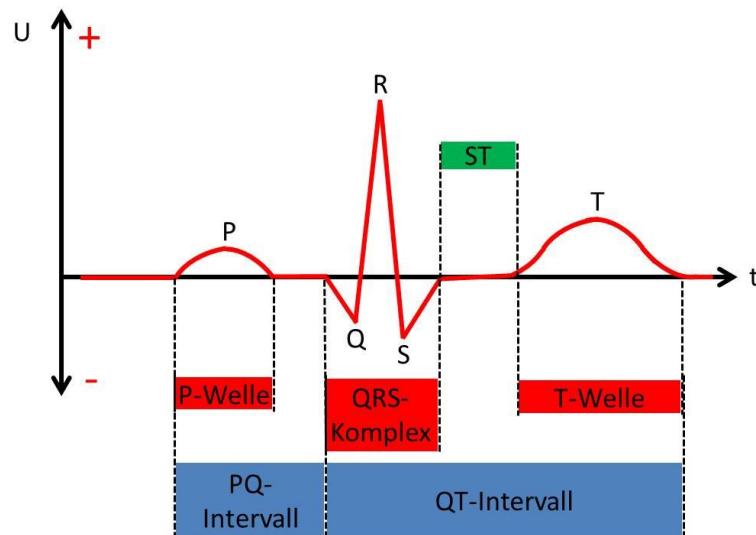


Abb. 2.5. Bezeichnungen der einzelnen Abschnitte der EKG-Kurve. Eingetragen sind die P-Welle, der QRS-Komplex, die ST-Strecke (ST), die T-Welle, sowie das PQ-Intervall und das QT-Intervall, modifiziert nach [Silbernagl, 2012, S. 209].

Ein weiteres wichtiges Intervall aus dem EKG ist das RR-Intervall. Das RR-Intervall ist der zeitliche Abstand zweier aufeinanderfolgender R-Zacken. Die Folge der RR-Intervalle wird als RR-Zeitreihe bezeichnet. Aus der RR-Zeitreihe kann die instantane Herzrate abgeleitet werden. Mit Hilfe der RR-Zeitreihe oder der Herzrate kann der Herzrhythmus untersucht werden. Der normale Herzerhythmus folgt einem Sinus-Rhythmus bei einer Herzrate von 60 bis 80 bpm. Unter physischer Belastung kommt es unter dem Einfluss des Sympathikus zu einer Erhöhung der Herzrate auf über 80 bpm. Eine Herzrate von über 100 bpm in Ruhe wird als Tachykardie bezeichnet. Bei einer Herzrate unter 60 bpm spricht man von einer Bradykardie. Eine Bradykardie stellt man besonders bei Sportlern in Ruhe fest, bei denen ein erhöhter Einfluss des Parasympathikus die Herzrate senkt. Weiterhin wird die Herzrate durch die Atmung beeinflusst, was man als respiratorische Arrhythmie bezeichnet. Bei Inspiration erhöht sich durch die Hemmung des Parasympathikus die Herzrate, während sich bei Expiration die Herzrate wieder senkt [Klinke et al., 2005, S. 169-170]. Die ständigen Schwankungen der Herzrate werden als Herzratenvariabilität (HRV) bezeichnet, die in dieser Arbeit noch genauer untersucht werden soll. Im folgenden Abschnitt wird der Einfluss von Sympathikus und Parasympathikus auf die Herzrate etwas genauer beschrieben.

2.1.4 Das vegetative Nervensystem

Das vegetative Nervensystem ist für die Regelung der Funktionen der inneren Organe und des Kreislaufs zuständig. Diese Regelungen finden weitestgehend unbewusst statt, weshalb man auch vom autonomen Nervensystem spricht. Die Steuerung des vegetativen Nervensystems wird durch den Hypothalamus übernommen. Das vegetative Nervensystem besteht aus dem Parasympathikus, dem Sympathikus und dem Darmnervensystem. Die Zentren des Parasympathikus liegen im Hirnstamm und dem Sakralmark. Die meisten Organe, darunter auch das Herz, sind über den Nervus Vagus mit dem Hirnstamm verbunden. Die Zentren des Sympathikus befinden sich im Brust- und Lendenmark [Silbernagl, 2012, S. 82-85].

Sympathikus und Parasympathikus innervieren die Organe entweder gegensätzlich oder ergänzend. Im Herz treten sie als Antagonisten auf. Während die Aktivität des Sympathikus die Herzrate erhöht, wird diese vom Parasympathikus gesenkt [Silbernagl, 2012, S. 84-85]. Der Einfluss des Parasympathikus erfolgt über den Neurotransmitter Acetylcholin (ACh). ACh öffnet im Sinusknoten, AV-Knoten und im Vorhof K^+ -Kanäle. Zudem wird der Ca^{2+} -Einstrom reduziert. Im Sinusknoten wird dadurch die Impulsfrequenz der Schrittmacherzellen gesenkt (negative Chronotropie). Im Potentialverlauf äußert sich dies durch ein negativeres MDP und einen flacheren Anstieg des Potentials zu Beginn der Depolarisation. Im AV-Knoten wirkt ACh negativ dromotrop, dass heißt die Überleitungszeit wird verlangsamt. Im Potentialverlauf des AV-Knotens ist ein flacherer Anstieg des Aktionspotentials und eine niedrigere Amplitude des Aktionspotentials zu beobachten [Silbernagl, 2012, S. 86-87, S. 206]. Der Sympathikus wirkt über die Cathecholamine Noradrenalin und Adrenalin auf die Herztätigkeit ein. Die Cathecholamine unterstützen die Öffnung der HCN-Kanäle, erhöhen den Ca^{2+} -Einstrom und führen so zu einem steileren Anstieg des Aktionspotentials im Sinusknoten. Sie wirken positiv chronotrop. Zudem wirken sie ebenfalls über die Beeinflussung von K^+ - und Ca^{2+} -Strömen positiv dromotrop auf die Erregungsüberleitung im AV-Knoten. Die Cathecholamine erhöhen zusätzlich die Kontraktilität und die Relaxationsgeschwindigkeit des Myokards [Silbernagl, 2012, S. 88, S. 206].

2.2 Mathematische Grundlagen

2.2.1 Zeitkontinuierliche Signale

Der zeitliche Verlauf einer beobachteten Größe wird als Signal bezeichnet. Die beobachteten Größen können dabei physikalische Größen sein, die bestimmte Informationen enthalten. Kann der Verlauf eines Signals durch eine mathematische Funktion exakt beschrieben werden, spricht man von einem deterministischen Signal. Kann der Verlauf eines Signals nicht durch eine deterministische Beschreibung vorhergesagt werden, so handelt es sich um ein stochastisches Signal. Signale können reellwertig oder komplexwertig sein. Für ein komplexwertiges, kontinuierliches Signal $y(t)$ erhalten wir die Abbildungsvorschrift [Kiencke & Jäkel, 2008, S. 4, S. 53]:

$$y : \mathbb{R} \rightarrow \mathbb{C}, t \mapsto y(t) . \quad (2.1)$$

2.2.2 Energiesignale

Signale werden als Energiesignale bezeichnet, wenn die im Signal enthaltene Energie endlich ist:

$$\int_{-\infty}^{\infty} y(t)y^*(t)dt < \infty . \quad (2.2)$$

Daraus folgt direkt, dass ein Energiesignal von endlicher Dauer sein muss:

$$\lim_{t \rightarrow \pm\infty} y(t) = 0 . \quad (2.3)$$

Das Innenprodukt zweier Energiesignale $y_1(t), y_2(t)$ ist definiert durch:

$$\langle y_1(t), y_2(t) \rangle_t = \int_{-\infty}^{\infty} y_1(t)y_2^*(t)dt . \quad (2.4)$$

Die Norm eines Energiesignals ergibt sich damit zu:

$$\|y\| = \sqrt{\langle y(t), y(t) \rangle_t} . \quad (2.5)$$

Die Energie des Signals erhält man durch die quadratische Norm des Signals:

$$E_y = \|y\|^2 = \langle y(t), y(t) \rangle \quad (2.6)$$

[Kiencke & Jäkel, 2008, S. 55-58] [Kiencke et al., 2008, S. 1].

2.2.3 Orthonormale Funktionensysteme

Ein Funktionenraum wird durch die Basisfunktionen $\phi_i(t)$ aufgespannt. Für eine orthonormale Basis $\{\phi_i : i = -\infty, \dots, \infty\}$ gilt die Bedingung:

$$\langle \phi_i(t), \phi_j(t) \rangle_t = \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases} . \quad (2.7)$$

Das Signal $y(t)$ kann mit Hilfe von Basisfunktionen $\phi_i(t)$ als eine Reihe dargestellt werden:

$$y(t) = \sum_{i=-\infty}^{\infty} a_i \phi_i(t) . \quad (2.8)$$

Die Koeffizienten a_i erhält man durch:

$$a_i = \langle y(t), \phi_i(t) \rangle_t . \quad (2.9)$$

Diese Gleichung kann als Projektion des Signals $y(t)$ auf die Basisfunktion $\phi_i(t)$ interpretiert werden [Kiencke et al., 2008, S. 35-36, S. 44].

2.2.4 Fourier-Transformation

Die Definition der Fourier-Transformation lautet:

$$Y(f) = \mathcal{F}\{y(t)\} = \langle y(t), e^{j2\pi ft} \rangle_t = \int_{-\infty}^{\infty} y(t) e^{-j2\pi ft} dt . \quad (2.10)$$

Dabei wird das Signal $y(t)$ auf die Basisfunktionen $\phi_f(t) = e^{j2\pi ft}$ projiziert, welche den komplexen Schwingungen der Frequenz f entsprechen. Das Signal wird demnach in die Spektralanteile $Y(f)$ der kontinuierlichen Frequenzen f zerlegt. Die Fourier-Transformierte $Y(f)$ ist somit die Darstellung des Signals $y(t)$ im Frequenzbereich und wird als Spektrum bezeichnet.

Die Definition der inversen Fourier-Transformation lautet:

$$y(t) = \mathcal{F}^{-1}\{Y(f)\} = \langle Y(f), e^{-j2\pi ft} \rangle_f = \int_{-\infty}^{\infty} Y(f) e^{j2\pi ft} df . \quad (2.11)$$

Die inverse Fourier-Transformation kann als Synthesegleichung verstanden werden, in der das Signal $y(t)$ als eine unendliche Summe der mit den infinitesimalen Spektralanteilen $Y(f)df$ gewichteten komplexen Schwingungen dargestellt wird. Die inverse Fourier-Transformation bildet somit das Spektrum $Y(f)$ in den Zeitbereich ab [Kiencke & Jäkel, 2008, S. 91ff].

2.2.5 Faltung und Korrelation

Die Faltung zweier Signale $x(t)$ und $y(t)$ ist definiert durch:

$$x(t) * y(t) = \langle x(t - \tau), y^*(\tau) \rangle_{\tau} = \int_{-\infty}^{\infty} x(t - \tau) y(\tau) d\tau . \quad (2.12)$$

Im Frequenzbereich korrespondiert die Faltung mit der Multiplikation [Kiencke & Jäkel, 2008, S. 95-96]:

$$\mathcal{F}\{x(t) * y(t)\} = \mathcal{F}\{x(t)\} \cdot \mathcal{F}\{y(t)\} . \quad (2.13)$$

Die Faltung spielt bei der Anwendung frequenzselektiver Filter eine wichtige Rolle. Wird das Filter durch seine Impulsantwort $g(t)$ vollständig charakterisiert, so ergibt sich für

das Eingangssignal $y_e(t)$ das Ausgangssignal [Kiencke & Jäkel, 2008, S. 133ff]:

$$y_a(t) = y_e(t) * g(t) \circledcirc Y_a(f) = Y_e(f) \cdot G(f) . \quad (2.14)$$

Einerseits werden frequenzselektive Filter dazu genutzt störende Signalanteile zu unterdrücken. Andererseits kann man mit Hilfe solcher Filter die Signalanteile bestimmter Frequenzbänder separat analysieren.

Die Korrelationsfunktion zweier Energiesignale $x(t)$ und $y(t)$ ist definiert mit:

$$\begin{aligned} R_{xy}^E(\tau) &= \langle x(t + \tau), y(t) \rangle_t = \int_{-\infty}^{\infty} x(t + \tau) y^*(t) dt \\ &= x(\tau) * y^*(-\tau) . \end{aligned} \quad (2.15)$$

Die Korrelationsfunktion gibt die Ähnlichkeit zweier Signale in Abhängigkeit der Zeitverschiebung τ an. Vergleicht man Gl. 2.15 für $\tau = 0$ mit Gl. 2.9, so erkennt man, dass die Koeffizienten a_i die Ähnlichkeit eines Signals $y(t)$ mit den Basisfunktionen $\phi_i(t)$ angeben. Die Spektralanteile aus der Fourier-Transformierten lassen sich auf diese Weise ebenfalls als Ähnlichkeit des Signals $y(t)$ mit harmonischen Schwingungen interpretieren [Kiencke & Eger, 2008, S. 204].

2.2.6 Zeitdiskrete Signale

In der digitalen Signalverarbeitung ist es nicht möglich, kontinuierliche Signale zu verarbeiten. Daher muss das Signal diskretisiert werden. Dazu wird das kontinuierliche Signal $y(t)$ zu den äquidistanten Zeitpunkten nt_A abgetastet:

$$y_n = y(nt_A), n \in \mathbb{Z} . \quad (2.16)$$

Die daraus entstehende Folge y_n wird als zeitdiskretes Signal bezeichnet. Der Abstand zwischen den Abtastzeitpunkten wird als Abtastzeit t_A bezeichnet. Die Abtastfrequenz ist der Kehrwert der Abtastzeit:

$$f_A = \frac{1}{t_A} \quad (2.17)$$

[Kiencke & Jäkel, 2008, S. 228]. Die Information zwischen den Abtastzeitpunkten geht dabei verloren. Damit das kontinuierliche Zeitsignal vollständig rekonstruiert werden kann, muss das Nyquist-Shannon-Abtasttheorem eingehalten werden. Dazu betrachtet man zunächst das zeitdiskrete Signal $y_*(t)$ als Multiplikation des zeitkontinuierlichen Signals $y(t)$ mit einem Impulskamm

$$y_*(t) = y(t) \cdot \sum_{n=-\infty}^{\infty} \delta(t - nt_A) , \quad (2.18)$$

wobei $\delta(t)$ ein Dirac-Impuls ist. Die Fourier-Transformation dazu lautet:

$$Y_*(f) = Y(f) * \frac{1}{t_A} \sum_{k=-\infty}^{\infty} \delta(f - kf_A) . \quad (2.19)$$

Die Faltung des Spektrums $Y(f)$ mit einem Impulskamm bewirkt eine mit der Abtastfrequenz f_A periodische Wiederholung von $Y(f)$ (Abb. 2.6). Daraus wird ersichtlich, dass das zeitkontinuierliche Signal genau dann rekonstruiert werden kann, wenn gilt:

$$f_A \geq \frac{f_{max}}{2} . \quad (2.20)$$

Hierbei ist f_{max} die höchste im Signal enthaltene Frequenz. Gl. 2.20 ist das Nyquist-Shannon-Abtasttheorem. Wird das Abtasttheorem nicht eingehalten, kommt es zur spektralen Überlappung, was als Aliasing bezeichnet wird. Das zeitkontinuierliche Signal kann durch Tiefpassfilterung mit der Grenzfrequenz $\frac{f_A}{2}$ und anschließender inverser Fourier-Transformation rekonstruiert werden. Dabei bezeichnet man $f_n = \frac{f_A}{2}$ als Nyquistfrequenz [Kiencke & Jäkel, 2008, S. 211ff]. Für die Rekonstruktion des kontinuierlichen Signals gibt es noch weitere Interpolationsmethoden, wie zum Beispiel die Spline-Interpolation [Kiencke & Eger, 2008, Abschnitt 2.3.3].

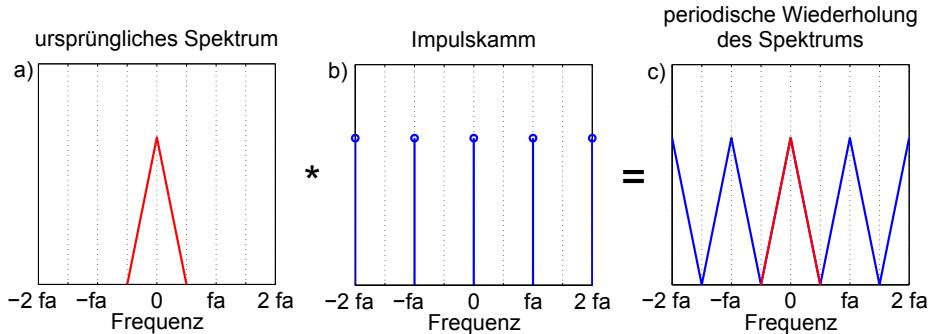


Abb. 2.6. Eine graphische Darstellung der Auswirkungen der Zeitdiskretisierung auf das Spektrum. In a) ist das Spektrum eines zeitkontinuierlichen Signals zu sehen. Das Spektrum verschwindet genau bei $\frac{f_A}{2}$. b) zeigt den Impulskamm, mit dem das Spektrum aus a) gefaltet wird. c) zeigt das periodische Spektrum des zeitdiskreten Signals. Das Abtasttheorem ist in diesem Fall genau eingehalten worden.

2.2.7 Diskrete Fourier-Transformation

Neben der Zeitdiskretisierung sind in der digitalen Signalverarbeitung noch weitere Schritte nötig. Zum einen kann das Signal nur für eine endliche Beobachtungszeit T beobachtet werden:

$$T = N \cdot t_A . \quad (2.21)$$

Dabei ist N die Anzahl der beobachteten Abtastwerte. Zum anderen muss auch das Frequenzspektrum abgetastet werden. Wählt man hierfür eine Auflösung von

$$\Delta f = \frac{f_A}{N} = \frac{1}{Nt_A} = \frac{1}{T} , \quad (2.22)$$

erhält man die diskrete Fourier-Transformation (DFT)

$$Y_k = \sum_{n=0}^{N-1} y_n e^{-j2\pi \frac{kn}{N}} \quad (2.23)$$

sowie die inverse Fourier-Transformation (IDFT):

$$y_n = \frac{1}{N} \sum_{k=0}^{N-1} Y_k e^{j2\pi \frac{kn}{N}} . \quad (2.24)$$

Dabei wird mit $k \in [0, N - 1]$ die diskrete Frequenz $k \cdot \Delta f$ indiziert. Für eine effizientere Berechnung der DFT verwendet man die zur DFT äquivalente schnelle Fourier-Transformation (FFT) [Kiencke & Jäkel, 2008, S. 253].

Durch die Begrenzung der Beobachtungszeit kommt es zu einer Verschmierung des Frequenzspektrums, was als Leckeffekt bezeichnet wird. Will man die Auflösung des Frequenzspektrums erhöhen, so wählt man im Frequenzbereich eine höhere Anzahl an Abtastwerten als im Zeitbereich. Dies wird als Zeropadding bezeichnet. Weitere Details zum Leckeffekt und Zeropadding findet man in [Kiencke & Jäkel, 2008, S. 260ff].

Weiterhin sei hier angemerkt, dass es ähnlich wie in Abb. 2.6 bei der IDFT des Spektrums Y_k zu einer mit der Beobachtungszeit T periodischen Wiederholung der Folge y_n im Zeitbereich kommt [Kiencke & Jäkel, 2008, S. 258].

2.2.8 Leistungsdichtespektrum

Bei der späteren Analyse der RR-Zeitreihe spielt die Verteilung der Energie auf verschiedene Frequenzbereiche eine besondere Rolle. Betrachten wir dazu nochmals die Korrelationsfunktion $R_{xy}^E(\tau)$ aus Gl. 2.15 für $\tau = 0$ und $y(t) = x(t)$ sowie Gl. 2.6, so erhält man:

$$R_{yy}^E(0) = \langle y(t), y(t) \rangle_t = E_y . \quad (2.25)$$

R_{yy}^E ist dabei die Autokorrelationsfunktion von $y(t)$ [Kiencke & Eger, 2008, S. 204]. Das Energiedichtespektrum $S_{yy}^E(f)$ erhält man durch Fourier-Transformation von R_{yy}^E mit Gl. 2.15 und Gl. 2.13 zu:

$$S_{yy}^E(f) = \mathcal{F}\{R_{yy}^E(\tau)\} \quad (2.26)$$

$$= \mathcal{F}\{y(\tau) * y^*(-\tau)\} \quad (2.27)$$

$$= Y(f)Y^*(f) = |Y(f)|^2 . \quad (2.28)$$

Diese Transformation wird auch als Transformation von Wiener und Khintchine bezeichnet [Kiencke & Eger, 2008, S. 220]. Durch Integration über S_{yy}^E erhält man wieder die Energie des Signals:

$$E_y = \int_{-\infty}^{\infty} S_{yy}^E(f) df = \langle Y(f), Y(f) \rangle_f . \quad (2.29)$$

Aus Gl. 2.29 und Gl. 2.25 erhält man den Satz von Parseval:

$$\langle y(t), y(t) \rangle_t = \langle Y(f), Y(f) \rangle_f . \quad (2.30)$$

Er besagt, dass die Signalenergie bei Anwendung der Fourier-Transformation erhalten bleibt [Kiencke & Jäkel, 2008, S. 94],[Kiencke et al., 2008, S. 2]. Für die DFT lautet der Satz von Parseval:

$$E_y = \sum_{n=0}^{N-1} |y_n|^2 = \frac{1}{N} \sum_{k=0}^{N-1} |Y_k|^2 \quad (2.31)$$

[Kiencke & Jäkel, 2008, S. 258]. Für zeitdiskrete Signale y_n der Dauer $N \cdot t_A$ kann das Energiedichtespektrum S_{yy} nur geschätzt werden. Diese Schätzung wird als Periodogramm bezeichnet und mit

$$\hat{S}_{yy}(k) = \frac{1}{N} Y_k Y_k^* \quad (2.32)$$

berechnet [Kiencke & Jäkel, 2008, S. 267].

Unter dem Periodogramm wird in der Literatur häufiger das Leistungsdichtespektrum (Power Spectral Density, PSD) verstanden. Dies ist insofern kein Widerspruch, da im Frequenzbereich die Unterscheidung zwischen Leistungs- und Energiesignal entfällt [Kiencke & Eger, 2008, S. 221]. Zudem kann ein Signal mit einer endlichen Beobachtungszeit T sowohl als Energie- als auch als Leistungssignal interpretiert werden [Kiencke & Jäkel, 2008, S. 56]. Das Periodogramm nach Gl. 2.32 bringt einige Probleme mit sich: die zeitliche Begrenzung T des Signals y_n führt im Frequenzbereich zu einer Faltung mit einer sinc^2 -Funktion (Leckeffekt). Die Schätzung ist weder erwartungstreu noch konsistent. Letzteres bedeutet, dass die Varianz für $T \rightarrow \infty$ nicht verschwindet [Kammeyer & Kroschel, 2009, S. 347]. Bei der Bartlett-Methode zerlegt man y_n in K gleichlange nicht überlappende Teilstücke der Länge N , berechnet für jede Teilstück das Periodogramm und mittelt anschließend über alle Periodogramme. Somit kann die Varianz reduziert werden. Um den Leckeffekt zu reduzieren und eine konsistente Schätzung zu erhalten, verwendet man die Welch-Methode, bei der sich die Teilstücke überlappen und die Teilstücke mit einer nicht rechteckigen Fensterfunktion multipliziert werden. Die Welch-Methode hat sich auch bei der Analyse der RR-Zeitreihe etabliert und wird in dieser Arbeit verwendet. Die genaueren Ausführungen dazu finden sich in [Morath, 2014] sowie in [Kammeyer & Kroschel, 2009, Kapitel 9].

2.2.9 Unschärferelation

Betrachtet man ein Signal der Zeitspanne Δ_t und der Bandbreite Δ_f , so gilt:

$$\Delta_t \cdot \Delta_f \geq \frac{1}{4\pi} . \quad (2.33)$$

Ein Signal mit kurzer Zeitspanne Δ_t , hat ein Spektrum mit großer Bandbreite Δ_f und umgekehrt. Sowohl für die DFT als auch das Periodogramm hat dies zur Folge, dass die Frequenzauflösung Δf von der Wahl der Beobachtungszeit T abhängt. Für die im folgenden Abschnitt beschriebenen Zeit-Frequenz-Darstellungen hat dies zur Folge, dass eine bessere Auflösung im Zeitbereich eine schlechtere Auflösung im Frequenzbereich bewirkt. Eine bessere Frequenzauflösung Δf erfordert umgekehrt eine längere Beobachtungszeit T [Kiencke & Jäkel, 2008, S. 118-121].

2.2.10 Wavelet-Transformation

Die Fourier-Transformierte $Y(f)$ und die PSD $S_{yy}(f)$ geben Aufschluss darüber, welche Frequenzen im Signal $y(t)$ vorhanden sind. Dabei wird implizit angenommen, dass sich das Spektrum zeitlich nicht verändert. Demnach erstrecken sich die enthaltenen Frequenzkomponenten im Zeitbereich über die gesamte Beobachtungszeit T . Allgemeiner wird dabei für das Signal $y(t)$ Stationarität vorausgesetzt. Bei Signalen wie der RR-Zeitreihe ist diese Voraussetzung jedoch nicht gegeben. Die RR-Zeitreihe ist kein stationäres Signal. Insbesondere das Spektrum der RR-Zeitreihe ist zeitvariant [Rajendra Acharya et al., 2006]. Daher ist man an Verfahren interessiert, die eine instantane Betrachtung des Signals im Zeit- und Frequenzbereich ermöglichen. Die verschiedenen Varianten der Wavelet-Transformation ermöglichen die Darstellung des Signals im Zeit-Frequenz-Bereich.

Kontinuierliche Wavelet-Transformation

Die kontinuierliche Wavelet-Transformation (Continuous Wavelet Transformation, CWT) ist definiert durch:

$$W_y^\psi(a, b) = \langle y(t), \psi_{a,b}(t) \rangle_t = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} y(t) \psi^* \left(\frac{t-b}{a} \right) dt . \quad (2.34)$$

Die CWT enthält einen Skalierungsparameter a und einen Translationsparameter b . $\psi_{a,b}(t)$ wird als Wavelet bezeichnet, dass durch a skaliert und b zeitlich verschoben wird [Kiencke et al., 2008, S. 115-117]. Das Wavelet $\psi_{a,b}(t)$ muss dabei verschiedene Kriterien erfüllen, die sicherstellen, dass die inverse CWT eindeutig ist. Als notwendige und hinreichende Bedingung muss das Wavelet $\psi_{a,b}(t)$ die Zulässigkeitsbedingung

$$C_\psi = \int_{-\infty}^{\infty} \frac{|\Psi(af)|}{|f|} df < \infty \quad (2.35)$$

mit der Fourier-Transformierten $\Psi_{a,b}(f)$

$$\Psi_{a,b}(f) = \sqrt{a} \Psi(af) e^{-j2\pi fb} \quad (2.36)$$

erfüllen [Kiencke et al., 2008, S. 119]. Daraus lassen sich die folgenden Kriterien herleiten:

$$\lim_{|f| \rightarrow \infty} \Psi_{a,b}(f) = 0 \quad (2.37)$$

$$\lim_{f \rightarrow 0} \Psi_{a,b}(f) = 0 \quad (2.38)$$

$$\int_{-\infty}^{\infty} \psi(t) dt = 0 \quad (2.39)$$

$$\int_{-\infty}^{\infty} |t \cdot \psi(t)| dt < \infty \quad (2.40)$$

$$\int_{-\infty}^{\infty} |\psi(t)|^2 dt = 1 . \quad (2.41)$$

Gl. 2.37 und Gl. 2.38 sagen aus, dass $\Psi_{a,b}(f)$ Bandpasscharakter hat. Für den Zeitbereich bedeutet dies, dass das Wavelet $\psi_{a,b}(t)$ ein mittelwertfreies, oszillierendes Signal sein muss

(Gl. 2.39). Gl. 2.40 sichert die Kompaktheit von $\psi_{a,b}(t)$. Das Wavelet $\psi_{a,b}(t)$ ist damit um die mittlere Zeit $t_\psi = b$ konzentriert und verschwindet mit zunehmendem Abstand von t_ψ . Gl. 2.41 stellt sicher, dass die CWT die Signalenergie nicht verändert. Daher wird $\psi_{a,b}(t)$ mit dem Faktor $\frac{1}{\sqrt{a}}$ normiert [Kiencke et al., 2008, S. 119-124].

Die Definition der CWT in Gl. 2.34 erinnert an die Korrelationsfunktion aus Gl. 2.15. Die CWT untersucht die Ähnlichkeit des Signals $y(t)$ mit dem Wavelet $\psi_{a,b}(t)$. Durch die Kompaktheit kann $\psi_{a,b}(t)$ als eine um b verschobene Fensterfunktion verstanden werden, die einen Ausschnitt aus $y(t)$ auf Ähnlichkeiten analysiert. Somit können zeitliche Veränderungen dieser Ähnlichkeiten lokalisiert werden. Die Skalierung a ändert die Breite von $\psi_{a,b}(t)$ im Zeitbereich. Ein größeres a analysiert einen breiteren Ausschnitt von $y(t)$. Im Frequenzbereich führt dies zu einem schmaleren Bandpass $\Psi_{a,b}(f)$ (vgl. mit der Unschärferelation, Abschnitt 2.2.9). Bei näherer Betrachtung kann a über

$$f = \frac{f_c}{a} \quad (2.42)$$

mit der Mittenfrequenz f_c von $\Psi_{a,b}(f)$ auch mit der im Signal $y(t)$ enthaltenen Frequenz f assoziiert werden [Kiencke et al., 2008, S. 116]. Die Darstellung des Betragsquadrats von $W_y^\psi(a, b)$ in Abhängigkeit von a und b wird als Skalogramm bezeichnet. Verwendet man statt a die damit assoziierte Frequenz f , erhält man eine Zeit-Frequenz-Darstellung von $y(t)$ [Kiencke et al., 2008, S. 118].

Diskrete Wavelet Transformation

Die diskrete Wavelet Transformation (DWT) wird ähnlich wie die DFT aus der Fourier-Transformation durch Diskretisierung der Parameter a und b hergeleitet. Man wählt dazu eine dyadische Diskretisierung mit

$$a_k = 2^k \quad (2.43)$$

$$b_{m,k} = m \cdot 2^k t_A \quad (2.44)$$

und erhält dann für das Wavelet $\psi_{m,k}(n)$ und die Wavelet-Koeffizienten $W_y^\psi(m, k)$

$$\psi_{m,k}(n) = 2^{-\frac{k}{2}} \psi(2^{-k} n - m) \quad (2.45)$$

$$W_y^\psi(m, k) = \langle y(n), \psi_{m,k}(n) \rangle_n . \quad (2.46)$$

Dabei wurde mit $t = n \cdot t_A$ die Zeit diskretisiert und die Abtastzeit t_A in den Gleichungen unterdrückt [Kiencke et al., 2008, S. 149-152]. Durch die dyadische Diskretisierung erhält man mit den zeitverschobenen und skalierten Wavelets $\psi_{m,k}(n)$ ein orthonormales Basisystem [Addison, 2002, S. 67-69]. Die Berechnung der Wavelet-Koeffizienten nach Gl. 2.46 ist sehr aufwendig. Man kann statt dessen die DWT mit Hilfe einer Filterbank realisieren. Die Interpretation der DWT als Filterbank soll im Folgenden motiviert werden.

Wir betrachten ein Signal $y_0(n)$ aus einem Funktionenraum V_0 , dessen maximale Frequenz f_n beträgt. Das Signal hat also Tiefpasscharakter. Die Wavelets $\psi_{m,1}(n)$ mit fester Skalierung $k = 1$ spannen einen Unterraum W_1 auf, dessen Signale $y_1^{HP}(n)$ im Frequenzbereich $[f_n \cdot 2^{-1}, f_n]$ liegen. Die Wavelets $\psi_{m,1}(n)$ projizieren also $y_0(n)$ auf W_1 mit

$$d_1(m) = \langle y_0(n), \psi_{m,1}(n) \rangle , \quad (2.47)$$

wobei mit d_1 die Wavelet-Koeffizienten bezeichnet werden. Um das Signal $y_0(n)$ auch auf einen Unterraum V_1 projizieren zu können, dessen Signale $y_1^{TP}(n)$ im Frequenzbereich $[0, f_n 2^{-1}]$ liegen, benötigt man die sogenannten Skalierungsfunktionen $\phi_{m,1}(n)$. Die Skalierungsfunktionen $\phi_{m,1}(n)$ bilden ebenfalls ein orthonormales Basissystem und spannen den Unterraum V_1 auf. Damit erhalten wir die Koeffizienten im Tiefpassbereich zu

$$c_1(m) = \langle y_0(n), \phi_{m,1}(n) \rangle . \quad (2.48)$$

Der Funktionenraum V_0 wird so in die Unterräume

$$V_0 = V_1 \cup W_1 \quad (2.49)$$

zerlegt. Das Signal $y_0(n)$ wird in die beiden Signale

$$y_0(n) = y_1^{TP}(n) + y_1^{HP}(n) \quad (2.50)$$

zerlegt, wobei mit $y_1^{TP}(n)$ das Signal im Tiefpassbereich und mit $y_1^{HP}(n)$ das Signal im Hochpassbereich bezeichnet wird. Das Signal $y_1^{TP}(n)$ kann nun auf gleiche Weise für $k = 2$ aufgespalten werden. Im allgemeinen Fall wird ein Signal $y_{k-1}(n)$ aus dem Funktionenraum V_{k-1} in die beiden Unterräume V_k und W_k projiziert. Wir erhalten:

$$V_{k-1} = V_k \cup W_k \quad (2.51)$$

$$y_{k-1}(n) = y_k^{TP}(n) + y_k^{HP}(n) . \quad (2.52)$$

Die verwendeten Basissysteme lauten:

$$\phi_{m,k}(n) = 2^{-\frac{k}{2}} \phi(2^{-k}n - m) \quad (2.53)$$

$$\psi_{m,k}(n) = 2^{-\frac{k}{2}} \psi(2^{-k}n - m) . \quad (2.54)$$

Die Skalierungsfunktionen $\phi_{m,k}(n)$ und die Wavelets $\psi_{m,k}(n)$ müssen dabei ebenfalls orthonormal sein. Die Koeffizienten der Unterräume erhält man durch die Projektionsvorschriften

$$c_k(m) = \langle y_k(n), \phi_{m,k}(n) \rangle \quad (2.55)$$

$$d_k(m) = \langle y_k(n), \psi_{m,k}(n) \rangle . \quad (2.56)$$

Damit können die Signale $y_k^{TP}(n)$ und $y_k^{HP}(n)$ als Reihenentwicklung angegeben werden:

$$y_k^{TP}(n) = \sum_{m=-\infty}^{\infty} c_k(m) \phi_{m,k}(n) \quad (2.57)$$

$$y_k^{HP}(n) = \sum_{m=-\infty}^{\infty} d_k(m) \psi_{m,k}(n) . \quad (2.58)$$

$y_k^{TP}(n)$ liegt dann im Frequenzbereich $[0, f_n 2^{-k}]$ und $y_k^{HP}(n)$ im Frequenzbereich $[f_n 2^{-k}, f_n 2^{-k+1}]$ vor. Dies entspricht einer Filterung von $y_{k-1}(n)$ mit einem Tiefpass $g(n)$ bzw. Hochpass $h(n)$. Die Realisierung als Filterbank ist in Abb. 2.7 zu sehen. Das

Signal $y(n)$ wird zunächst mit $g(n)$ und $h(n)$ gefiltert. Anschließend wird die Abtastrate f_A und somit auch f_n um den Faktor 2 reduziert, womit die Skalierung realisiert wird. Das Verfahren wird iterativ mit dem Signal im Tiefpassbereich wiederholt. Für die Zeit-Frequenz-Darstellung erhalten wir damit verschiedene von der Skalierungsstufe abhängige Auflösungen. Mit jeder Stufe wird die Frequenzauflösung um den Faktor 2 feiner. Durch die niedrigere Abtastrate wird im Gegenzug die Zeitauflösung um den Faktor 2 grober [Kiencke et al., 2008, Abschnitt 4.2].

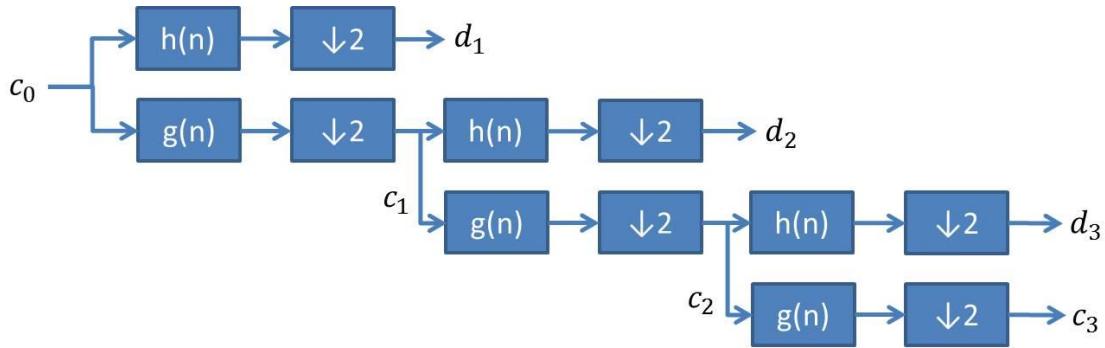


Abb. 2.7. Realisierung der DWT als Filterbank für 3 Skalierungsstufen. Jede Filterstufe besteht aus dem Tiefpassfilter $g(n)$, dem Hochpassfilter $h(n)$ und der anschließenden Halbierung der Abtastrate. Weiterhin sind die entsprechenden Koeffizienten c_k und d_k je nach Skalierungsstufe k eingetragen.

Mit Hilfe von Gl. 2.57, Gl. 2.58 und Gl. 2.52 lassen sich die verschiedenen Signalanteile rekonstruieren. Die Signalrekonstruktion kann ebenfalls durch eine Filterbank realisiert werden (Abb. 2.8). Dabei können gerade die gespiegelten Filter $g(-n)$ und $h(-n)$ verwendet werden. Vor jeder Filterstufe erfolgt eine Erhöhung der Abtastrate um den Faktor 2. Man erhält damit auch die Möglichkeit, nur die Signale bestimmter Frequenzbereiche zu rekonstruieren und andere Frequenzbereiche zu unterdrücken [Mallat, 1989].

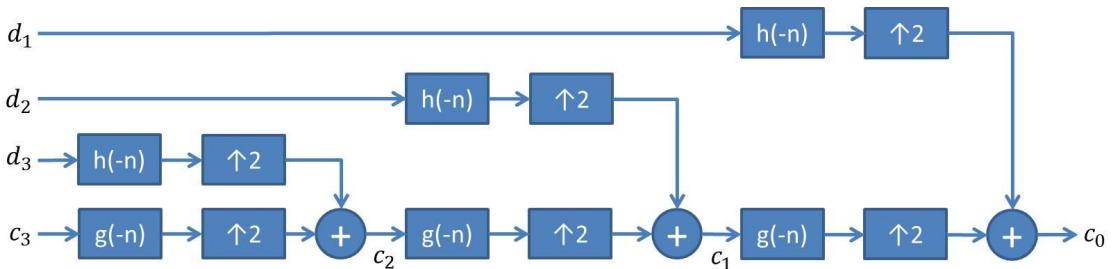


Abb. 2.8. Darstellung der Signalrekonstruktion der DWT als Filterbank. Die Rekonstruktion erfolgt mit den gespiegelten Filtern $g(-n), h(-n)$ und anschließender Erhöhung der Abtastrate um den Faktor 2.

Die Darstellung in einer Zeit-Frequenz-Ebene kann sowohl mit Hilfe der Koeffizienten der entsprechenden Frequenzbänder als auch mit Hilfe der rekonstruierten Signale erstellt werden. Letzteres hat den praktischen Vorteil, dass die Abtastraten der rekonstruierten Signale und des ursprünglichen Signals gleich sind [Mallat, 1989].

Detailliertere mathematische Darstellungen der DWT, insbesondere zur Berechnung der Skalierungsfunktionen und der Impulsantworten der Filter $g(n)$ und $h(n)$ finden sich in [Kiencke et al., 2008, Kapitel 4], [Addison, 2002, Kapitel 3] und [Mallat, 1989].

Wavelet Packet Analysis

Die Wavelet Packet Analysis (WPA) ist eine Verallgemeinerung der im vorherigen Abschnitt beschriebenen DWT. Während bei der DWT nur die Signale $y_k^{TP}(n)$ im Tiefpassbereich $[0, f_n 2^{-k}]$ in der folgenden Skalierungsstufe zerlegt werden, wird bei der WPA auch das Signal $y_k^{HP}(n)$ im Hochpassbereich $[f_n 2^{-k}, f_n 2^{-k+1}]$ weiter zerlegt. Dabei kann die gleiche Filterstruktur verwendet werden. Der Grund dafür liegt an der Reduzierung der Abtastrate um den Faktor 2. Der Vorgang soll in Abb. 2.9 illustriert werden. Ein Signal y_0 der Abtastrate f_A hat Signalanteile im Frequenzbereich $[0, f_n]$, wobei $f_n = \frac{f_A}{2}$ gilt. Nach der ersten Filterstufe erhalten wir Spektralanteile im Frequenzbereich $[0, \frac{f_n}{2}]$ sowie $[\frac{f_n}{2}, f_n]$. Nun wird die Abtastrate halbiert:

$$f'_A = \frac{f_A}{2} . \quad (2.59)$$

Unter Beachtung der in Gl. 2.19 beschriebenen periodischen Wiederholung des Spektrums um f'_A und dem Aspekt, dass reelle Signale um $f = 0$ symmetrische Spektren besitzen, wird das Spektrum im oberen Frequenzbereich $[\frac{f_n}{2}, f_n]$ in den Tiefpassbereich $[0, \frac{f_n}{2}]$ abgebildet. Daher kann auch das Signal im oberen Spektralbereich mit dem Tiefpass $g(n)$ in der folgenden Skalierungsstufe separiert werden [Kiencke et al., 2008, S. 209-212].

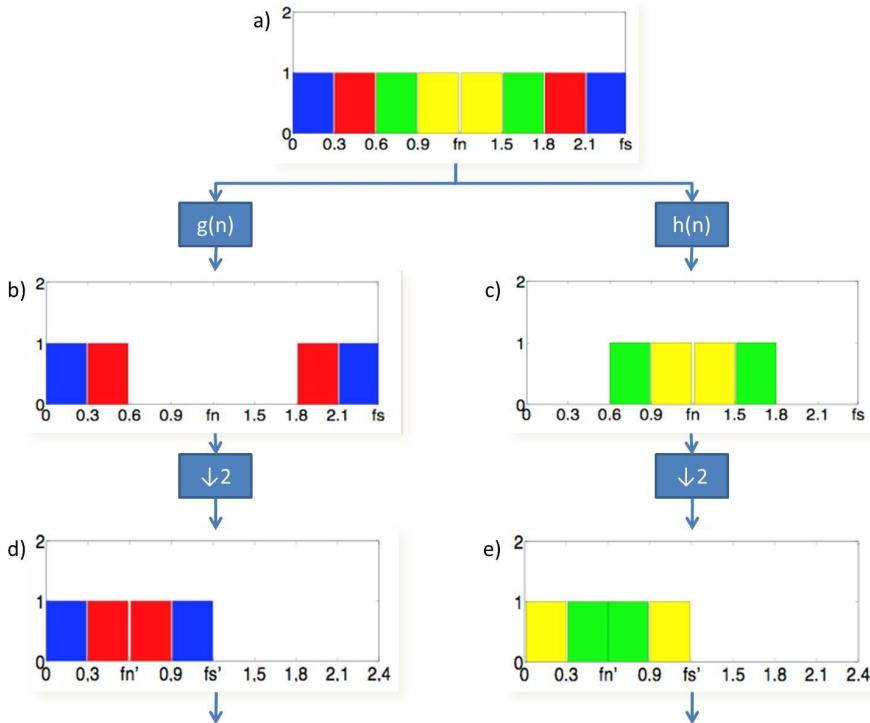


Abb. 2.9. Illustration der WPA im Frequenzbereich für eine Filterstufe. In a) ist das Spektrum eines zeitdiskreten Signals zu sehen, dass mit $f_A = 2.4$ Hz abgetastet wurde. Das Signal soll mit Hilfe der WPA in die farbig markierten Spektralanteile separiert werden. b) zeigt das Spektrum nach der Tiefpassfilterung. c) zeigt das Spektrum nach der Hochpassfilterung. In d) und e) sind die Spektren nach der Umsetzung der Abtastrate auf $f'_A = 1.2$ Hz zu sehen. In e) wird ersichtlich, wie das Spektrum aus dem Hochpassbereich in den Tiefpassbereich zwischen 0 Hz und 0.6 Hz abgebildet wird.

Für die Filterstruktur der WPA ergibt sich nun eine Baumstruktur, deren Knoten die Koeffizienten des entsprechenden Frequenzbereichs repräsentieren (Abb. 2.10). Tiefer liegende Knoten haben eine größere Skalierungsstufe k und somit eine feinere Frequenzauflösung, während die Zeitauflösung grober wird [Kiencke et al., 2008, S. 209-210]. Das zu einem Knoten gehörende Signal kann auch hier ganz analog zur DWT durch Erhöhung der Abtastrate und Filterung mit den gespiegelten Filtern rekonstruiert werden. Man erhält so bei der WPA mehr Flexibilität bei der Gestaltung einer Zeit-Frequenz-Darstellung, da die Auflösung im Zeit- und Frequenzbereich nun von der Wahl der verwendeten Knoten abhängt. Wählt man alle Knoten der gleichen Skalierungsstufe K , so erhält man für die Zeit-Frequenz-Darstellung 2^K Frequenzbänder mit der Frequenzauflösung $f_n 2^{-K}$. Daraus folgt für die Zeitauflösung entsprechend $t_A 2^K$. Ein Beispiel einer Zeit-Frequenz-Ebene für die Skalierungsstufe $K = 2$ ist in Abb. 2.11 zu sehen. Eine detaillierte Beschreibung der Gestaltungsmöglichkeiten der WPA findet sich in [Addison, 2002, Abschnitt 3.9].

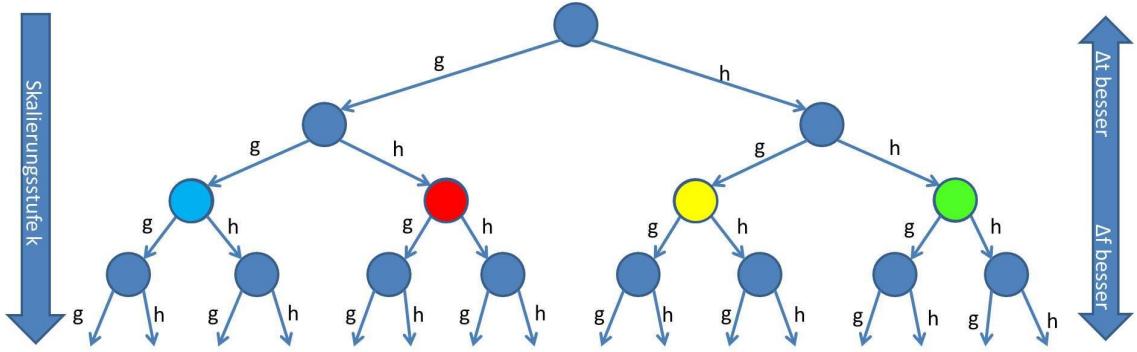


Abb. 2.10. Darstellung der WPA-Struktur in Form des WPA-Baums. Die Äste Stellen die Filterstufen inklusive der Reduzierung der Abtastrate dar. Jeder Knoten repräsentiert die entsprechenden Koeffizienten. Mit zunehmender Skalierungsstufe erhält man eine bessere Frequenzauflösung auf Kosten der Zeitauflösung. Die farbig markierten Knoten entsprechen den Signalanteilen aus Abb. 2.9.

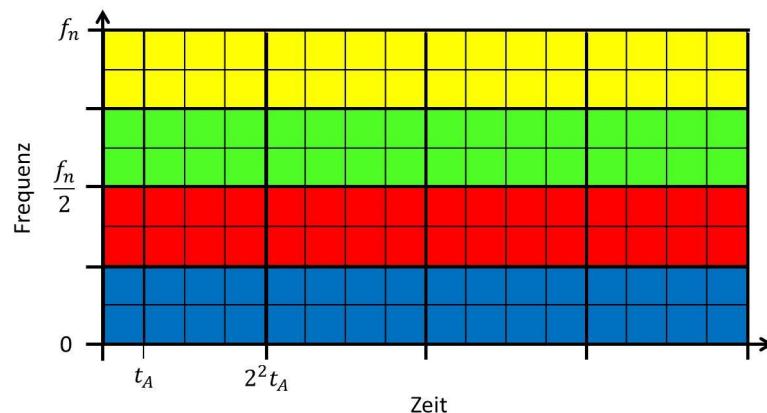


Abb. 2.11. Darstellung der Zeit-Frequenz-Ebene der WPA. Die farbig markierten Frequenzbänder entsprechen den farbig markierten Knoten des WPA-Baums aus Abb. 2.10 und den entsprechenden Signalanteilen aus Abb. 2.9. Für die Skalierungsstufe $K = 2$ erhält man eine Frequenzauflösung von $f_n \cdot 2^{-2}$ und eine Zeitauflösung von $t_A \cdot 2^2$.

2.2.11 Grundbegriffe der Statistik

Da in Kapitel 5 einige Features aus dem EKG und der RR-Zeitreihe mit Hilfe statistischer Größen berechnet werden, sollen hier die dafür notwendigen Grundbegriffe aus der Statistik zusammengefasst werden.

Wir gehen zunächst von einem Zufallsexperiment aus, in dem die Ereignisse ω auftreten können. Die Gesamtmenge aller möglichen Ereignisse sei mit Ω bezeichnet. Jedem Ereignis ω kann eine reelle Zahl zugeordnet werden. Die Abbildungsvorschrift

$$X : \Omega \mapsto \mathbb{R}, \omega \rightarrow X(\omega) \quad (2.60)$$

wird als Zufallsvariable bezeichnet. Mit Hilfe dieser Zufallsvariablen will man die Wahrscheinlichkeit angeben, mit der das Ereignis ω auftritt. Dazu benötigt man die Wahrscheinlichkeitsverteilung F_X der Zufallsvariablen X :

$$F_X(x) = P\{X(w) \leq x\} . \quad (2.61)$$

Die Wahrscheinlichkeitsverteilung gibt an, mit welcher Wahrscheinlichkeit die Zufallsvariable X einen Wert kleiner oder gleich x annimmt. Die Ableitung der Wahrscheinlichkeitsverteilung ist die Wahrscheinlichkeitsdichte:

$$f_X(x) = \frac{dF_X(x)}{dx} . \quad (2.62)$$

Kennt man die Wahrscheinlichkeitsdichte f_X der Zufallsvariablen X , so lässt sich die Wahrscheinlichkeit aus Gl. 2.61 berechnen:

$$P\{X(\omega) \leq x\} = \int_{-\infty}^x f_X(x) dx . \quad (2.63)$$

Dabei muss für die Wahrscheinlichkeitsdichte f_X gelten:

$$f_X(x) \geq 0 \quad \forall x \in \mathbb{R} \quad (2.64)$$

$$\int_{-\infty}^{\infty} f_X(x) dx = 1 . \quad (2.65)$$

Die Eigenschaften eines Zufallsexperiments werden mit Hilfe der Wahrscheinlichkeitsdichte berechnet. Dazu verwendet man die statistischen Momente:

$$E\{x^n\} = \int_{-\infty}^{\infty} x^n f_X(x) dx . \quad (2.66)$$

Dabei bezeichnet $E\{\cdot\}$ den Operator für die Erwartungswertbildung. Das erste statistische Moment mit $n = 1$ ist der Mittelwert oder der Schwerpunkt der Zufallsvariablen X und wird häufig mit μ_X bezeichnet. Neben den statistischen Momenten werden auch die zentralen Momente verwendet:

$$E\{(x - E\{x\})^n\} = \int_{-\infty}^{\infty} (x - E\{x\})^n f_X(x) dx . \quad (2.67)$$

Das zweite zentrale Moment mit $n = 2$ ist die Varianz der Zufallsvariablen X und stellt ein Maß für die Streuung von X dar. Die Varianz wird häufig mit σ_X^2 bezeichnet. Aus der Varianz lässt sich die Standardabweichung σ_X berechnen:

$$\sigma_X = \sqrt{\sigma_X^2} . \quad (2.68)$$

Das dritte zentrale Moment ist die Skewness ρ_X , wobei diese auf die Standardabweichung normiert wird:

$$\rho_X = \frac{E\{(x - E\{x\})^3\}}{\sigma_X^3} . \quad (2.69)$$

Die Skewness ρ_X ist ein Maß für die Symmetrie der Wahrscheinlichkeitsdichte f_X . Das vierte zentrale Moment κ_X ist die Kurtosis:

$$\kappa_X = \frac{E\{(x - E\{x\})^4\}}{\sigma_X^4} . \quad (2.70)$$

Die Kurtosis ist ein Maß für die Spitzigkeit von f_X und gibt ein Maß für die Abweichung von f_X von einer Normalverteilung an [Kiencke & Eger, 2008, S. 136-142].

Im Falle von Energiesignalen $x(t)$ können statistische Momente berechnet werden, um bestimmte Eigenschaften des Signals zu beschreiben. Dazu interpretiert man in Analogie zur Wahrscheinlichkeitsdichte das Signal $|x(t)|^2$ als Energiedichte und die Zeit t als Zufallsvariable. Als Wahrscheinlichkeitsdichte erhält man:

$$f_T(t) = \frac{|x(t)|^2}{\|x(t)\|^2} , \quad (2.71)$$

wobei mit der Normierung der Energiedichte auf die Gesamtenergie $\|x(t)\|^2$ die Bedingung aus Gl. 2.65 erfüllt wird. Die statistischen Momente berechnen sich nun nach Gl. 2.66 und Gl. 2.67. Beispielsweise ist

$$t_x = \int_{-\infty}^{\infty} t \cdot f_T(t) dt \quad (2.72)$$

die mittlere Zeit des Energiesignals $x(t)$. Die Standardabweichung ist in diesem Fall die Zeitspanne. Ganz analog dazu kann auch mit dem Spektrum $X(f)$ verfahren werden. In diesem Fall erhält man aus dem ersten Moment die mittlere Frequenz und aus der Standardabweichung die Bandbreite des Spektrums [Kiencke et al., 2008, S. 11].

Im Falle von Stichproben eines Zufallsexperiments können die statistischen Momente nur geschätzt werden. Zeitdiskrete Signale x_n mit endlicher Beobachtungszeit können ebenfalls als Stichprobe einer Zufallsvariablen angesehen werden. In diesem Fall ist die dazugehörige Wahrscheinlichkeitsdichte häufig unbekannt. Die Schätzungen der hier verwendeten Momente lauten [Kiencke & Eger, 2008, S. 146-151]:

$$\hat{\mu}_X = \frac{1}{N} \sum_{n=1}^N x_n \quad (2.73)$$

$$\hat{\sigma}_X^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \hat{\mu}_X)^2 \quad (2.74)$$

$$\hat{\rho}_X = \frac{1}{N} \cdot \frac{\sum_{n=1}^N (x_n - \hat{\mu}_X)^3}{\hat{\sigma}_X^3} \quad (2.75)$$

$$\hat{\kappa}_X = \frac{1}{N} \cdot \frac{\sum_{n=1}^N (x_n - \hat{\mu}_X)^4}{\hat{\sigma}_X^4} . \quad (2.76)$$

Die statistischen Momente sind oft anfällig für Ausreißer. Der Mittelwert einer Folge $x_n = (1, 2, 3, 2, 1000)$ ist nach Gl. 2.74 beispielsweise 201.6. Bei einer Folge, deren Zahlenwerte in der Regel zwischen 1 und 3 liegen, würde man unter 201.6 sicherlich keinen Mittelwert verstehen. Um im Falle häufiger Ausreißer robuste Eigenschaften der Stichprobe zu erhalten, können Lagemaße verwendet werden. Dazu werden die Werte der Stichprobe zunächst der Größe nach sortiert. Für die Beispieldfolge x_n erhält man die geordnete Folge $x_m = (1, 2, 2, 3, 1000)$. Als Pendant zum Mittelwert bestimmt man nun den Median. Der Median ist der mittlerste Wert der Stichprobe. Im Fall von x_m wäre der Median also 2. Verallgemeinert kann man nun Lagemaße Q_p mit $0 \leq p \leq 1$ bestimmten, für die $p \cdot N$ Werte kleiner als Q_p sind. p wird häufig in % angegeben. Für $p = 50\%$ erhält man wieder den Median. Die Werte Q_p werden als Quantile bezeichnet. Die Quantile Q_{25} und Q_{75} bezeichnet man als Quartile. Die Differenz $Q_{75} - Q_{25}$ wird als Interquartilsabstand bezeichnet und kann als Streumaß verstanden werden [Henze, 2008, S. 29-35].

3

State of the Art

Bei der Untersuchung der EKG-Signale unterscheidet man zwei große Bereiche. Bei der Analyse der Morphologie untersucht man die Kurvenform der in Abschnitt 2.1.3 beschriebenen EKG-Kurve. Für die Analyse von Herzrhythmen wird die RR-Zeitreihe aus dem EKG-Signal exktrahiert und analysiert. Die ständige Veränderung der RR-Intervalle wird als Herzratenvariabilität (HRV) bezeichnet. Die im folgenden Abschnitt aufgeführten Publikationen sollen die bisherigen Erkenntnisse der Auswirkungen von mentalem Stress auf die Morphologie und die HRV zusammenfassen.

Die Untersuchungen der Auswirkungen von mentalem Stress auf die Morphologie beschränken sich meist auf die Analyse der QT-Zeit und der ST-Strecke. Ginopoulos et al. untersuchten die Hypothese, dass mentaler Stress bei Patienten mit ischämischer Herzkrankheit ventrikuläre Herzrhythmusstörungen hervorrufen könnten. Diese könnten mit Hilfe der QT-Zeit und der QT-Dispersion analysiert werden. Die QT-Dispersion beschreibt dabei die Variation der QT-Intervalle. Für eine Mehrheit der Patienten konnte ein signifikanter Anstieg der QT-Dispersion während eines Stress-Tests festgestellt werden. Jedoch wurde angemerkt, dass die Auswertung der QT-Intervalle von starken Messfehlern beeinflusst sein könnte [Ginopoulos et al., 2003]. Gottdiener et al. untersuchten ebenfalls Patienten mit ischämischer Herzkrankheit. Sie führten sowohl Stress-Tests als auch physische Tests durch und analysierten die Änderungen der ST-Strecke. Der physische Test hatte dabei deutlich signifikantere Auswirkungen auf die ST-Strecke als der Stress-Test [Gottdiener et al., 1994]. Im Gegensatz dazu stellten Specchia et al. in einer ähnlichen Studie bei einigen Patienten eine Absenkung der ST-Strecke während des Stress-Tests fest. Aber auch hier war der Einfluss durch einen physischen Test deutlich stärker [Specchia et al., 1984].

Im Gegensatz zur Morphologie scheint die HRV-Analyse eindeutigere Ergebnisse zu liefern. Wie in Abschnitt 2.1.4 bereits erläutert wurde, wird die Herzrate und somit auch die RR-Zeitreihe durch den Einfluss von Sympathikus und Parasympathikus moduliert. Die HRV-Analyse gilt als nützliches Werkzeug um das Zusammenspiel von Sympathikus und Parasympathikus zu untersuchen. Da die HRV-Analyse für die Untersuchung zahlreicher physiologischer Prozesse verwendet wurde, wurden 1996 von Malik et al. einige Empfehlungen und Standards zur Messung und Interpretation der HRV zusammengestellt. Darin befinden sich auch einige häufig verwendete Parameter, die aus der RR-Zeitreihe berechnet werden [Malik et al., 1996]. Eine erweiterte Zusammenstellung dieser HRV-Parameter und der verwendeten Methoden zu deren Berechnung wurde von Rajendra Acharya et al. 2006 veröffentlicht [Rajendra Acharya et al., 2006]. Die in dieser Arbeit verwendeten Parameter werden im Anhang A kurz beschrieben. Man unterscheidet dabei Parame-

ter im Zeit- und Frequenzbereich. Im Zeitbereich beschreiben die statistischen Parameter $SDNN$, $SDANN$, $SDNN index$ die Variationen der RR-Intervalle. Die statistischen Parameter $rMSSD$, $SDSD$, $pNN20$ und $pNN50$ beschreiben dagegen die Variationen der Differenzen aufeinanderfolgender RR-Intervalle. Weitere geometrische Parameter werden aus anderen Darstellungsformen der RR-Zeitreihe, wie zum Beispiel dem Histogramm oder dem Poincaré-Plot, gewonnen. Die nichtlinearen Parameter versuchen die Irregularität und die Rauigkeit der RR-Zeitreihe zu beschreiben. Im Frequenzbereich werden Parameter aus der PSD der RR-Zeitreihe berechnet. Dabei steht TP für die gesamte in der RR-Reihe vorhandene Leistung. VLF steht für die Leistung im Frequenzbereich unterhalb 0.04 Hz. LF gibt die Leistung zwischen 0.04 Hz und 0.15 Hz und HF die Leistung zwischen 0.15 Hz und 0.4 Hz an. LFn und HFn sind auf $TP - VLF$ normierte Leistungen. Weiterhin wird noch das Verhältnis $\frac{LF}{HF}$ berechnet. Korrelationen mit Parametern aus dem Zeitbereich bestehen unter anderem zwischen TP und $SDNN$ sowie zwischen HF und $rMSSD$ [Malik et al., 1996], [Rajendra Acharya et al., 2006]. Viele Untersuchungen und theoretische Überlegungen führten zu der Annahme, dass die Frequenz-Parameter die Aktivitäten von Sympathikus und Parasympathikus am deutlichsten wiedergeben. HF korreliert demnach mit der parasympathischen Aktivität, während mit LF oft die Aktivität des Sympathikus in Verbindung gebracht wird. Jedoch wird mit ansteigender sympathischer Aktivität und der damit verbundenen Erhöhung der Herzrate ein deutslicher Rückgang von TP beobachtet, was sowohl HF als auch LF beeinflusst. Daher wird empfohlen LFn und HFn zu verwenden. Das Verhältnis $\frac{LF}{HF}$ ist daher ebenfalls ein sehr häufig verwendeteter Parameter zur Messung der Balance zwischen Sympathikus und Parasympathikus [Rajendra Acharya et al., 2006].

Mentaler Stress und erhöhte physische Anstrengungen werden mit einer erhöhten Aktivität des Sympathikus in Verbindung gebracht [Malik et al., 1996]. Die folgenden Publikationen versuchten dies nachzuweisen. Takeuchi et al. untersuchten tagesrhythmische Schwankungen der HRV an Wistar-Ratten. Diese wurden durch bestimmte Schallfrequenzen zusätzlich unter Stress gesetzt. Zur Messung der HRV wurde die doppeltlogarithmisch aufgetragene PSD durch eine Gerade approximiert und deren Steigung β bestimmt. Unter erhöhtem Stress wurde ein erhöhtes β festgestellt. β konnte auch den tagesrhythmischen Verlauf der HRV anzeigen. In den zusätzlich entnommenen Blutproben konnte ein signifikanter Anstieg an Adrenalin und Cortisol festgestellt werden. Sie interpretierten den Anstieg von β mit einer erhöhten Aktivität des Sympathikus. Jedoch schlugen sie für den Nachweis eine Bestimmung von LF und HF mit Hilfe der Wavelet-Transformation vor [Takeuchi et al., 2001]. Salahudin, Kim et al. führten einen Stroop-Test durch, da der Stroop-Test direkte Auswirkungen auf das vegetative Nervensystem habe. Beim Stroop-Test wird dem Probanden beispielsweise das Wort „blau“ in roter Farbe gezeigt. Der Proband hat die Aufgabe die Farbe des gezeigten Wortes richtig zu identifizieren. Dabei neigen die Probanden dazu, die Farbe des geschriebenen Wortes, im Beispiel „blau“, anstatt die angezeigte Farbe des Wortes, im Beispiel „rot“, zu nennen. Zur Auswertung verwendeten sie die oben aufgeführten HRV-Parameter. Die Frequenz-Parameter wurden mit der Welch-Methode bestimmt. Während LFn und $\frac{LF}{HF}$ signifikant stiegen, sanken alle anderen HRV-Parameter signifikant. Des Weiteren stellten sie fest, dass bereits Messungen von 50 Sekunden Dauer ausreichten, um signifikante Änderungen in $rMSSD$, $PNN50$, LFn , HF , HFn und $\frac{LF}{HF}$ zu erhalten [Salahuddin et al., 2007]. Kim et al. berechneten in einem weiteren Stroop-Test die relativen Abweichungen der HRV-Parameter von den HRV-Parametern der Normal-Sinus-Rhythm-Datenbank. $SDNN$, $rMSSD$, $PNN50$ und LF waren während der Ruhephase signifikant höher als während des Stroop-Tests [Kim

et al., 2008b]. Ferner versuchten sie mittels logistischer Regression ein Modell zur Messung von mentalem Stress zu finden. Die Probanden füllten nach dem Stroop-Test einen Fragebogen aus, aus dem ein Stress-Index ermittelt wurde. Auf Basis des Stress-Index wurden die Probanden in die Kategorien "niedriger Stress" und "hoher Stress" eingeteilt. Jedoch konnte das Modell nur 66 % der Probanden richtig klassifizieren [Kim et al., 2008a]. Wu et al. führten einen Stress-Test mit Hilfe von Videosequenzen durch. Den Probanden wurde für 5 Minuten ein Video mit beruhigenden Landschaftsbildern gezeigt. Anschließend sahen sie für weitere 5 Minuten ein Horror-Video. Als Referenz wurde eine 5 Minuten andauernde Ruhephase durchgeführt. Die PSD wurde sowohl mit der Welch-Methode als auch dem ARMA-Modell bestimmt. Während des Landschaftsvideos war ein Rückgang von LF_n und $\frac{LF}{HF}$ und ein Anstieg von HF_n zu beobachten. Für das Horror-Video konnte ein umgekehrtes Verhalten beobachtet werden [Wu et al., 2009].

Nach den hier aufgeführten Publikationen liefern die Frequenz-Parameter die größte Aussagekraft. Die Berechnung der Parameter wird jedoch immer noch diskutiert. Das Kernproblem der PSD bleibt die Stationarität. Bleiben die im Signal enthaltenen harmonischen Schwingungen während des Beobachtungszeitraums stationär, liefert die PSD verlässliche Ergebnisse. Dies ist jedoch bei der RR-Zeitreihe nicht der Fall. Darüber hinaus kann die PSD zeitabhängige Variationen während des Beobachtungsintervalls nicht lokalisieren. Dies kann zu fehlerhaften Interpretationen führen [Rajendra Acharya et al., 2006]. Um diese Probleme zu beheben, wurde nach Verfahren gesucht, die eine Zeit-Frequenz-Darstellung der RR-Zeitreihe liefern. Unter den zahlreichen Transformationen hierfür erfreut sich die DWT für die HRV-Analyse wachsender Beliebtheit. Pichot et al. führten einen Vergleich der DFT mit der DWT bei der Auswertung einer Studie durch. Bei ihrer Studie wurde den Probanden zu verschiedenen Zeitpunkten unterschiedliche Dosen an Atropin und Propranolol verabreicht. Atropin hemmt den Parasympathikus, während Propranolol den Sympathikus hemmt. Die DWT konnte die Veränderungen an Hand von $\frac{LF}{HF}$ zeitlich deutlich besser lokalisieren, als die für aufeinanderfolgende Zeitsegmente angewandte DFT. Unter Atropin erhöhte sich $\frac{LF}{HF}$, während dieses Verhältnis unter dem Einfluss von Propranolol sank [Pichot et al., 1999]. Gamero et al. verwendeten die DWT für die Klassifikation von kurzzeitig auftretender Ischämie. Zuvor wurde anhand von Veränderungen der ST-Strecke entschieden, ob Ischämie vorlag oder nicht. Da die ST-Strecke aber von sehr vielen Faktoren wie zum Beispiel einer Veränderung der Lageposition des Probanden beeinflusst werden kann, führte dies zu einer hohen Falsch-Positiv-Rate und somit einer niedrigen Spezifität. Durch die Anwendung der DWT zur Berechnung von LF und HF konnten zum einen Aussagen über den zeitlichen Verlauf der Ischämie getroffen werden und zum anderen die Spezifität auf 89.7 % gesteigert werden [Gamero et al., 2002]. Wiklund et al. verglichen die Unterschiede der Kurzzeit-Fourier-Transformation, der WPA und der Cosine-Packets bei der Anwendung auf RR-Zeitreihen. Demnach seien die WPA und die Cosine-Packets geeigneter Verfahren für die HRV-Analyse [Wiklund et al., 1997]. Für die Detektion von mentalem Stress wendeten Pani et al. die WPA an. In deren Forschung ging es um die Kooperation von Menschen und Robotern. Die Roboter sollten dabei in der Lage sein, den Stress-Level des Menschen zu erkennen. Mit Hilfe der DFT und der WPA wurden die Frequenzbänder von Sympathikus und Parasympathikus geschätzt und Features aus den Frequenzbändern generiert. Ein auf Fuzzy Logic basierender Klassifikator wurde dann auf Basis der Features angelernt. Der Klassifikator ermittelte einen Stress-Index. Allerdings führten zu große individuelle Variationen der Features zwischen den Probanden zu großen Problemen [Rani et al., 2002].

Es gibt zwar jede Menge Publikationen über die HRV-Analyse in der Schlafforschung, jedoch finden sich kaum Publikationen über die Auswirkungen von Sekundenschlaf-Episoden auf die HRV. Ein möglicherweise vergleichbares Phänomen ist jedoch das plötzliche Aufwachen aus dem Schlaf. Mantaras et al. analysierten dazu die HRV mit Hilfe einer Zeit-Frequenz-Transformation. Sie verwendeten die Born-Jordan-Verteilung und ermittelten daraus den zeitlichen Verlauf der Frequenz-Parameter LF , HF und $\frac{LF}{HF}$. Kurz nach dem Aufwachen konnte bei steigender Herzrate ein Anstieg von LF und $\frac{LF}{HF}$ beobachtet werden. HF veränderte sich statt dessen nur wenig. Da die Dauer der Aufwachphasen und die damit verbundenen Variationen der Frequenz-Parameter deutlich unterhalb von 30 Sekunden lagen, wurde angemerkt, dass eine Betrachtung der Frequenz-Parameter ohne Zeitabhängigkeit zu fehlerhaften Interpretationen führen würde [Mantaras et al., 2006].

4

Studien und Daten

4.1 Mental-Stress-Test

Für die Untersuchung der Auswirkungen von mentalem Stress auf das EKG wurde am Institut für Arbeitswissenschaft und Betriebsorganisation (IFAB) des KIT ein Versuch durchgeführt. Dazu wurde am IFAB ein Fahrsimulator aufgebaut. Der Fahrsimulator bestand aus einem Lenkrad, einem Fahrpedal und einer Leinwand zur Anzeige der Fahrbahn (Abb. 4.1). Die Strecke bestand aus langen Geraden mit 3 Fahrspuren. Am Fahrbahnrand standen in gleichmäßigen Abständen Schilder, die anzeigen, auf welche Spur der Fahrer wechseln sollte. Am Ende jeder Geraden befand sich eine 180° -Kurve, die jedoch keine Schilder enthielt. Die Fahrgeschwindigkeit wurde während des gesamten Versuchs konstant auf 60 km/h gehalten.

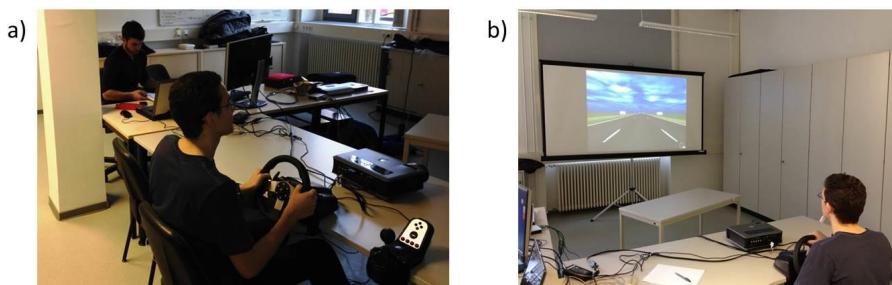


Abb. 4.1. Fahrsimulator des Mental-Stress-Tests. In a) ist ein Proband mit dem Lenkrad zu sehen. b) zeigt die Leinwand, auf der die zu befahrende Straße angezeigt wird.

Am Versuch nahmen 14 Probanden, überwiegend Studenten des KIT, teil. Von jedem Probanden wurden während des Versuchs mit einem mobilen EKG-Gerät die EKG-Signale aus 3 Ableitungen mit einer Abtastrate von 1 kHz aufgezeichnet. In einer ersten Trainingsphase wurde der Proband mit dem Fahrsimulator vertraut gemacht. Es folgte eine 15 Minuten andauernde Ruhephase. Dazu setzten sich die Probanden alleine auf einen Stuhl in einem Nachbarraum und betrachteten landschaftliche Bilder aus einem Buch. Nach der Ruhephase folgte der eigentliche Stress-Test. Der Stress-Test bestand aus der Fahrsimulation und einer mentalen Aufgabe. Bei der Fahrsimulation mussten die Probanden bei jedem Schild die Spur entsprechend wechseln. Der Spurwechsel sollte dazu möglichst schnell durchgeführt werden. Außerdem sollte darauf geachtet werden, möglichst gerade innerhalb der Spur zu bleiben. Bei einer Geschwindigkeit von etwa 60 km/h

betrug der zeitliche Abstand zwischen den Schildern etwa 8.7 Sekunden (Abb. 4.2, a)). Zur gleichen Zeit wurde den Probanden von einer aufgenommenen Stimme Zahlen zwischen 0 und 9 gesagt, die von den Probanden wiederholt werden mussten. Die Zahlen wurden in einem Abstand von etwa 3.7 Sekunden während der Fahrt auf den Geraden gesagt. Während der Kurven wurden keine weiteren Zahlen genannt. Der Stress-Test bestand dabei aus 3 verschiedenen Phasen. Jede Phase dauerte in etwa 6 Minuten. Während die Fahrsimulation in jeder Phase identisch war, wurde die Schwierigkeit der mentalen Aufgabe sukzessive erhöht. In Phase 1, im Folgenden mit Stress-Level 1 bezeichnet, musste die Zahl direkt wiederholt werden. In Phase 2, im Folgenden mit Stress-Level 2 bezeichnet, mussten die Probanden sich die aktuell genannte Zahl merken und die zuvor genannte Zahl wiederholen. Entsprechend mussten sich die Probanden in Phase 3, im Folgenden mit Stress-Level 3 bezeichnet, die aktuelle und davor genannte Zahl merken und die vorletzte Zahl wiederholen (Abb. 4.2, b)). Die Probanden wurden gebeten, den Versuch bei Fehlern direkt fortzusetzen. Zwischen den 3 Stress-Levels gab es jeweils eine Pause um einen Fragebogen zur Bewertung der psychischen und physischen Belastung durch den Test auszufüllen. Im Anschluss an Stress-Level 3 wurde erneut eine Ruhephase von 10 Minuten durchgeführt. Die Versuchsdaten sind in Tab. 4.1 nochmal zusammengefasst.

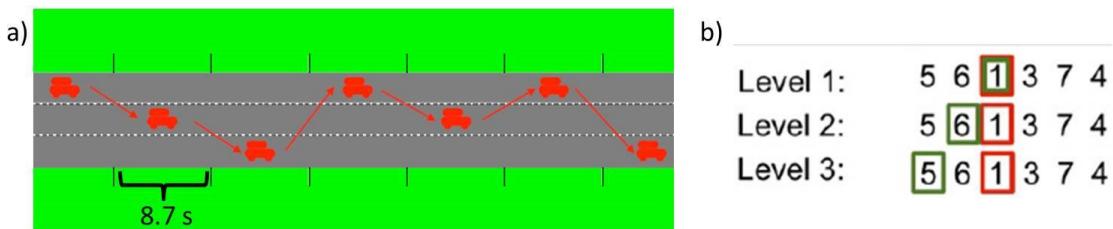


Abb. 4.2. Darstellung des Mental-Stress-Tests. a) zeigt die Fahrsimulation mit regelmäßigen Spurwechseln bei jedem Schild. In b) ist die mentale Aufgabe mit den 3 verschiedenen Schwierigkeitsstufen dargestellt. Die rot umrandete Zahl ist die aktuell genannte Zahl. Die grün umrandete Zahl muss vom Probanden wiederholt werden.

Geschwindigkeit	60 km/h
Zeit zwischen den Spurwechseln	8.7 s
Zeit zwischen den genannten Zahlen	3.7 s
Dauer der ersten Ruhephase	15 min.
Dauer der 3 Test-Phasen	je 6 min.
Dauer der zweiten Ruhephase	10 min.

Tabelle 4.1. Zusammenfassung der Versuchsdaten zum Mental-Stress-Test.

Zur Verarbeitung und Auswertung der EKG-Signale wurden aus den Ruhe- und Stressphasen jeweils Segmente extrahiert. Da die Stressphasen jeweils etwa 6 Minuten dauerten, wurden aus den Ruhephasen ebenfalls Segmente von 6 Minuten Dauer extrahiert. Die Definition der Segmente ist in Abb. 4.3 schematisch dargestellt. Für jedes dieser Segmente wurden Features mit den in Kapitel 5 genannten Methoden generiert.

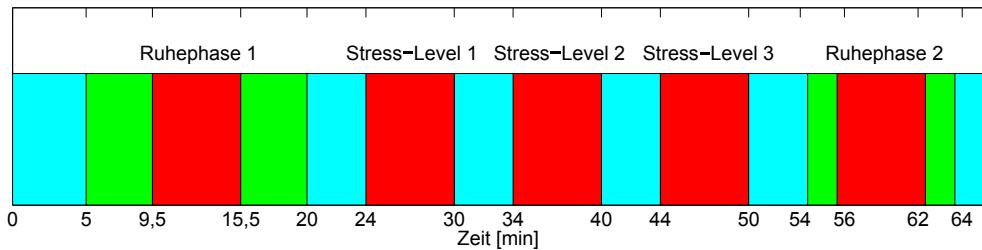


Abb. 4.3. Zeitlicher Ablauf des Mental-Stress-Tests. In rot sind die Zeitsegmente markiert, für welche Features berechnet wurden.

4.2 MSE-Experiment

An der Hochschule für angewandte Wissenschaften in Schmalkalden wird das Auftreten von Mikroschlaf-Episoden (MSE) umfassend untersucht. Dazu wurde im Labor ein Fahrsimulator aufgebaut (Abb. 4.4). Der Fahrsimulator wurde dabei so ausgelegt, dass die Müdigkeit des Probanden während des Versuchs stetig gesteigert wird. Die mit fortschreitender Dauer der Fahrsimulation anwachsende Müdigkeit sollte das Auftreten von MSEs provozieren. Beim Fahrsimulator wurde besonderer Wert auf einen monotonen Straßenverlauf gelegt. Es handelte sich um eine zweispurige Straße mit wenigen Kurven in einer monotonen landschaftlichen Umgebung. Die Verkehrsdichte wurde sehr gering gehalten. Auf der eigenen Fahrspur gab es keine weiteren Fahrzeuge. Auf der Gegenspur fuhr nur jeweils ein Fahrzeug im Abstand von etwa 3 Minuten. Die Probanden wurden angewiesen, die Spur möglichst gut zu halten. Zudem sollten sie es möglichst vermeiden, während der Fahrt einzuschlafen.



Abb. 4.4. Fahrsimulator des MSE-Experiments. In der Darstellung ist das abgedunkelte Labor, das Fahrzeug und die monotone Straße zu sehen.

An dem Versuch nahmen insgesamt 14 Probanden teil. 2 Probanden absolvierten 7 Durchläufe mit einer Dauer von etwa 40 Minuten. Die anderen Probanden absolvierten 5 Durchläufe mit einer Dauer von etwa 35 Minuten. Zwischen den einzelnen Durchläufen wurde ein Wachsamkeitstest durchgeführt und ein Fragebogen ausgefüllt. Die Durchläufe fanden zwischen 0 Uhr und 8 Uhr morgens statt. Jeder Proband hatte bereits vor dem Versuch einen einstündigen Trainingsdurchlauf am Fahrsimulator absolviert. Um die Müdigkeit zu steigern, durften die Probanden in den letzten 16 Stunden vor dem Versuch nicht mehr schlafen (Abb. 4.5).

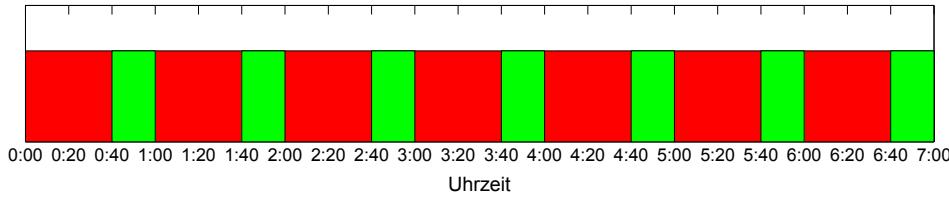


Abb. 4.5. Zeitlicher Ablauf des MSE-Experiments. In rot sind die Zeitabschnitte der Fahrsimulation gekennzeichnet. Die Pausen sind in grün eingezzeichnet.

Zur Messung der MSEs wurden sehr viele verschiedene Signale erfasst. Unter den Bio-signalen befanden sich die Elektroenzephalographie (EEG), die Elektrookulographie (EOG), das EKG und die Elektromyographie (EMG). Mit Hilfe eines Eye-Tracking-Systems wurde die Pupillengröße und der Blickwinkel der Augen vermessen. Aus dem Fahrverhalten während des Versuchs wurden unter anderem die Lenkbewegungen sowie die laterale Position des Fahrzeugs relativ zur Fahrbahn registriert. Zusätzlich wurde das Verhalten der Probanden über Videokameras beobachtet. Über längere Zeit geschlossene Augenlider, langsam absinkende Kopfbewegungen und ein Verlassen der Fahrspur wurden von Beobachtern während des Versuchs als MSE bewertet. Häufig folgten auf MSEs plötzliche Bewegungen der Probanden. Alle Signale sowie die Videoaufnahmen wurden im Anschluss an den Versuch erneut durch einen Experten betrachtet um zu bewerten, zu welchem Zeitpunkt ein MSE stattfand und zu welchem Zeitpunkt kein MSE stattfand. Golz et al. entwickelten bereits zuvor auf der Basis solcher gelabelten Daten einen MSE-Detektor. Dabei wurden aus den EEG- und EOG-Signalen Segmente von 6 Sekunden während eines MSEs exktrahiert. Die gleiche Anzahl an Segmenten wurde extrahiert, die keine MSEs enthielten. Aus jedem Segment wurden anschließend verschiedene Features generiert. Mit Hilfe dieser Features und der gelabelten Daten wurde eine Support Vector Machine (SVM) trainiert. Die SVM wurde damit in die Lage versetzt, die Segmente in "MSE" oder "kein MSE" zu klassifizieren. Auf Grund der hohen Anzahl der Features wurden die Parameter des MSE-Detektors über mehrere Durchläufe iterativ optimiert. Die Dauer der MSEs lag zwischen 4 und 12 Sekunden. Im Mittel dauerten die MSEs 9 Sekunden. Eine detaillierte Beschreibung des MSE-Detektors findet sich in [Golz et al., 2011]. Weitere Erläuterungen zum Experiment und zur Definition von MSEs können unter anderem in [Golz et al., 2007] nachgelesen werden.

Für die Auswertung des Versuchs wurden uns die EKG-Signale der 14 Probanden sowie die Zeitpunkte der aufgetretenen MSEs zur Verfügung gestellt. Die EKG-Signale wurden mit einer Abtastrate von 256 Hz abgetastet. Zusätzlich zu den MSE-Zeitpunkten wurde noch eine Stärke der MSEs auf einer Skala von 1 bis 6 angegeben. Ein Beispiel eines EKG-Signals mit markierten MSEs ist in Abb. 4.6 zu sehen. Für jedes MSE wurde ein Segment vor dem MSE und ein Segment nach dem MSE extrahiert. Die Dauer der Segmente betrug in einem ersten Ansatz 2 Minuten und in einem zweiten Ansatz 30 Sekunden. Als Referenz wurden in den ersten 20 Minuten des ersten Durchlaufs Segmente extrahiert, die keine MSEs enthielten. Die Definition der Segmente ist in Abb. 4.7 schematisch dargestellt. Für jedes der Segmente wurden mit den in Kapitel 5 genannten Methoden Features generiert.

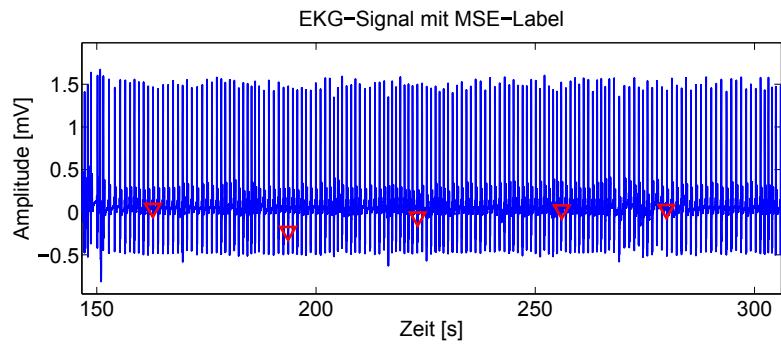


Abb. 4.6. Beispiel eines EKG-Signals mit den Zeitpunkten der MSEs (rote Markierungen).

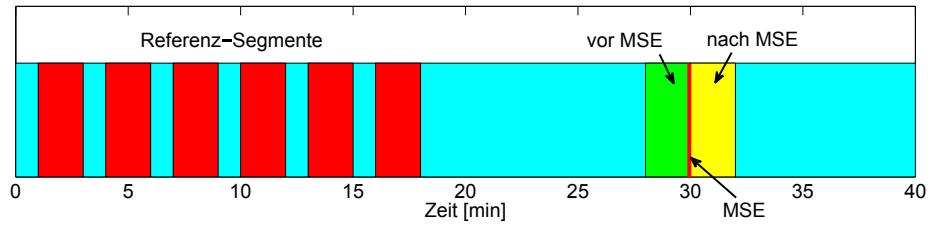


Abb. 4.7. Definition der extrahierten Zeitsegmente. In rot sind die Referenz-Segmente des ersten Durchlaufs markiert. Ein MSE und die dazu gehörenden Zeitsegmente sind beispielhaft eingetragen.

5

Feature-Generierung

Im folgenden Kapitel wird die Generierung der Features aus den EKG-Signalen vorgestellt. Zunächst wird die Prozessierung der EKG-Signale kurz erläutert. Anschließend wird auf die Generierung der Morphologie-Features eingegangen. Im letzten Abschnitt werden die Methoden der HRV-Analyse vorgestellt. Die Features werden dabei für jedes der in Kapitel 4 definierten Segmente bestimmt.

5.1 Prozessierung der EKG-Signale

Sowohl für die Untersuchung der Morphologie als auch für die HRV-Analyse müssen die in Abschnitt 2.1.3 beschriebenen Segmente der EKG-Kurve detektiert werden. Die hierfür notwendigen Methoden wurden bereits zuvor am IBT entwickelt und sollen hier nur kurz erwähnt werden. In Abb. 5.1 sind die einzelnen Prozessschritte stark vereinfacht dargestellt. Zunächst wird der QRS-Komplex detektiert. Der wichtigste Punkt daraus ist die Spitze der R-Zacke R_{peak} . Einerseits wird R_{peak} in der Morphologie häufig als Referenz verwendet. Andererseits liefern die Differenzen der adjazenten R_{peaks} die RR-Zeitreihe für die HRV-Analyse. Weiterhin wird die Spitze der Q-Zacke Q als auch die Spitze der S-Zacke S detektiert. Die gefundenen Zeitpunkte Q, R_{peak} und S werden in der Fiducial Point Table (FPT) abgelegt. Als nächstes wird die T-Welle detektiert. Da die T-Welle gewisse Ähnlichkeiten zum QRS-Komplex aufweist und dessen Amplitude unter Umständen in der Nähe der Amplitude der R-Zacke liegen kann, wird bei der T-Wellen-Detektion der QRS-Komplex zunächst entfernt und durch eine Sigmoidfunktion ersetzt. Bei der T-Wellen-Detektion wird ein Startpunkt T_{on} , der Endpunkt T_{off} und das Maximum der T-Welle T_{peak} detektiert. Auch diese werden in der FPT abgelegt. Als letztes folgt die Detektion der P-Welle. Bevor die P-Welle detektiert werden kann, werden der QRS-Komplex und die T-Welle entfernt und durch eine Sigmoidfunktion ersetzt. Es werden P_{on} , P_{off} und P_{peak} detektiert und in der FPT abgelegt [Pilia, 2013]. Werden die EKG-Signale mehrerer Ableitungen verwendet, so wird für jede Ableitung eine FPT generiert. Zudem wird in diesem Fall in einem weiteren Schritt eine synchronisierte FPT erstellt. Ein Beispiel eines EKG-Signals mit den automatisch detektierten Zeitpunkten ist in Abb. 5.2 zu sehen.

Der nächste Schritt ist die Klassifikation des QRS-Komplexes. Aus dem QRS-Komplex werden insgesamt 55 Features generiert. Eine ebenfalls am IBT entwickelte SVM entscheidet auf Basis der Features, ob es sich bei dem QRS-Komplex um eine normale Systole handelt oder eine Extrasystole vorliegt [Lenis, 2010]. Extrasystolen sollen in der späteren Untersuchung der Morphologie nicht berücksichtigt werden. Zudem werden bei der

Extraktion der RR-Zeitreihe nur die R_{peaks} aus normalen Systolen verwendet. Der Klassifizierungsprozess wird ebenfalls für alle verwendeten Ableitungen durchgeführt. In der synchronisierten FPT wird dann über ein Abstimmungsverfahren entschieden zu welcher Klasse der QRS-Komplex angehört. Für die Untersuchung der Morphologie werden die zu jeder Ableitung gehörenden FPTs verwendet. Die RR-Zeitreihe wird mit Hilfe der synchronisierten FPT generiert.

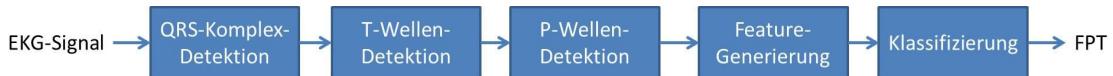


Abb. 5.1. Vereinfachte Darstellung der Prozessierung des EKG-Signals im Falle einer einzelnen Ableitung.

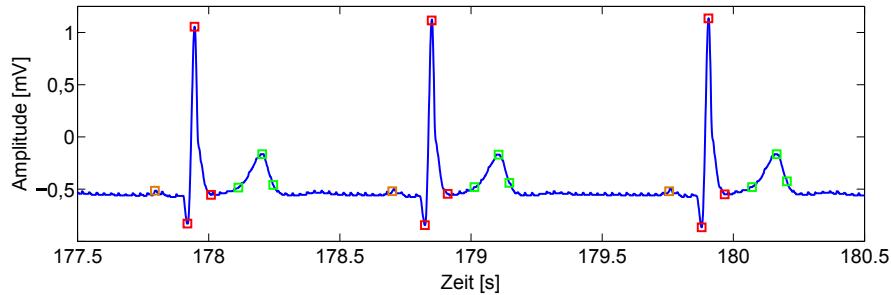


Abb. 5.2. Ein Beispiel eines ungefilterten EKG-Signals nach der Detektion der P-Wellen (orange markiert), der QRS-Komplexe (rot markiert) und der T-Wellen (grün markiert).

5.2 Untersuchung der Morphologie

Für die Untersuchung der Morphologie werden das EKG-Signal, die FPT sowie die in Kapitel 4 definierten Zeitsegmente verwendet. Das zu untersuchende Zeitsegment wird zunächst aus dem gesamten EKG-Signal extrahiert. Aus der FPT werden nur diejenigen Herzschläge verwendet, die vollständig innerhalb des Zeitsegments liegen.

Als nächster Schritt folgt eine Filterung des EKG-Signals. Das EKG-Signal ist mit einer Reihe von Störsignalen behaftet. Unter den hochfrequenten Anteilen befindet sich hauptsächlich Rauschen. Unter den niederfrequenten Anteilen befindet sich die Modulation der isoelektrischen Linie durch die Atmung, was als Baseline-Wander bezeichnet wird, sowie ein Offset. Einerseits soll das Filter diese Störsignale unterdrücken. Andererseits soll die Morphologie der EKG-Kurve nicht zu stark beeinflusst werden. Als Filter wurde ein Gaußfilter verwendet. Das Filter besteht aus einem Tiefpass- und einem Hochpassfilter. Für die P-Welle, die T-Welle und die ST-Strecke wurde für das Tiefpassfilter eine Grenzfrequenz von 0.3 Hz und für das Hochpassfilter eine Grenzfrequenz von 20 Hz gewählt. Beim QRS-Komplex wurde für das Tiefpassfilter eine Grenzfrequenz von 0.5 Hz und für das Hochpassfilter eine Grenzfrequenz von 40 Hz gewählt. In Abb. 5.3 sieht man das ungefilterte EKG-Signal (blau) sowie die gefilterten EKG-Signale (rot und grün). Vergleicht man die gefilterten Signale miteinander, so sieht man am QRS-Komplex, dass durch die hohe Grenzfrequenz des Tiefpassfilters die Q-Zacke und die R-Zacke besser erhalten werden konnten. Für die P-Welle, die T-Welle und die ST-Strecke wurde dagegen

das Rauschen stärker unterdrückt. Da das Hochpassfilter bei diesen Segmenten jedoch bereits wichtige Spektralanteile dämpft, wurde eine niedrigere Grenzfrequenz gewählt, was zu einem höheren Einfluss des Baseline-Wanders führt.

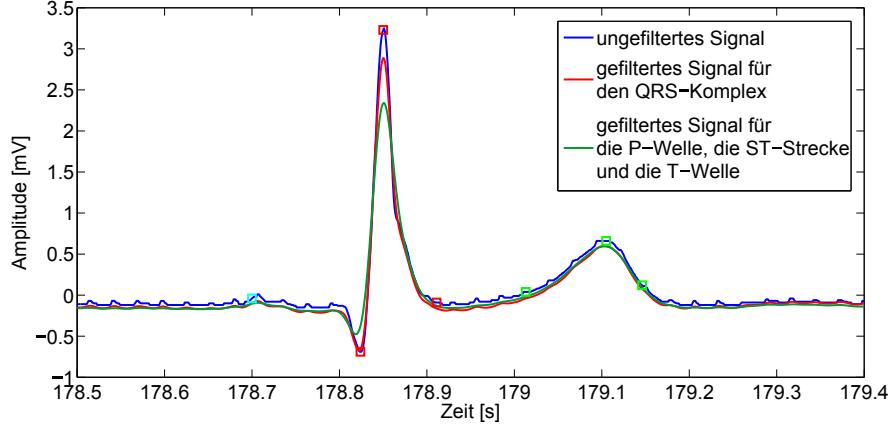


Abb. 5.3. Vergleich des ungefilterten EKG-Signals und der beiden gefilterten EKG-Signale für die Untersuchung der Morphologie. In rot ist das gefilterte EKG-Signal für den QRS-Komplex zu sehen. In grün ist das gefilterte EKG-Signal für die P-Welle, die ST-Strecke und die T-Welle dargestellt.

Aus den gefilterten Signalen können nun die Features der P-Welle, des QRS-Komplexes, der ST-Strecke und der T-Welle jedes Herzschlags generiert werden. Für jedes Feature $f_i(j)$ wird anschließend der Mittelwert gebildet:

$$\bar{f}_i = \frac{1}{N} \sum_{j=1}^N f_i(j) . \quad (5.1)$$

Dabei wird mit j der j . Herzschlag aus dem betrachteten Zeitsegment indiziert. N ist die Anzahl der betrachteten Herzschläge. Die verschiedenen Features werden mit i indiziert. Bei der Mittelwertbildung werden Extrasystolen nicht berücksichtigt. Um mögliche Randeffekte zu Beginn und am Ende des Signalausschnitts zu vermeiden, werden die Features des ersten und letzten Herzschlags eines Zeitsegments ebenfalls bei der Mittelwertbildung nicht berücksichtigt.

5.2.1 Template-Bildung

Für jeden Abschnitt der EKG-Kurve wird ein mittlerer Kurvenverlauf gebildet, der als Template bezeichnet wird. Das Template dient der robusten Detektion morphologischer Veränderungen. Der Algorithmus zur Bildung des Templates wurde bereits bei der Klassifizierung der QRS-Komplexe verwendet und wurde für die Anwendung auf die in dieser Arbeit verwendeten EKG-Signale angepasst. Der Algorithmus soll hier kurz anhand der QRS-Komplexe erläutert werden.

Wir gehen zunächst von der Menge B aus, die alle im betrachteten Zeitsegment enthaltenen QRS-Komplexe $b(j)$ enthält. Es wird eine Untermenge $M \subset B$ gesucht, die diejenigen QRS-Komplexe enthält, welche zur Bildung des Templates verwendet werden. Die Suche nach M erfolgt in 3 Stufen, die Abb. 5.4 schematisch dargestellt ist.

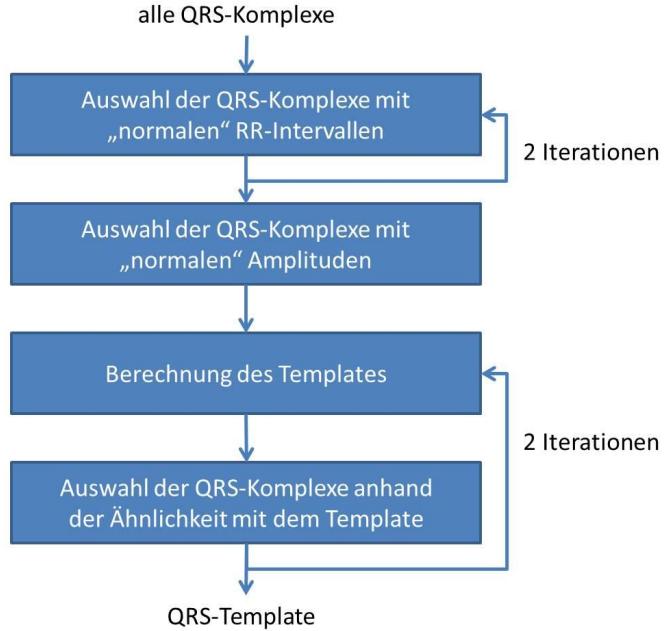


Abb. 5.4. Schematische Darstellung der Auswahlstufen zur Generierung eines Templates am Beispiel des QRS-Komplexes.

In einer ersten Stufe werden diejenigen Herzschläge gesucht, welche zum “normalen” Herzerhythmus gehören. Dazu wird aus dem EKG-Signal die RR-Zeitreihe generiert. Aus der RR-Zeitreihe wird das Poincaré-Plot erstellt, indem die aufeinanderfolgenden RR-Intervalle $RR(j)$ und $RR(j + 1)$ als Punkte eingetragen werden (Abb. 5.5). Diejenigen Punkte, die sich in der Umgebung U des Punktes $\overline{RR}, \overline{RR}$ befinden, werden als “normal” angesehen. \overline{RR} ist dabei das mittlere RR-Intervall. U ist ebenfalls in Abb. 5.5 eingezeichnet und wird durch die Abstände

$$d_1 = 2.5 \cdot \sigma_1 \quad (5.2)$$

$$d_2 = 0.7 \cdot \sigma_2 \quad (5.3)$$

von $\overline{RR}, \overline{RR}$ bestimmt. σ_1 ist der mittlere Abstand von $[RR(j), RR(j + 1)]$ von der Geraden $y = x$. σ_2 ist der mittlere Abstand von $[RR(j), RR(j + 1)]$ von der Geraden $y = -x + 2 \cdot \overline{RR}$. Ist $[RR(j), RR(j + 1)]$ innerhalb von U , so gilt $b(j) \in M_1$. $M_1 \subset B$ enthält nun alle QRS-Komplexe, die zu einem “normalen” RR-Intervall gehören. Das Verfahren wird anschließend für alle $b(j) \in M_1$ wiederholt.

In der zweiten Stufe werden die Minima und Maxima der QRS-Komplexe $b(j) \in M_1$ betrachtet. Dazu werden für alle $b(j) \in M_1$ die Quantile $Q_{25,min}$ und $Q_{75,min}$ für die Minima und $Q_{25,max}$ und $Q_{75,max}$ für die Maxima bestimmt. $b(j)$ ist genau dann Element von $M \subset M_1$, wenn gilt:

$$Q_{25,min} \leq \min\{b(j)\} \leq Q_{75,min} \quad (5.4)$$

$$Q_{25,max} \leq \max\{b(j)\} \leq Q_{75,max}. \quad (5.5)$$

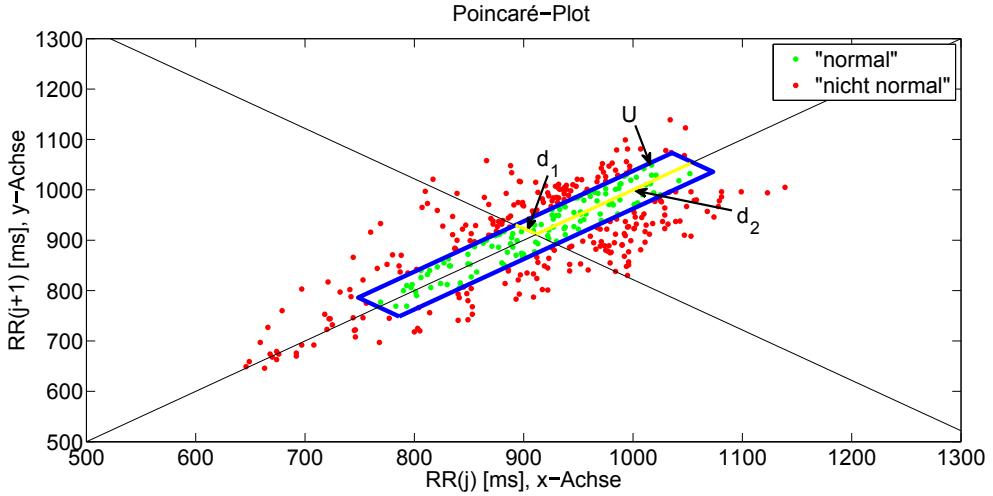


Abb. 5.5. Visualisierung der ersten Auswahlstufe für die Template-Bildung. Zu sehen ist das Poincaré-Plot mit der gefundenen Umgebung U . Die zu den grün eingezeichneten Punkten gehörenden QRS-Komplexe werden ausgewählt.

Im Anschluss wird das Template $\text{temp}(n)$ gebildet, wobei n die Abtastpunkte des QRS-Komplexes indiziert:

$$\text{temp}(n) = \frac{1}{|M|} \sum_{\forall b(j) \in M} b(j, n) . \quad (5.6)$$

$|M|$ ist hierbei die Mächtigkeit von M .

In der dritten Stufe wird für alle $b(j) \in M_1$ ein Maß $e(j)$ für die Abweichung von $b(j, n)$ vom Template $\text{temp}(n)$ berechnet:

$$e(j) = \frac{\sum_{n=1}^N [b(j, n) - \text{temp}(n)]^2}{\sum_{n=1}^N \text{temp}^2(n)} . \quad (5.7)$$

Für alle $e(j)$ wird das Quantil $Q_{85,e}$ bestimmt. M wird nun aktualisiert: $b(j) \in M_1$ wird Element von M , wenn gilt:

$$e(j) \leq Q_{85,e} . \quad (5.8)$$

Für alle $b(j) \in M$ wird erneut nach Gl. 5.6 ein Template berechnet. Die dritte Stufe wird einmal wiederholt. Zum Schluss wird das Template noch auf sein Maximum normiert.

Für den Stress-Test wurde für die erste Ruhephase ein Template erstellt. Für das MSE-Experiment wurde ein Template aus allen Referenzphasen generiert. Aus dem Template werden ebenfalls entsprechende Features f_i^t generiert. Mit Hilfe des Templates werden die Features $f_i(j)$ normiert. Dabei wird zunächst die Abweichung $\delta f_i(j)$ des Features $f_i(j)$ vom Template-Feature f_i^t berechnet:

$$\delta f_i(j) = f_i(j) - f_i^t . \quad (5.9)$$

Anschließend wird ein normiertes Feature $f_i^{norm}(j)$ berechnet:

$$f_i^{norm}(j) = \frac{\delta f_i(j) - \mu_i}{\sigma_i} . \quad (5.10)$$

μ_i ist die mittlere Abweichung aller $\delta f_i(j)$ mit $b(j) \in M$ und σ_i die entsprechende Standardabweichung dazu. Zwischen den einzelnen Zeitsegmenten werden so nur Änderungen gegenüber dem Template aus den Referenzphasen betrachtet. Der Vorteil dieser Vorgehensweise liegt darin, dass der Einfluss durch die Verwendung unterschiedlicher EKG-Geräte, eine Änderung der Abtastrate, ungenaue Positionierung der Elektroden und individuelle, körperliche Unterschiede der Probanden auf die Morphologie-Features so reduziert werden kann.

5.2.2 QRS-Komplex

Die Methode zur Generierung der Features des QRS-Komplexes ist eine adaptierte Variante der Methode, welche die Features für die Klassifizierung der QRS-Komplexe generiert [Lenis et al., 2012]. Alle QRS-Komplexe des aktuellen Zeitsegments werden zunächst extrahiert. Dabei werden alle Abtastwerte innerhalb des Fensters $[R_{peak} - 100\text{ ms}, R_{peak} + 100\text{ ms}]$ extrahiert. Aus den QRS-Komplexen wird dann das Template gebildet. Ein Beispiel dazu ist in Abb. 5.6 zu sehen. Man erkennt deutlich, dass der Einfluss des Baseline-Wanders durch die Filterung stark reduziert wurde. Zur Berechnung der Features hat es sich als vorteilhaft erwiesen, das Template in Richtung y-Achse so zu verschieben, dass die isoelektrische Linie vor dem QRS-Komplex tatsächlich auf der 0-Linie liegt. Daher wird aus den ersten 20 ms des extrahierten Abschnitts der Offset berechnet und sowohl das Template als auch die einzelnen QRS-Komplexe entsprechend verschoben.

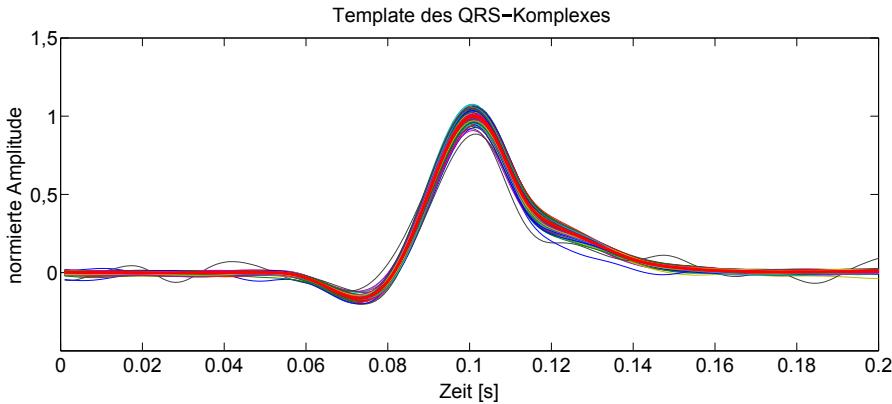


Abb. 5.6. Darstellung der extrahierten QRS-Komplexe inklusive dem daraus gebildeten Template.

Die Auflistung aller gebildeten Features würde an dieser Stelle den Rahmen sprengen. Daher seien hier nur die verschiedenen Kategorien der Features aufgezählt. Es werden Features gebildet, die die Amplitude der QRS-Komplexe beschreiben sollen. Darunter befinden sich die Minima und Maxima der QRS-Komplexe sowie die Minima und Maxima der ersten und zweiten Ableitungen, verschiedene Integrale der QRS-Komplexe wie zum Beispiel die Energie der QRS-Komplexe sowie verschiedene statistische Momente der

Amplitudenverteilung. Weitere Features sind verschiedene statistische Momente aus der als Wahrscheinlichkeitsdichte betrachteten QRS-Komplexe. Aus der Korrelation der QRS-Komplexe mit dem Template werden ebenfalls Features gewonnen. Zusätzliche Features werden aus der DFT der QRS-Komplexe sowie der Approximation der QRS-Komplexe mit Hilfe der Hermiteschen Basisfunktionen gewonnen. Genaue Beschreibungen der Features finden sich in [Lenis et al., 2012] und [Menges, 2013]. Eine Auflistung der Features befindet sich im Anhang B.

5.2.3 T-Welle

Das Fenster zur Extraktion der T-Wellen wird durch $[T_{peak} - 150\text{ ms}, T_{peak} + 200\text{ ms}]$ definiert. Ähnlich wie beim QRS-Komplex werden hieraus die letzten 50 ms genutzt, um den Offset der isoelektrischen Linie zu berechnen und die T-Wellen entsprechend zu verschieben. Die T-Wellen und das Template sind in Abb. 5.7 zu sehen. Im Gegensatz zum QRS-Komplex erkennt man deutlich den größeren Einfluss durch Baseline-Wander und eine größere Variabilität der Amplitude.

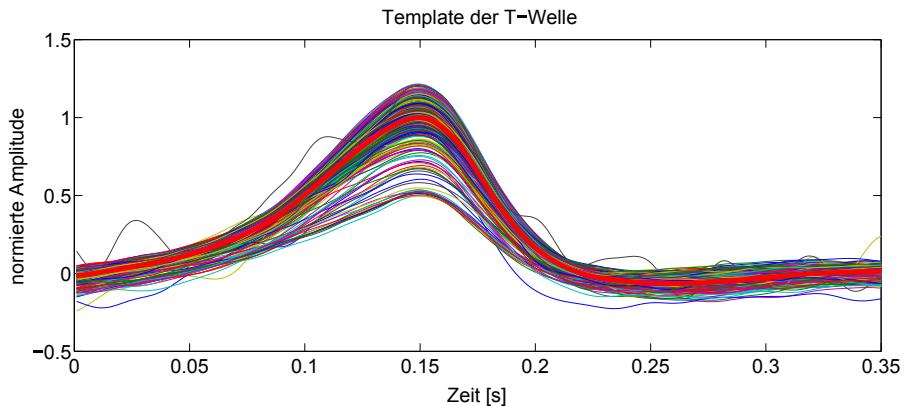


Abb. 5.7. Darstellung der extrahierten T-Wellen inklusive dem daraus gebildeten Template.

Auch hier werden nicht alle Features aufgezählt, die die T-Welle charakterisieren. Einige Features beschreiben die Eigenschaften der Amplitude der T-Welle. Darunter befindet sich das Maximum der T-Welle sowie Energieintegrale der Form

$$E = \int_{t_1}^{t_2} twelle^2(t)dt . \quad (5.11)$$

Die Berechnung der Integrale erfolgt dabei durch numerische Integration mit Hilfe der Trapezregel [Kiencke & Jäkel, 2008, S. 337-340]. Weitere Features beschreiben den Kurvenverlauf der T-Welle. So werden beispielsweise die maximalen Steigungen der T-Welle links und rechts von T_{peak} berechnet. Um solche Features robuster zu machen, werden die T-Wellen zuvor mit Hilfe des gleitenden Mittelwerts (Moving Average, MA) geglättet. Dies entspricht einer Faltung mit einem Rechteckfenster:

$$twelle_{MA}(n) = twelle(n) * \frac{1}{N} rec_N(n) . \quad (5.12)$$

Die Fensterbreite N wird dabei so gewählt, dass jeweils über 20 ms der T-Welle gemittelt wird. Die Krümmung in der Umgebung von T_{peak} wird ebenfalls als Feature verwendet. Dazu wird die T-Welle in der Umgebung von T_{peak} durch ein Polynom zweiten Grades

$$y(t) = a_2 t^2 + a_1 t + a_0 \quad (5.13)$$

mit Hilfe eines Least-Square-Schätzers approximiert [Kiencke & Eger, 2008, S. 18-21]. a_2 gibt daraus die Krümmung an. Für weitere Features kann die T-Welle als Wahrscheinlichkeitsdichte angesehen werden. Der Schwerpunkt t_{center} ergibt sich dann aus

$$t_{center} = \int_{t_1}^{t_2} t \cdot \rho_{twelle}(t) dt , \quad (5.14)$$

wobei die Dichte $\rho_{twelle}(t)$ durch

$$\rho_{twelle}(t) = \frac{twelle^2(t)}{\int_{t_1}^{t_2} twelle^2(t) dt} \quad (5.15)$$

gegeben ist und t_1 und t_2 gerade die Grenzen der extrahierten T-Wellen sind. Daraus werden weitere statistische Momente berechnet. Es werden weiterhin einige Features extrahiert, die die Symmetrie der T-Welle beschreiben sollen. Die Korrelation der T-Welle mit dem Template wird ebenfalls als Feature verwendet. Auch verschiedene Zeitdauern aus der T-Welle wurden als Parameter verwendet. Ein wichtiger Parameter aus der Morphologie ist die QT -Zeit. Da die Zeitpunkte R_{peak} und T_{peak} sich als deutlich robuster gezeigt haben als Q und T_{off} , wird statt der QT -Zeit die RT -Zeit bestimmt:

$$RT = T_{peak} - R_{peak} . \quad (5.16)$$

Die QT -Zeit ist von der Herzfrequenz abhängig. Daher wird in der Literatur häufig eine korrigierte QT -Zeit QTc nach Bazett [Bazett, 1920] verwendet. Hier wird statt dessen die RTc -Zeit verwendet:

$$RTc = \frac{RT}{\sqrt{RR}} . \quad (5.17)$$

Dabei wird RT in [ms] und RR in [s] verwendet. Aus allen RT - und RTc -Zeiten eines Zeitsegments werden auch zwei Varianten der häufig verwendeten QT -Dispersion bzw. hier der RT -Dispersion verwendet:

$$RTd1 = \sqrt{\frac{1}{N-1} \sum_{j=1}^N [RT(j) - \overline{RT}]^2} \quad (5.18)$$

$$RTd2 = \max\{RT\} - \min\{RT\} . \quad (5.19)$$

\overline{RT} ist dabei die mittlere RT -Zeit. Für RTc erfolgt die identische Berechnung.

5.2.4 ST-Strecke

Das Fenster zur Extraktion der ST-Strecke wird durch $[R_{peak} + 80\text{ ms}, R_{peak} + 160\text{ ms}]$ definiert. Die Korrektur des Offsets wird auf Basis des Intervalls aus dem QRS-Komplex durchgeführt. Ein Template der ST-Strecke ist in Abb. 5.8 zu sehen.

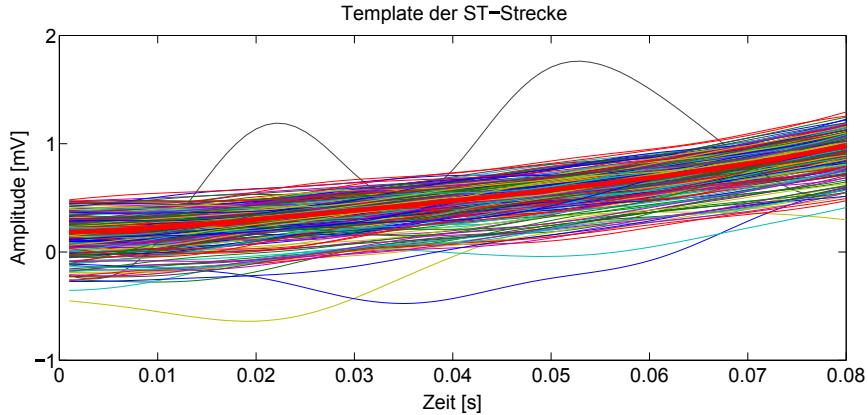


Abb. 5.8. Darstellung der extrahierten ST-Strecken inklusive dem daraus gebildeten Template.

Die Features der ST-Strecke sind den Features der T-Welle sehr ähnlich. Einige Features charakterisieren die Amplitude. Weitere Features beschreiben den Kurvenverlauf in Form von Steigung und Krümmung. Auch hier wird die ST-Strecke als Wahrscheinlichkeitsdichte interpretiert, um daraus statistische Momente zu bestimmen.

5.2.5 P-Welle

Die Feature-Generierung aus der P-Welle stellt im Gegensatz zu den bisher betrachteten Segmenten der EKG-Kurve eine Besonderheit dar. Die Filterung des Signals ist zunächst noch identisch mit der Filterung der ST-Strecke und der T-Welle. Es hat sich jedoch gezeigt, dass eine direkte Generierung der Features nicht sinnvoll ist, da der Einfluss durch Baseline-Wander zu stark ist. Vor der Extraktion der P-Welle und der Template-Bildung erfolgt jetzt eine Prozessierung, die auf der von Pilia entwickelten Detektion der P-Welle basiert [Pilia, 2013]. Die einzelnen Prozessschritte sind in Abb. 5.9 dargestellt. Im ersten Schritt werden der QRS-Komplex und die T-Welle aus dem Signal entfernt. Im zweiten Schritt wird eine Wavelet-Transformation des Signals mit Hilfe der stationären Wavelet-Transformation (SWT) durchgeführt. Dabei wird das Haar-Wavelet verwendet. Für die P-Welle wird eine Mittelfrequenz von 7 Hz angenommen. Die Skalierungsstufe l errechnet sich in Abhängigkeit von der Abtastrate f_s zu:

$$l = \left\lfloor \log_2 \left(\frac{f_s}{2 \cdot 7 \text{ Hz}} \right) \right\rfloor. \quad (5.20)$$

Somit ergibt sich für $f_s = 1\text{ kHz}$ die Skalierungsstufe zu $l = 6$ und für $f_s = 256\text{ Hz}$ zu $l = 4$. Bei dem auf diese Weise erzeugten Signal befindet sich bei P_{peak} kein Maximum mehr. Daher wird zuerst das Maximum P_{peak}^{SWT} innerhalb des Fensters $[P_{peak}-80\text{ ms}, P_{peak}+80\text{ ms}]$ bestimmt und anschließend das Signal innerhalb des Fensters

$[P_{peak}^{SWT} - 80\text{ ms}, P_{peak}^{SWT} + 80\text{ ms}]$ extrahiert. Aus dem Betrag der extrahierten Segmente wird das Template gebildet, wie es in Abb. 5.10 zu sehen ist. Für weitere Details dazu sei auf [Pilia, 2013] verwiesen.

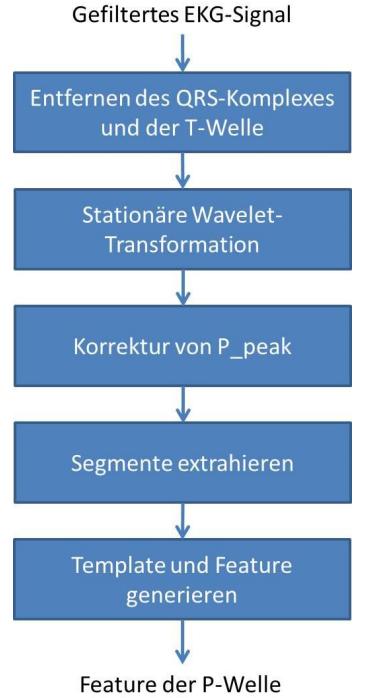


Abb. 5.9. Algorithmus zur Generierung von Templates und Features aus der P-Welle.

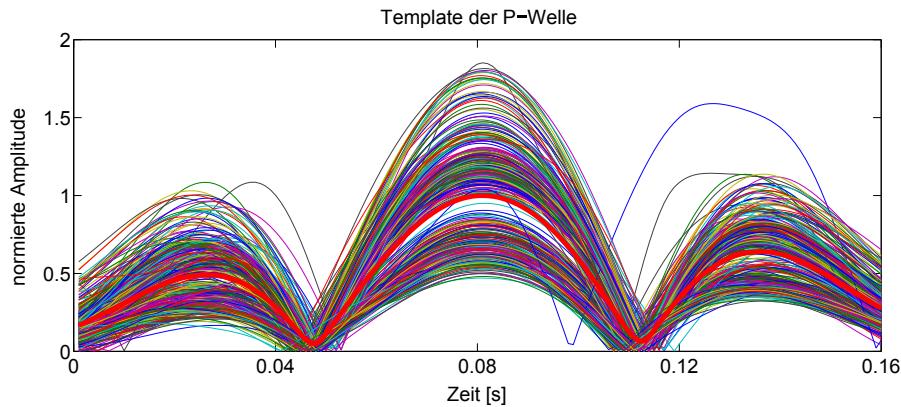


Abb. 5.10. Darstellung des Betrags der SWT der P-Wellen inklusive dem daraus gebildeten Template.

Aus dem Betrag der SWT der P-Wellen werden nun die gleichen Features generiert, wie sie auch für die T-Welle generiert werden. Die Idee dahinter ist, dass Änderungen in der Morphologie der P-Welle sich auch in der Morphologie der Wavelet-Transformierten

wiederspiegeln. Ähnlich wie bei der *QT*-Zeit kann hier die *PQ*-Zeit nicht robust genug bestimmt werden. Daher wird hier die *PR*-Zeit verwendet.

5.3 HRV-Analyse

Analog zur Analyse der Morphologie wird die HRV-Analyse auf alle Zeitsegmente aus Kapitel 4 angewendet. Zunächst wird aus der FPT die RR-Zeitreihe generiert. Falls mehr als eine Ableitung verwendet wurde, wird hierfür die synchronisierte FPT verwendet. Ein RR-Intervall ist dabei der zeitliche Abstand der aufeinanderfolgenden R-Zacken (Abb. 5.11).

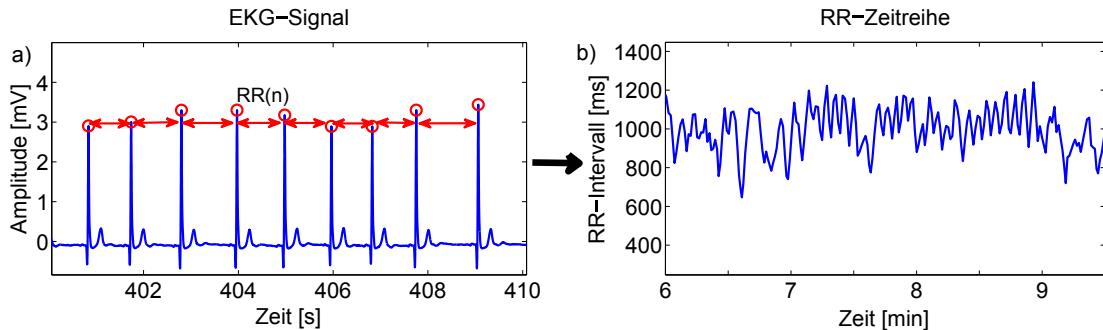


Abb. 5.11. Generierung der RR-Zeitreihe aus dem EKG-Signal. In a) ist ein EKG-Signal und die darin enthaltenen RR-Intervalle (rote Pfeile) zu sehen. b) zeigt die daraus entstehende RR-Zeitreihe.

Die RR-Zeitreihe kann durch verschiedene Arten von Artefakten beeinflusst werden. So können falsch sitzende Elektroden, Bewegungen der Probanden oder auch Herzrhythmusstörungen wie Extrasystolen die RR-Zeitreihe verfälschen. Um die RR-Zeitreihe zu bereinigen, wurde in einer vorherigen Arbeit eine Filtermethode zur Detektion und Korrektur solcher Artefakte entwickelt und implementiert. Innerhalb dieses Filters werden nur RR-Intervalle akzeptiert, die zwischen 300 ms und 2000 ms betragen, was einer Herzrate zwischen 30 bpm und 200 bpm entspricht. Weiterhin dürfen adjazente RR-Intervalle sich nicht mehr als 20 % voneinander unterscheiden. Auch die als Extrasystolen klassifizierten QRS-Komplexe werden herausgefiltert. Alle nicht akzeptierten RR-Intervalle werden aus der RR-Zeitreihe entfernt und durch ein approximiertes RR-Intervall ersetzt. Das approximierte RR-Intervall wird dabei mittels kubischer Spline-Interpolation zwischen den beiden benachbarten RR-Intervallen bestimmt. Genauere Details zu dieser Filtermethode werden in [Morath, 2014] erläutert.

Auf Basis der korrigierten RR-Zeitreihe wird dann die eigentliche HRV-Analyse durchgeführt. Dabei werden für jedes Zeitsegment die in der Literatur häufig verwendeten HRV-Parameter im Zeit- und Frequenzbereich bestimmt. Die Methoden zur Bestimmung dieser Parameter wurden ebenfalls bereits im Rahmen der Arbeit von Morath implementiert [Morath, 2014]. Dort finden sich auch genauere Erläuterungen zu den einzelnen Parametern. Hier sollen die Parameter nur kurz aufgeführt werden und gegebenenfalls Anpassungen erläutert werden. Eine kurze Beschreibung der Parameter befindet sich im Anhang A. Die HRV-Analyse wurde in dieser Arbeit durch die WPA ergänzt, die eine instantane Betrachtung der RR-Zeitreihe im Zeit- und Frequenzbereich erlaubt. Aus der WPA werden weitere Parameter für jedes Zeitsegment generiert.

5.3.1 Parameter im Zeitbereich

Unter den Parametern im Zeitbereich unterscheidet man statistische Parameter, geometrische Parameter und nichtlineare Parameter. Unter den statistischen Parametern

befinden sich $meanRR$, $SDNN$, $SDANN(1 \text{ min.})$ und $SDNN index(1 \text{ min.})$, die langsame Variationen der RR-Zeitreihe beschreiben. Die Parameter $SDANN(1 \text{ min.})$ und $SDNN index(1 \text{ min.})$ wurden dabei auf die Dauer der Zeitsegmente angepasst. Während in der Literatur beispielsweise $SDANN$ die Standardabweichung aller über 5 Minuten gemittelten RR-Intervalle angibt, wird in dieser Arbeit stattdessen die Standardabweichung aller über eine Minute gemittelten RR-Intervalle bestimmt. Für $SDANN index$ wurde genauso verfahren. Die Parameter $rMSSD$, $SDSD$, $pNN20$ und $pNN50$ sind ebenfalls statistische Parameter, die die Variationen der Differenzen aufeinanderfolgender RR-Intervalle angeben. Diese Parameter charakterisieren daher eher schnelle Variationen der RR-Zeitreihe [Malik et al., 1996].

Bei den geometrischen Parametern wird die RR-Zeitreihe zunächst in eine andere Darstellungsform transformiert. Eine dieser Darstellungsformen ist das Histogramm der RR-Intervalle. Aus dem Histogramm werden die Parameter $TINN$ und $HRV triangular index$ bestimmt. Diese Parameter sind mit $SDNN$ korreliert, jedoch sind diese Parameter robuster gegen das Auftreten von Artefakten oder Extrasystolen [Rajendra Acharya et al., 2006]. Eine weitere Darstellungsform ist das Poincaré-Plot, das bereits in Abschnitt 5.2.1 verwendet wurde. Im Poincaré-Plot wird jedes RR-Intervall $RR(j)$ mit seinem nachfolgenden RR-Intervall $RR(j + 1)$ als Punkt $[RR(j), RR(j + 1)]$ dargestellt. Zur Analyse der so entstehenden Punktwolken werden die Parameter $SD1$, $SD2$ und $\frac{SD1}{SD2}$ generiert. $SD1$ ist proportional zu $rMSSD$ und beschreibt somit ebenfalls schnelle Variationen. $SD2$ steht dagegen in Beziehung mit $SDNN$ und steht eher für langsame Variationen der RR-Zeitreihe [Morath, 2014].

Aus den nichtlinearen Parametern werden hier die Entropie-Parameter $ApEn$ und $SampEn$ verwendet. Diese Parameter untersuchen die Irregularität der RR-Zeitreihe. $ApEn$ sinkt mit kleiner werdendem $SDNN$, was bedeutet, dass die RR-Zeitreihe mit abnehmender HRV regulärer wird. Für RR-Zeitreihen mit mehr als 200 RR-Intervallen verhalten sich $ApEn$ und $SampEn$ nahezu identisch [Rajendra Acharya et al., 2006]. Weiterhin wird die Detrended Fluctuation Analysis (DFA) verwendet um die Parameter α_1 und α_2 zu bestimmen. α_1 und α_2 sind Maße für die Rauheit der RR-Zeitreihe. Je höher die Werte von α_1 und α_2 sind, je glatter ist das Signal. α_1 betrachtet für die Analyse Segmente mit 4 bis 16 RR-Intervallen, während α_2 16 bis 64 RR-Intervalle verwendet.

Für die Zeitsegmente von 2 Minuten und 6 Minuten gibt es für die mathematische Berechnung der hier verwendeten Parameter keine Einschränkungen. Die Parameter $SDANN(1 \text{ min.})$, $SDNN index(1 \text{ min.})$ und α_2 können für Zeitsegmente mit einer Dauer von 30 Sekunden nicht berechnet werden, da diese die RR-Zeitreihe für mehr als 1 Minute verwenden. Ob die genannten Parameter für kürzere Zeitsegmente noch vertrauenswürdig sind, muss für jeden Parameter einzeln bewertet werden.

5.3.2 Parameter im Frequenzbereich

Für die Analyse der HRV im Frequenzbereich wird die PSD aus der RR-Zeitreihe geschätzt. Für die PSD wird hier die Welch-Methode verwendet, die ebenfalls bereits in [Morath, 2014] ausführlich beschrieben wurde. Die einzelnen Schritte der Welch-Methode sind in Abb. 5.12 angedeutet.

Die Abtastpunkte der RR-Zeitreihe sind nicht äquidistant. Daher muss im ersten Schritt die RR-Zeitreihe interpoliert und neu abgetastet werden. Die RR-Zeitreihe wird hierzu mit einer kubischen Spline-Interpolation interpoliert und anschließend mit einer Abtastrate von 4 Hz neu abgetastet. Im zweiten Schritt folgt die eigentliche Schätzung der PSD. Dazu werden mittels einer Fensterfunktion Segmente der RR-Zeitreihe extrahiert. Für

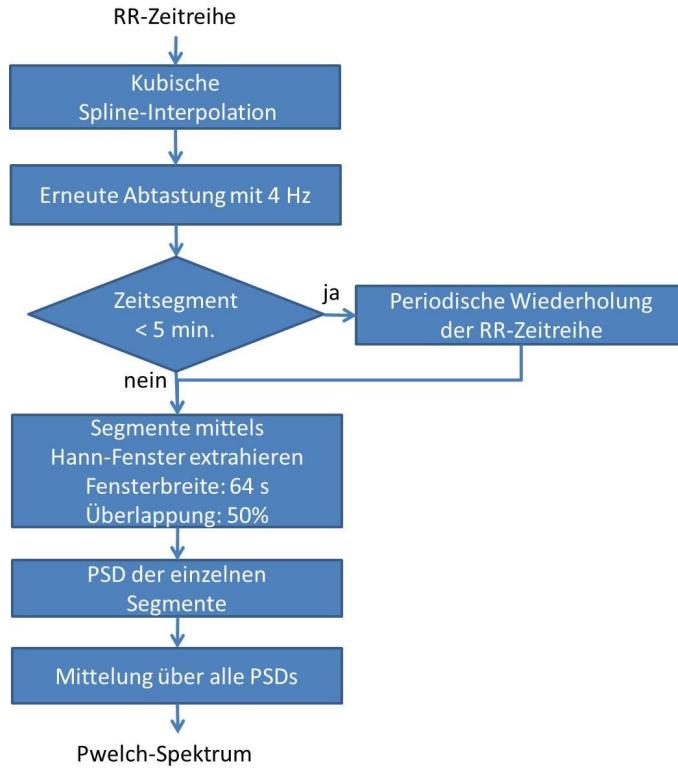


Abb. 5.12. Algorithmus zur Generierung des Welch-Spektrums aus der RR-Zeitreihe. Die Modifikation der Methode durch die periodische Wiederholung der RR-Zeitreihe im Falle zu kurzer Zeitsegmente wurde ebenfalls eingetragen.

jedes Segment wird eine PSD berechnet. Anschließend wird über alle Spektren gemittelt (vgl. Abschnitt 2.2.8). Als Fensterfunktion wurde ein Hann-Fenster mit einer Breite von 256 Abtastwerten verwendet. Dies entspricht einer Fensterbreite von 64 Sekunden. Es wurde für die Segmente eine Überlappung von 50 % verwendet. Bei der Berechnung der PSD für jedes Segment wurde eine FFT mit 1024 Punkten verwendet. In Abb. 5.13 ist eine auf diese Weise geschätzte PSD für eine RR-Zeitreihe von 6 Minuten Dauer dargestellt.

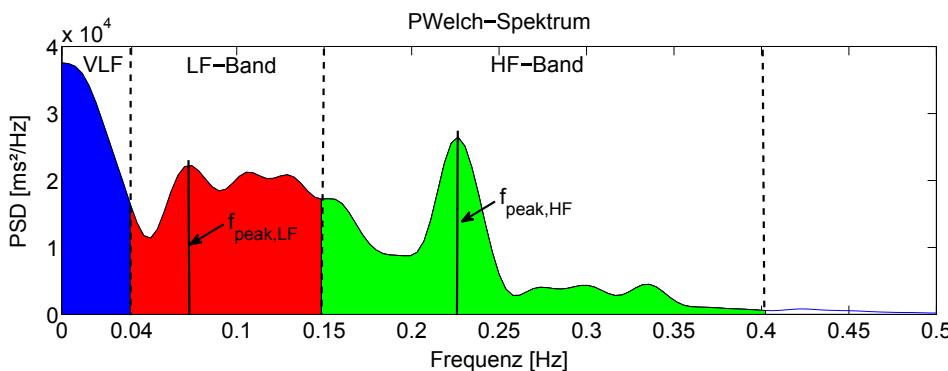


Abb. 5.13. Beispiel einer mit der Welch-Methode bestimmten PSD aus der RR-Zeitreihe. Die Frequenzbänder VLF, LF und HF sind ebenfalls eingezeichnet. Weiterhin wurden für dieses Beispiel die Frequenzen $f_{peak,LF}$ und $f_{peak,HF}$ bei den entsprechenden lokalen Maxima eingezeichnet.

Aus der PSD werden verschiedene Parameter entnommen, die der Leistung verschiedener Frequenzbereiche entsprechen. Die verschiedenen Frequenzbereiche sind ebenfalls in Abb. 5.13 eingezeichnet. Die Leistungen P werden dabei durch numerische Integration über den betrachteten Frequenzbereich berechnet:

$$P = \int_{f_1}^{f_2} PSD(f) df . \quad (5.21)$$

TP ist die gesamte Leistung aus der PSD. VLF gibt die Leistung im Frequenzbereich unterhalb von 0.04 Hz an. LF ist die Leistung zwischen 0.04 Hz und 0.15 Hz. HF ist die Leistung zwischen 0.15 Hz und 0.4 Hz. Mit LFn und HFn werden die auf $TP - VLF$ normierten Leistungen angegeben. Weiterhin wird das Verhältnis $\frac{LF}{HF}$ bestimmt. Neben den Leistungsparametern werden zusätzlich in den 3 Frequenzbereichen für VLF , LF und HF die Frequenzen $f_{peak,VLF}$, $f_{peak,LF}$ und $f_{peak,HF}$ der jeweiligen lokalen Maxima als Parameter verwendet. Zwischen den Parametern im Zeit- und Frequenzbereich bestehen einige Korrelationen. TP ist mit $SDNN$ korreliert und charakterisiert langsame Variationen der RR-Zeitreihe. HF ist dagegen mit Parametern wie $rMSSD$ korreliert, die schnelle Variationen aufeinanderfolgender RR-Intervalle beschreiben [Malik et al., 1996].

Für das MSE-Experiment wurden Zeitsegmente von 120 s und 30 s Dauer verwendet. Inwiefern die hier vorgestellte Welch-Methode auf solche Zeitsegmente noch anwendbar ist, soll im Folgenden diskutiert werden. Die Welch-Methode bietet durch die Mittelung über mehrere Spektren eine konsistente Schätzung der PSD mit reduzierter Varianz. Die Güte dieser Schätzung hängt dabei maßgeblich von der Anzahl der Segmente und der Länge der Segmente ab [Kammeyer & Kroschel, 2009, Kapitel 9]. Für Zeitsegmente von weniger als 2 Minuten erhält man mit der Fensterbreite von 64 Sekunden und einer Überlappung von 50 % jedoch nur 3 Spektren, über die gemittelt wird. Die Varianz der Schätzung kann dadurch nicht so stark reduziert werden, wie das noch bei den Zeitsegmenten von 6 Minuten Dauer der Fall war. Der Vorteil der Welch-Methode verschwindet somit. Um wieder über mehr als 3 Spektren zu mitteln, gibt es verschiedene Möglichkeiten. Eine Variante wäre, die Fensterbreite zu reduzieren. Eine Reduktion der Fensterbreite auf 128 Abtastpunkte, was einer Dauer von 32 Sekunden entspricht, würde eine Mittelung über 7 Spektren ermöglichen. Jedoch führt eine schmalere Fensterfunktion zu einer größeren Verschmierung des Spektrums durch den Leckeffekt, was in [Morath, 2014] ebenfalls gezeigt wurde. Zudem reicht diese Reduktion der Fensterbreite nicht aus um auch für Zeitsegmente von 30 Sekunden Dauer eine PSD zu schätzen. Eine andere Variante ist die periodische Wiederholung der RR-Zeitreihe. Dabei wird die RR-Zeitreihe so oft periodisch wiederholt, bis die Dauer der RR-Zeitreihe wieder mehr als 5 Minuten beträgt. Dadurch erhält man wieder mehr Spektren, über die gemittelt werden kann. Eine ähnliche Vorgehensweise wird beispielsweise in der Kommunikationstechnik in OFDM-Systemen verwendet um die Auswirkungen der Mehrwegausbreitung zu reduzieren [Kammeyer et al., 2011, Kapitel 16]. In Abb. 5.14 ist die PSD eines 2 Minuten Segments ohne periodische Wiederholung in blau dargestellt. Das häufig in der PSD sichtbare Maximum bei 0.1 Hz ist hier bereits stark verschmiert und nicht mehr von den Frequenzanteilen niedrigerer Frequenzen zu unterscheiden. In rot ist die PSD mit periodischer Wiederholung zu sehen. In schwarz ist außerdem die PSD mit einer Fensterbreite von 32 Sekunden und ohne periodische Wiederholung dargestellt. Man erkennt bei beiden Varianten das Maximum bei 0.1 Hz. Das Maximum bei 0.31 Hz bleibt bei der Variante der periodischen Wiederholung besser

erhalten als bei der Variante mit der reduzierten Fensterbreite. Die periodische Wiederholung wurde daher für die Zeitsegmente von 30 Sekunden und 2 Minuten Dauer wie in Abb. 5.12 zu sehen in die Methode aufgenommen. Für die Betrachtung der PSD eines Zeitsegments mit einer Dauer von 30 Sekunden sei auf die WPA im folgenden Abschnitt 5.3.3 verwiesen.

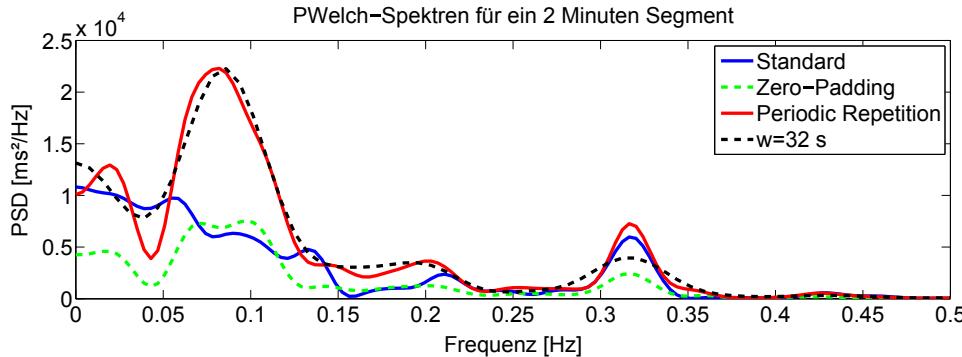


Abb. 5.14. Darstellung der Welch-Spektren aus verschiedenen Ansätzen zur Modifikation des Algorithmus für 2 Minuten Segmente. In blau ist das Spektrum ohne Modifikation zu sehen. In grün ist ein Spektrum nach Zero-Padding dargestellt. Das Spektrum nach der periodischen Wiederholung ist in rot abgebildet. Das Spektrum nach Verwendung eines 32 s-Fensters ist in schwarz eingezzeichnet. Sowohl die Variante mit reduzierter Fensterbreite als auch die Variante der periodischen Wiederholung können das typische Maximum bei 0.1 Hz gut schätzen. Das Maximum bei 0.31 Hz bleibt bei der periodischen Wiederholung gut erhalten.

Für die Schätzung der Parameter im *HF*-Bereich sollte die Dauer des betrachteten Zeitsegments mindestens 1 Minute betragen. Für die Parameter im *LF*-Bereich wird eine Dauer von mindestens 2 Minuten empfohlen. Im Allgemeinen sollte die Dauer der Zeitsegmente mindestens 10 mal länger sein, als die längste betrachtete Periodendauer [Malik et al., 1996]. Da dies für die 30 s-Segmente nicht eingehalten wird, muss die Aussagekraft von *HF* und vor allem *LF* in Frage gestellt werden.

5.3.3 Wavelet Packet Analyse (WPA)

In diesem Abschnitt wird die in dieser Arbeit verwendete Variante der WPA vorgestellt. Dabei spielt die Wahl des Wavelets und die Wahl der verwendeten Knoten im WPA-Baum eine entscheidende Rolle. Die WPA liefert eine Zeit-Frequenz-Darstellung der RR-Zeitreihe. Aus der WPA werden schließlich weitere Features extrahiert. Die einzelnen Verarbeitungsschritte des Algorithmus sind in Abb. 5.15 zusammengefasst.

Interpolation und Abtastrate

Wie bei der Welch-Methode zur Schätzung der PSD muss auch hier die RR-Zeitreihe interpoliert und erneut abgetastet werden. Dazu wird ebenfalls eine kubische Spline-Interpolation mit einer Abtastrate von $f_s = 2.4$ Hz verwendet. Der Grund für die Wahl von f_s liegt darin, dass ab der 3. Skalierungsstufe die Signalanteile oberhalb und unterhalb von 0.15 Hz durch die WPA getrennt werden. Dadurch können bei der WPA ebenfalls die Frequenzbänder *LF* und *HF* aus der Welch-Methode betrachtet werden [Wiklund et al., 1997].

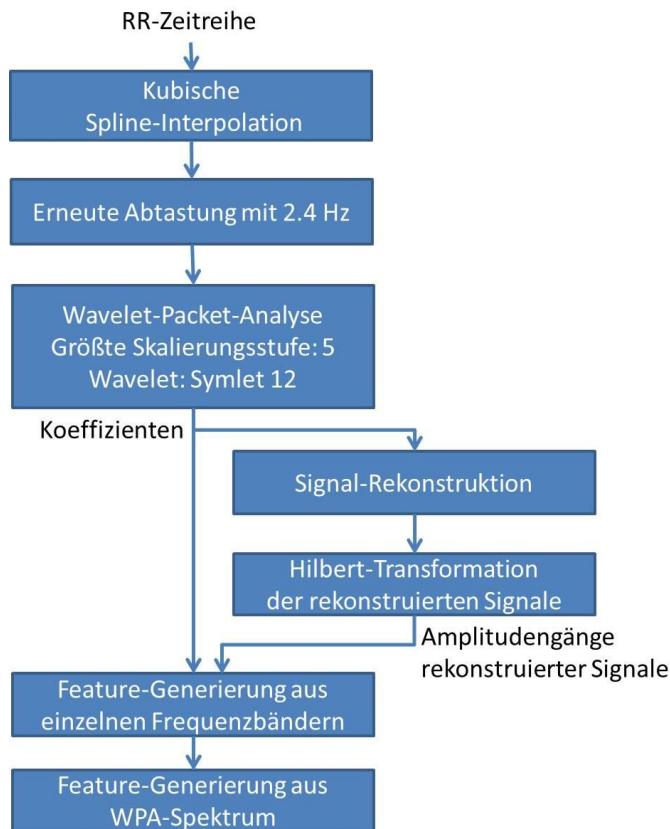


Abb. 5.15. Algorithmus zur Feature-Generierung mit Hilfe der WPA.

Die Wahl des Wavelets

Die Wavelet-Koeffizienten geben die Ähnlichkeit eines Ausschnitts der RR-Zeitreihe mit der Form des Wavelets an. Daher richtet sich die Wahl des Wavelets nach der im Signal vermuteten Anteile. Nach [Malik et al., 1996] befinden sich in der RR-Zeitreihe unter anderem verschiedene sinusförmige Signalanteile, die jedoch zeitlich variieren können. In der Literatur werden die Daubechies-Wavelets bevorzugt. Neben der Form des Wavelets ist noch die Ordnung der dazugehörigen Filter wichtig. Eine höhere Ordnung der Filter führt zu einer längeren Impulsantwort im Zeitbereich und somit zu einer schlechteren Auflösung. Im Frequenzbereich führt eine höhere Ordnung zu einem steiler abfallenden Frequenzgang, sodass die Frequenzbänder untereinander besser getrennt werden können [Kiencke et al., 2008, S. 170-171]. Gamero et al. [Gamero et al., 2002] und Wiklund et al. [Wiklund et al., 1997] verwendeten das Daubechies 12 Wavelet, da dieses im Fall der RR-Zeitreihe eine sehr gute Trennung der Frequenzbänder ermöglicht. Nach einigen Experimenten mit verschiedenen Wavelets wurde in dieser Arbeit als Wavelet das Symlet 12 verwendet. Die Symlets sind eine modifizierte Variante der Daubechies. Die Frequenzgänge der Symlets sind mit jenen der Daubechies nahezu identisch. Jedoch besitzen die Symlets im Zeitbereich eine deutlich symmetrischere Form als die Daubechies Wavelets. Das hat den Vorteil, dass es bei der Visualisierung der RR-Zeitreihe in der Zeit-Frequenz-Ebene nicht zu asymmetrischen Verzerrungen kommt, die eine Interpretation erschweren würden [Addison, 2002, S. 115-117]. Weitere Details zu den Daubechies und den Sym-

lets finden sich in [Addison, 2002, Abschnitt 3.5]. Das Symlet 12, die Impulsantwort der Skalierungs- und Wavelet-Filter und deren Frequenzgänge sind in Abb. 5.16 dargestellt.

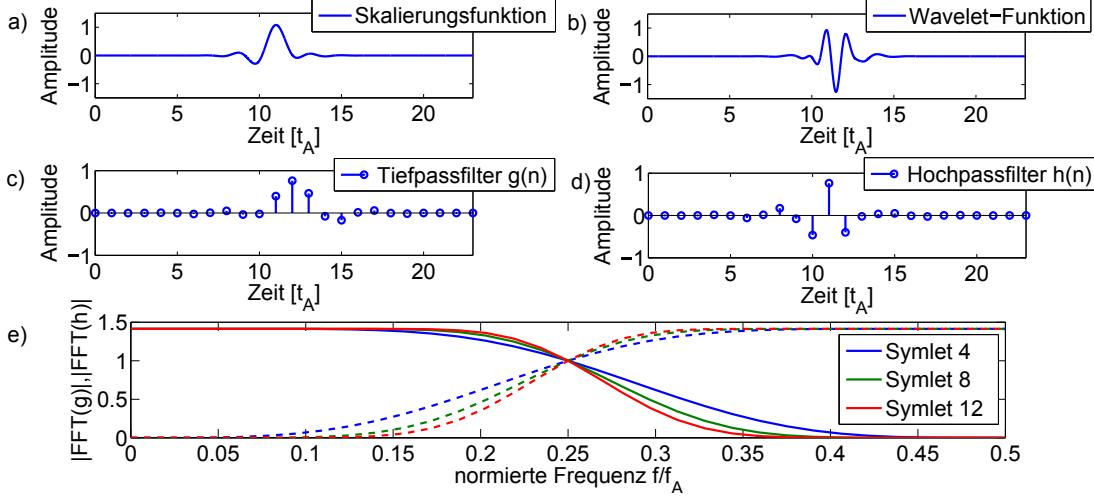


Abb. 5.16. Darstellung des Symlet 12. In a) ist die Skalierungsfunktion dargestellt. b) zeigt die Wavelet-Funktion. Die dazugehörigen Filter $g(n)$ und $h(n)$ sind in c) und d) dargestellt. Der Frequenzgang der Filter ist in e) dargestellt. In e) sind zum Vergleich die Frequenzgänge von Symlet 4 (blau), Symlet 8 (grün) und Symlet 12 (rot) dargestellt. Man erkennt deutlich den steiler abfallenden Frequenzgang der Filter mit zunehmender Ordnung.

WPA-Baum

Nach der Wahl der Abtastrate und der Wahl des Wavelets fehlt noch die Auswahl der verwendeten Knoten im WPA-Baum. Die Auswahl der Knoten bestimmt die Gestaltung der Zeit-Frequenz-Ebene. Es werden hier die Knoten der Skalierungsstufe 5 verwendet. Mit der Nyquist-Frequenz von $f_n = 1.2$ Hz führt das auf eine Frequenz-Auflösung von

$$\Delta f = \frac{f_n}{2^5} = 0.0375 \text{ Hz}. \quad (5.22)$$

Damit erhalten wir 32 Frequenzbänder. Die oberen 16 Frequenzbänder im Bereich von 0.6 – 1.2 Hz enthalten ausschließlich Rauschen. Um dies nachvollziehen zu können, betrachten wir die RR-Zeitreihe als ein zeitdiskretes Signal, dass durch Abtastung der Herzaktivität generiert wurde. Für eine Herzrate von 60 bpm erhalten wir in diesem Fall eine Abtastrate von 1 Hz. Nach dem Abtasttheorem aus Gl. 2.20 können demnach aus der RR-Zeitreihe nur Frequenzen unterhalb von 0.5 Hz im Frequenzbereich betrachtet werden, da höhere Frequenzen zu Aliasing führen. Durch die zusätzliche Verwendung der Spline-Interpolation und der anschließenden Abtastung mit 2.4 Hz können in den Frequenzbändern oberhalb von 0.6 Hz keine Informationen vorhanden sein. Daher sollen diese hier nicht weiter betrachtet werden. Alle Signalanteile, wie Schwingungen mit einer Periodendauer von über 25 s oder auch lineare Signalanteile werden in das unterste Frequenzband zwischen 0 – 0.0375 Hz projiziert. Das führt dazu, dass der Energieanteil dieses Frequenzbandes der Energie aller anderen Frequenzbänder deutlich überwiegt. Daher wurden die Koeffizienten dieses Bandes zu 0 gesetzt. Damit hat man den Trend der RR-Zeitreihe

entfernt [Wiklund et al., 1997]. Alle anderen Frequenzbänder und deren zugehörige übergeordnete Frequenzbänder *VLF*, *LF*, *HF* und *VHF* (Very High Frequency) sind in Tab. 5.1 aufgelistet. Der so entstandene WPA-Baum ist in Abb. 5.17 dargestellt. Es sei hier angemerkt, dass die Reihenfolge der Knoten des WPA-Baums nicht der Reihenfolge der Frequenzbänder entspricht.

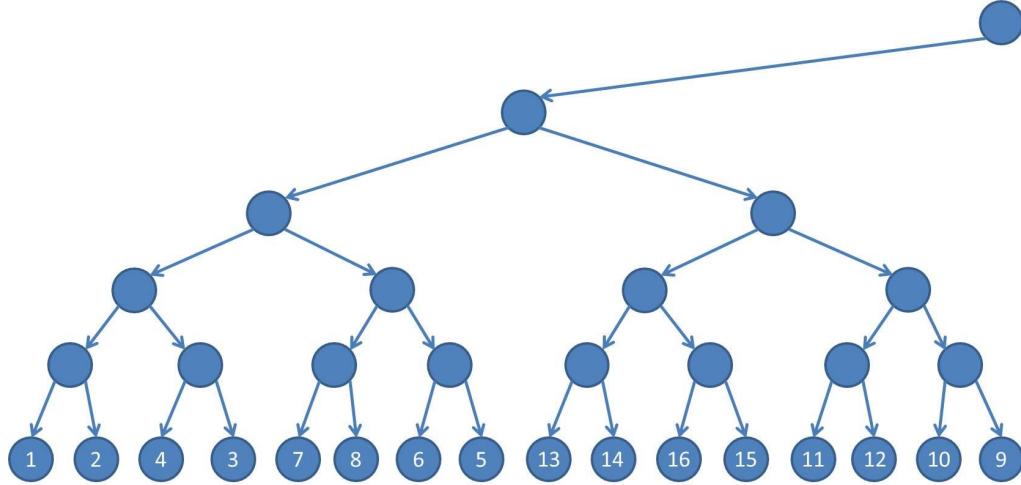


Abb. 5.17. Darstellung des hier verwendeten WPA-Baums. Zu sehen ist die linke Hälfte des WPA-Baums, die den Frequenzbereich [0 Hz, 0,6 Hz] abdeckt. Die verwendeten Knoten sind nach der Reihenfolge der Frequenzbänder nummeriert.

übergeordnetes Frequenzband	Knoten	Frequenzband [Hz]
VLF	1	0-0.0375
LF	2	0.0375-0.075
	3	0.075-0.1125
	4	0.1125-0.15
	5	0.15-0.1875
HF	6	0.1875-0.225
	7	0.225-0.2625
	8	0.2625-0.3
	9	0.3-0.3375
	10	0.3375-0.375
	11	0.375-0.4125
	12	0.4125-0.45
VHF	13	0.45-0.4875
	14	0.4875-0.525
	15	0.525-0.5625
	16	0.5625-0.6

Tabelle 5.1. Frequenzbänder der hier verwendeten WPA

Visualisierung der WPA

Zur Demonstration der WPA wurde hier das synthetische Signal aus Abb. 5.18 a) verwendet. In den ersten 3 Minuten des Signals ist ein Sinus mit einer Frequenz von $f_1 = 0.09$ Hz

zu sehen. In den zweiten 3 Minuten ändert sich die Frequenz des Sinus auf $f_2 = 0.32$ Hz. Zudem ist im zweiten Abschnitt des Signals ein Impuls zu erkennen. Die dazugehörige Zeit-Frequenz-Ebene ist in Abb. 5.18 b) zu sehen. Für die Visualisierung der WPA werden die rekonstruierten Signale der jeweiligen Frequenzbänder verwendet. Im Folgenden werden diese mit rec_{fb} bezeichnet, wobei fb das zugehörige Frequenzband indiziert. Weiterhin hat es sich als vorteilhaft erwiesen, anstatt rec_{fb} den dazugehörigen Amplitudengang in der Darstellung zu verwenden. Dazu wird aus einem Signal $y(t)$ das analytische Signal mit

$$z(t) = y(t) + j \cdot \mathcal{H}\{y(t)\} \quad (5.23)$$

berechnet. $\mathcal{H}\{\cdot\}$ ist der Operator der Hilbert-Transformation. Den Amplitudengang erhält man durch Betragsbildung von $z(t)$ [Kiencke & Jäkel, 2008, Abschnitt 4.7]. Man sieht in der Zeit-Frequenz-Ebene deutlich die zu f_1 und f_2 gehörenden Frequenzbänder 3 und 9. Man erkennt jedoch auch, dass Signalanteile der Frequenz f_2 in das benachbarte Band 8 projiziert wurden. Der Impuls in der zweiten Hälfte des Signals wurde über mehrere Frequenzbänder verteilt und zeitlich verschmiert.

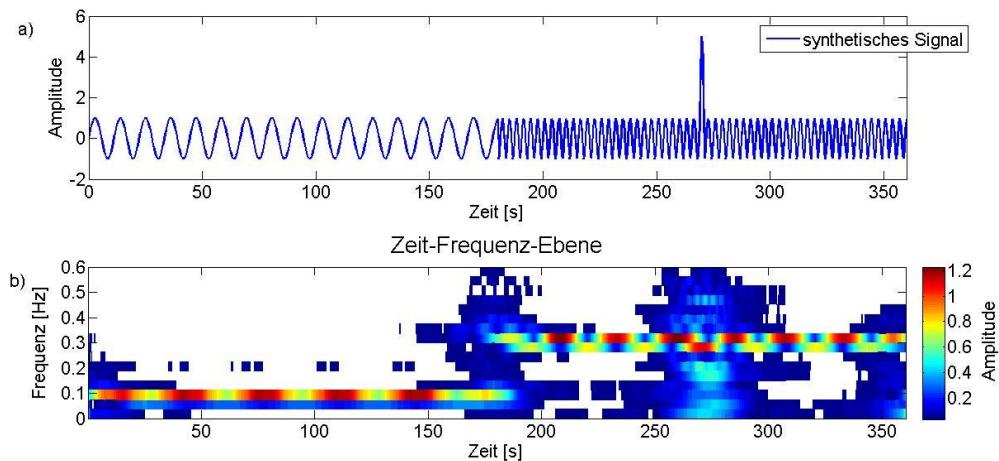


Abb. 5.18. Demonstration der WPA anhand eines synthetischen Signals. a) Synthetisches Signal mit den Frequenzen $f_1 = 0.09$ Hz (Frequenzband 3) in den ersten 180 s und $f_2 = 0.32$ Hz (Frequenzband 9) in den zweiten 180 s, sowie einen Impuls bei 270 s. b) Zeit-Frequenz-Darstellung des synthetischen Signals. Man erkennt, dass die Frequenzbänder 3 und 9 zu den jeweiligen Zeitabschnitten dominieren. Der Impuls wurde zeitlich verschmiert und erzeugte Signalanteile in allen Frequenzbändern.

Extraktion der Features aus der WPA

Die Features, die aus der WPA extrahiert werden, lassen sich generell in zwei Kategorien einteilen. Es werden zum einen Features extrahiert, die die Frequenzbänder separat charakterisieren. Zum anderen werden Features extrahiert, die sich auf die übergeordneten Frequenzbänder *LF*, *HF* und *VHF* beziehen.

Zunächst sollen die Features der einzelnen Frequenzbänder betrachtet werden. Aus den Koeffizienten $coef_{fb}$ kann ein Energiedichtespektrum gewonnen werden. Ähnlich wie bei der DFT erhält man die Energie des Frequenzbandes fb mit

$$E_{fb} = \|\text{coeff}_{fb}\|^2 . \quad (5.24)$$

Man kann zeigen, dass auch bei der WPA der Satz von Parseval gilt. Die Energie bleibt bei der Zerlegung des Signals erhalten [Vetterli & Kovačević, 1995]. Neben der absoluten Energie der Frequenzbänder wird auch die normierte Energie En_{fb} als Feature verwendet:

$$En_{fb} = \frac{E_{fb}}{\sum_{i=2}^{16} E_i} . \quad (5.25)$$

Ein qualitativer Vergleich des WPA-Spektrums mit dem Welch-Spektrum ist in Abb. 5.19 zu sehen. Weiterhin werden statistische Momente und Lagemaße der Koeffizienten als Merkmale extrahiert. Darunter befinden sich der Mittelwert, die Standardabweichung, die Skewness und die Kurtosis der Koeffizienten. Als Pendant zum Mittelwert wird aus den Lagemaßen der Median verwendet. Der Interquartilsabstand iqr_{fb} kann als robustes Streumaß mit der Varianz verglichen werden:

$$iqr_{fb} = Q_{75,fb} - Q_{25,fb} , \quad (5.26)$$

wobei mit Q_p das entsprechende Quantil bezeichnet wird. Als eine Art Spannweite der Koeffizienten wird $iqr_{9010,fb}$ verwendet:

$$iqr_{9010,fb} = Q_{90,fb} - Q_{10,fb} . \quad (5.27)$$

Das Quantil $Q_{90,fb}$ wird ebenfalls als Feature extrahiert. Zusätzlich wird die Entropie über

$$Entropie_{fb} = \sum_{m=1}^M \text{coeff}_{fb}(m) \cdot \log_2(\text{coeff}_{fb}(m)) \quad (5.28)$$

verwendet, wobei M die Anzahl der Koeffizienten angibt [Panigrahi & Pandi, 2009]. Aus dem Amplitudengang der rekonstruierten Signale wird außerdem in Anlehnung an den Zeit-Parameter $pNN50$ der Parameter $pRec50_{fb}$ verwendet, der den Prozentteil angibt, für welchen die Amplitude von rec_{fb} größer als 50 ms beträgt. Das Ziel dieser Features ist die Energie oder allgemeiner die Aktivität der Frequenzbänder zu charakterisieren. Es wurden gezielt scheinbar redundante Features extrahiert.

Die Features der übergeordneten Frequenzbänder *LF*, *HF* und *VHF* haben im Wesentlichen die Aufgabe eine Vergleichbarkeit mit dem Welch-Spektrum herzustellen. Aus einigen Publikationen wie [Tanaka & Hargens, 2004] geht hervor, dass die Schätzung der Frequenz-Parameter aus der DWT verlässlicher sei als aus dem Welch-Spektrum. Die Energie-Parameter erhält man durch Aufsummierung der entsprechenden Energien der Frequenzbänder:

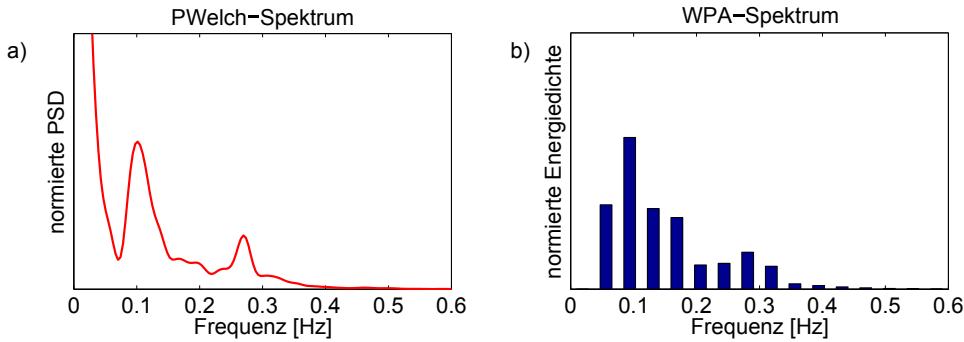


Abb. 5.19. Qualitativer Vergleich der normierten Spektren aus der Welch-Methode (a) und aus der WPA(b). In beiden Spektren sind die Maxima bei etwa 0.1 Hz und 0.3 Hz zu sehen. Die Auflösung des Welch-Spektrums ist deutlich besser. Dafür bleiben bei der WPA die Informationen der zeitlichen Entwicklung erhalten. (Bei der WPA wurde das Frequenzband für Frequenzanteile unterhalb von 0.0375 Hz entfernt.)

$$LF = \sum_{fb=2}^4 E_{fb} \quad (5.29)$$

$$HF = \sum_{fb=5}^{11} E_{fb} \quad (5.30)$$

$$VHF = \sum_{fb=12}^{16} E_{fb} \quad (5.31)$$

$$TP = LF + HF + VHF . \quad (5.32)$$

Die normierten Energien LF_n , HF_n und VHF_n erhält man entsprechend durch Division durch die Gesamtenergie TP . Auch hier wird das Verhältnis $\frac{LF}{HF}$ als weiteres Feature generiert. Aus dem normierten Energiedichtespektrum werden weiterhin statistische Momente wie die mittlere Frequenz f_{center} , die Bandbreite B , die effektive Bandbreite B_{eff} , die Skewness und die Kurtosis berechnet. Für weitere Features werden die zu LF und HF gehörenden Signalanteile rekonstruiert. Wie man unter anderem aus der Reihenentwicklung Gl. 2.57 und Gl. 2.58 oder auch aus der Filterstruktur in Abb. 2.7 leicht sehen kann, ergeben sich die rekonstruierten Signale einfach durch folgende Summen:

$$rec_{LF} = \sum_{fb=2}^4 rec_{fb} \quad (5.33)$$

$$rec_{HF} = \sum_{fb=5}^{11} rec_{fb} . \quad (5.34)$$

Zur Demonstration der Qualität der Signalrekonstruktion wurden in Abb. 5.20 die rekonstruierten Signal rec_{LF} und rec_{HF} sowie deren Überlagerung $rec_{LF} + rec_{HF}$ mit der ursprünglichen RR-Zeitreihe verglichen. Aus den Amplitudengängen von rec_{LF} und rec_{HF} werden der Mittelwert, der Median, das Quantil Q_{90} und der bereits eingeführte Parameter $pRec50$ extrahiert.

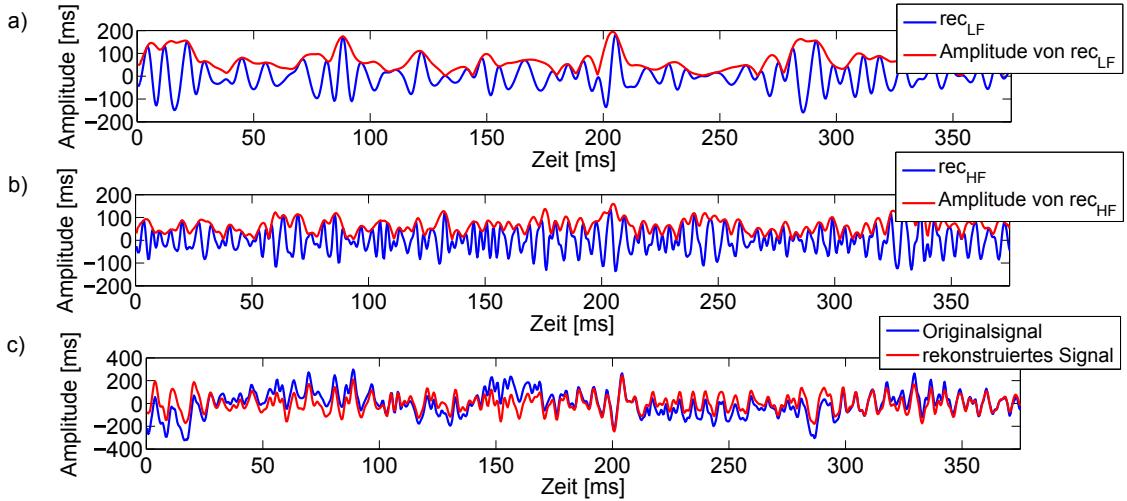


Abb. 5.20. Signalrekonstruktion der RR-Zeitreihe. In a) ist das rekonstruierte Signal aus dem *LF*-Band (blau) und der dazu gehörende Amplitudengang (rot) dargestellt. b) zeigt das rekonstruierte Signal aus dem *HF*-Band (blau) und den dazugehörigen Amplitudengang (rot). c) zeigt die ursprüngliche RR-Zeitreihe (blau) und die rekonstruierte RR-Zeitreihe aus $rec_{LF} + rec_{HF}$ (rot). Der Grund für die Abweichungen liegt an der Unterdrückung des Frequenzbandes 1 (0-0.04 Hz). (Anmerkung: Zur Darstellung wurde von der RR-Zeitreihe der Mittelwert subtrahiert.)

WPA für kurze Zeitsegmente

Bei der hier verwendeten WPA erhält man mit der Skalierungsstufe 5 eine Zeitauflösung von

$$\Delta t = \frac{1}{t_A} \cdot 2^5 = 13.3 \text{ s} . \quad (5.35)$$

Damit gibt es für Zeitsegmente mit einer Dauer von 2 Minuten keine Einschränkungen. Für Zeitsegmente von 30 Sekunden Dauer erhält man noch 3 Koeffizienten aus der WPA. Damit muss die Robustheit der Features aus der WPA in Frage gestellt werden. Nach Versuchen mit synthetischen Signalen wie in Abb. 5.18 hat sich gezeigt, dass die Zeitauflösung noch gerade ausreicht, um solche Signale sinnvoll in einer Zeit-Frequenz-Ebene darstellen zu können. In Abb. 5.21 ist nochmal ein Vergleich des Welch-Spektrums mit dem WPA-Spektrum dargestellt. Die Spektren wurden dabei aus der gleichen RR-Zeitreihe berechnet, die bereits in Abb. 5.14 bei der Einführung der periodischen Wiederholung verwendet wurde. Man erkennt in beiden Spektren das Maximum bei 0.1 Hz. Das Maximum bei 0.3 Hz ist beim Welch-Spektrum besser zu erkennen, als beim WPA-Spektrum. Dennoch erkennt man im entsprechenden Frequenzband der WPA eine leichte Erhöhung der Energie. Natürlich gilt auch hier die Empfehlung, dass für die Schätzung der Energie in niedrigen Frequenzbändern die Dauer der betrachteten RR-Zeitreihe größer als 10 Perioden sein sollte [Malik et al., 1996].

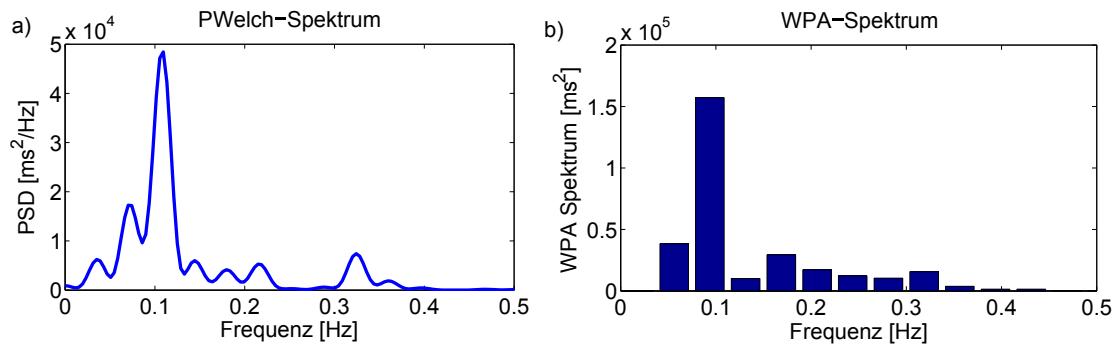


Abb. 5.21. Qualitativer Vergleich des Welch-Spektrums mit dem WPA-Spektrum für ein 30 s-Segment der RR-Zeitreihe.

6

Ergebnisse

6.1 Auswertung des Mental-Stress-Test

In diesem Abschnitt werden die Ergebnisse aus der Analyse der Morphologie und der HRV zu den einzelnen Phasen des Mental-Stress-Tests vorgestellt. Zur Bestimmung von signifikanten Änderungen zwischen den einzelnen Phasen des Tests wurde der Wilcoxon-Vorzeichen-Rang-Test verwendet, der auch von Gamero et al. vorgeschlagen wurde [Gamero et al., 2002]. Es handelt sich dabei um einen nicht-parametrischen Signifikanztest, der keine Normalverteilung der betrachteten Features voraussetzt. Der Test beurteilt, ob sich der Median des betrachteten Features zwischen zwei Phasen verändert hat. Dabei berücksichtigt der Test weiterhin die Abhängigkeit der Features zwischen den beiden Phasen, die in diesem Fall durch die individuellen Personen gegeben ist. Es wurde die Signifikanz zwischen der ersten Ruhephase und Stress-Level 1, zwischen Stress-Level 1 und Stress-Level 2 und zwischen Stress-Level 2 und Stress-Level 3 berechnet. Eine Veränderung wurde als signifikant bewertet, wenn die Irrtumswahrscheinlichkeit $p < 0.05$ betrug [Büning & Trenkler, 1994, Kapitel 6].

Wir betrachten zunächst die Parameter der HRV-Analyse im Zeit- und Frequenzbereich. Einige Beispiele sind in Abb. 6.1 als Boxplots dargestellt. Die signifikantesten Veränderungen zwischen Ruhephase und Stress-Level 1 zeigten die Entropie-Parameter *ApEn* und *SampEn*, die während der Stress-Level höhere Werte annahmen, als in der Ruhephase. Nach [Rajendra Acharya et al., 2006] weist dies auf eine höhere Irregularität hin. Weiterhin gingen die Parameter *TP*, *VLF*, *SDNN*, *SDNN index(1 min)*, *SD2* und *TINN* im Vergleich zwischen Ruhephase und Stress-Level 1 signifikant zurück, während $\frac{SD1}{SD2}$ stieg. Diese Parameter sind korreliert und stehen für langsamere Variationen der RR-Zeitreihe. Dies weist auf einen Rückgang der HRV während des Stress-Tests hin, was mit einer dominierenden Aktivität des Sympathikus interpretiert werden kann [Malik et al., 1996]. Das mittlere RR-Intervall *meanRR* verzeichnete während des gesamten Versuch einen Rückgang von etwa 775 ms in der Ruhephase 1, was einer Herzrate von etwa 77 bpm entspricht, auf etwa 700 ms im Stress-Level 3, was einer Herzrate von etwa 86 bpm entspricht. Signifikant war dabei die Veränderung zwischen Ruhephase 1 und Stress-Level 1 und die Veränderung zwischen Stress-Level 1 und Stress-Level 2. Die Parameter für schnelle Variationen der RR-Zeitreihe *rMSSD*, *SDSD*, *pNN20*, *pNN50*, *SD1* und *HF* konnten einen signifikanten Rückgang zwischen Stress-Level 1 und Stress-Level 2 feststellen. Diese Parameter sind ebenfalls korreliert und weisen auf einen Rückgang des Parasympathikus hin [Malik et al., 1996]. Der Parameter $\frac{LF}{HF}$ war der einzige Parameter, der eine signifikante Veränderung zwischen Stress-Level 2 und 3 feststellen konnte. Wie in Abb. 6.1 zu

sehen ist, war das jedoch nicht für alle Probanden der Fall. Es gab keinen Parameter der zwischen allen Phasen des Tests signifikante Veränderungen feststellen konnte. Das gilt insbesondere für die in der Literatur häufig verwendeten Parameter HF_n und LF_n . Bei HF_n ist lediglich ein tendenzieller Rückgang zu sehen.

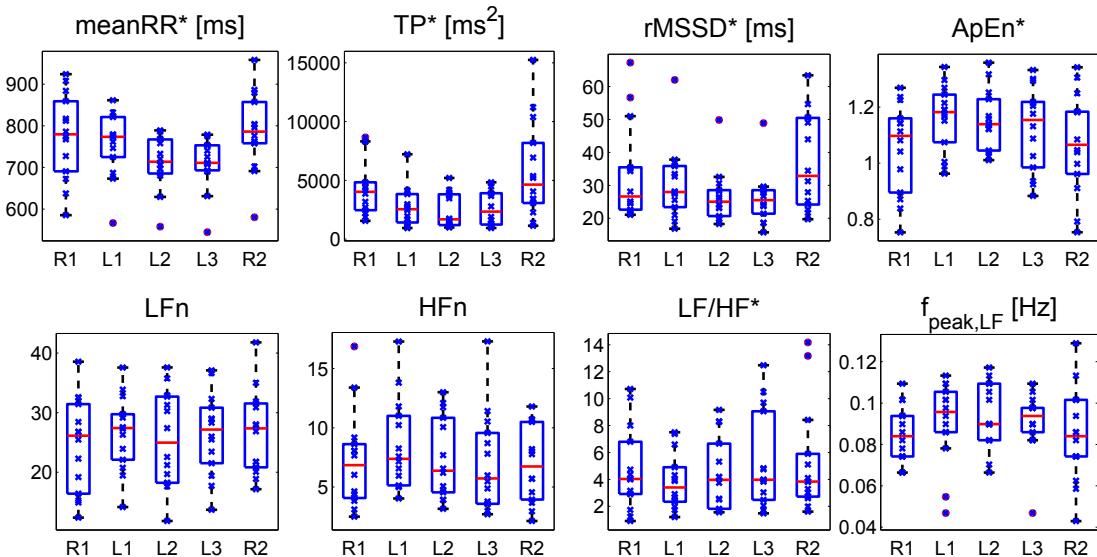


Abb. 6.1. Ergebnisse einiger ausgewählter HRV-Parameter zum Mental-Stress-Test. (R1 und R2 sind die Ruhephasen. L1, L2 und L3 sind die Stress-Level. * Signifikante Veränderung zwischen mindestens 2 Phasen.)

Die WPA-Features, die auf der Basis der Frequenzbänder LF und HF gebildet wurden, verhielten sich sehr ähnlich zu jenen aus dem Welch-Spektrum. Allerdings konnten hier die Parameter $LF_n(WPA)$ und $\frac{LF}{HF}(WPA)$ einen signifikanten Anstieg und $HF_n(WPA)$ einen signifikanten Rückgang zwischen Stress-Level 2 und Stress-Level 3 feststellen. Es gab kein Feature aus der WPA, das signifikante Veränderungen zwischen allen Phasen des Stress-Tests feststellen konnte. Bemerkenswert war jedoch die genauere Betrachtung der normierten Energien der Frequenzbänder 2,3 und 4, die zusammen das übergeordnete Frequenzband LF bilden (Abb. 6.2). Im Frequenzband 2 (0.0375 Hz - 0.075 Hz) konnte ein signifikanter Rückgang von En_2 zwischen Ruhephase 1 und Stress-Level 1 festgestellt werden. Generell konnten unter allen HRV-Parametern die Parameter des 2. Frequenzbandes, allen voran der Parameter $iqr\ 9010_2$, die signifikantesten Veränderungen zwischen der Ruhephase 1 und Stress-Level 1 feststellen. Im Frequenzband 3 (0.075 Hz - 0.1125 Hz) konnte ein leichter jedoch nicht signifikanter Anstieg von En_3 beobachtet werden. Der Anstieg von En_4 im Frequenzband 4 (0.1125 Hz - 0.15 Hz) war dagegen signifikant. Daraus lässt sich bereits folgern, dass eine differenziertere Betrachtung der Spektren nötig ist als die einfache Zerlegung in LF und HF .

Als nächstes betrachten wir die Zeit-Frequenz-Ebenen der verschiedenen Phasen des Stress-Tests. In Abb. 6.3 sind für einen Probanden die Zeit-Frequenz-Ebenen aus der ersten Ruhephase und dem Stress-Level 2 dargestellt. Während der Ruhephasen war hier ein sehr unregelmäßiges Verhalten zu erkennen. Es gab in den Bändern zwischen 0.0375 Hz und 0.3 Hz hin und wieder lokale Maxima in den Amplituden, jedoch keine klar dominierenden Frequenzbänder. Dies änderte sich jedoch während der Stress-Level. Man

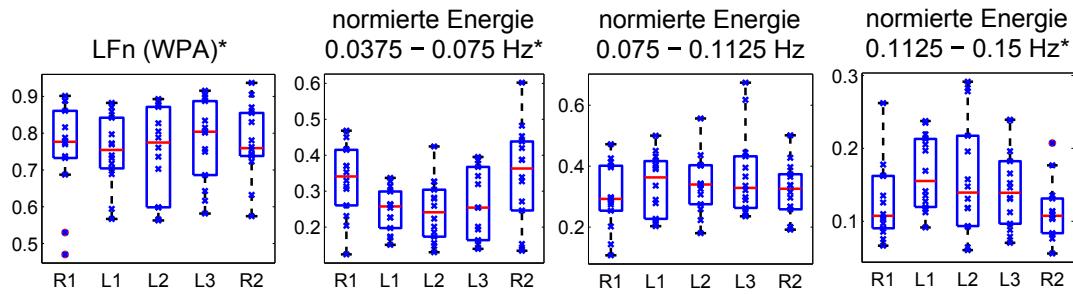


Abb. 6.2. Vergleich der normierten Energien LFn (WPA) mit den 3 dazugehörenden Frequenzbändern aus der WPA. (R1 und R2 sind die Ruhephasen. L1, L2 und L3 sind die Stress-Level. * Signifikante Veränderung zwischen mindestens 2 Phasen.)

konnte hier für die Frequenzbänder 3 (0.075 Hz - 0.1125 Hz) und 4 (0.1125 Hz - 0.15 Hz) immer wiederkehrende lokale Maxima erkennen. Die beiden Bänder um die Frequenz von 0.1 Hz herum dominierten. Aus den Leistungsdichtespektren ist das Maximum bei 0.1 Hz sehr bekannt. In der Literatur wird hierzu die Aktivität des Baroreflexes genannt, der für die Regelung des Blutdrucks verantwortlich ist [Stein & Kleiger, 1999]. Als weitere physiologische Ursache wird außerdem die Regelung des Blutflusses durch die Kontraktion bestimmter Blutgefäße genannt. Diese Hypothese konnte unter anderem durch eine Untersuchung von Kvernmo et al. gestützt werden [Kvernmo et al., 1998]. Allerdings würde man für diese Ursachen eine relativ konstante Amplitude in den beiden Frequenzbändern 3 und 4 erwarten, was jedoch nicht der Fall war.

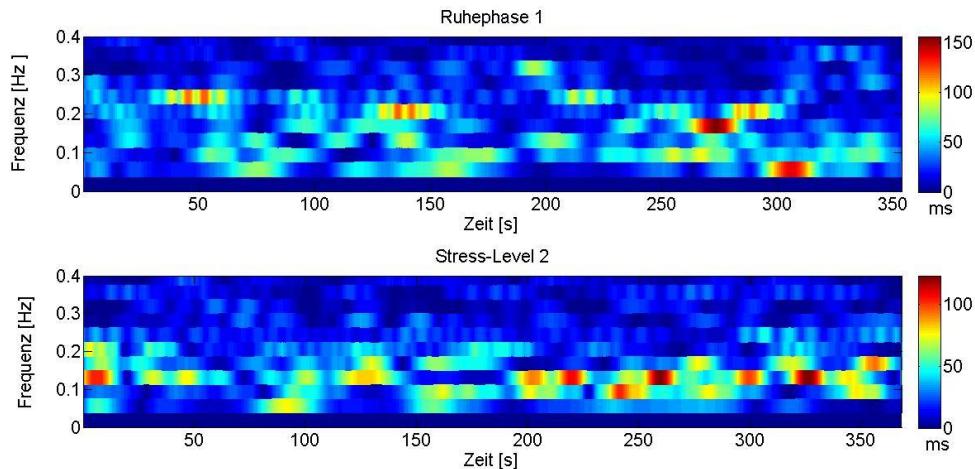


Abb. 6.3. Vergleich der Zeit-Frequenz-Ebenen zwischen Ruhephase und Stress-Level 2. In der Ruhephase ist kein dominierendes Frequenzband zu sehen. Im Stress-Level 2 liegen die lokalen Maxima in den Frequenzbändern 3 und 4 um die 0.1 Hz herum.

Als eine weitere mögliche Ursache kam nun auch die Spurwechsel-Frequenz während der Fahrsimulation in Betracht. Wie in Abschnitt 4.1 bereits beschrieben wurde, mussten die Probanden bei jedem Schild im Abstand von 8.7 s die Spur wechseln, was einer Spurwechsel-Frequenz von 0.115 Hz entspricht. Um zu untersuchen, ob die Herzrate bzw. die RR-Zeitreihe vom regelmäßigen Spurwechsel moduliert wird, wurde der Mental-

Stress-Test für einen Probanden ein weiteres Mal durchgeführt. Beim zweiten Experiment wurde dabei mit einer höheren Geschwindigkeit von 88 km/h gefahren. Dies führte zu einer Spurwechsel-Frequenz von 0.168 Hz, was der Mittenfrequenz des Frequenzbandes 5 (0.15 Hz - 0.1875 Hz) entspricht. Die Versuchsdaten beider Experimente sind in Tab. 6.1 nochmal zusammengefasst.

Experiment	Geschwindigkeit	Zeit zwischen den Spurwechseln	Spurwechsel-Frequenz
1	60 km/h	8.7 s	0.115 Hz
2	88 km/h	5.9 s	0.168 Hz

Tabelle 6.1. Parameter der beiden Experimente des Mental-Stress-Tests

Beide Experimente wurden vom gleichen Probanden durchgeführt. Die Ergebnisse der Experimente sind in Abb. 6.4 gegenübergestellt. Während der Ruhephasen war sowohl im Welch-Spektrum als auch im WPA-Spektrum in beiden Experimenten ein Maximum nahe der 0.1 Hz zu erkennen. Während der Stress-Level unterschieden sich die Spektren der beiden Experimente jedoch deutlich. Sowohl das Welch-Spektrum, als auch das WPA-Spektrum wiesen nun Maxima in der Nähe der neuen Spurwechsel-Frequenz von 0.168 Hz auf. Zudem konnte in der Zeit-Frequenz-Ebene das Frequenzband 5 als dominierendes Band identifiziert werden (Abb. 6.5). Dieses Ergebnis zeigt, dass der regelmäßige Spurwechsel die Herzrate direkt moduliert. Ein vergleichbarer Effekt konnte in der Literatur bisher nicht gefunden werden. Dieses Ergebnis lässt auch die Ergebnisse der HRV-Features nochmals in ein anderes Licht rücken. Die HRV-Features konnten besonders signifikante Veränderungen zwischen Ruhephase 1 und Stress-Level 1 feststellen, was ebenfalls durch den Einfluss des Spurwechsels bedingt sein könnte.

Aus der Untersuchung der Morphologie haben sich besonders signifikante Veränderungen in der T-Welle gezeigt. Zwischen der Ruhephase und Stress-Level 1 ergaben sich signifikante Veränderungen bei den Features zur Beschreibung der Amplitude, bei Energie-Features, bei den Features zur Beschreibung von Steigungen und Krümmungen, bei den statistischen Momenten sowie den Symmetrie-Features. Über 10 dieser Features der T-Welle zeigten signifikante Veränderungen in mindestens 2 von 3 Ableitungen. Eine Auswahl solcher Features ist in Abb. 6.6 dargestellt. Dabei sei hier nochmals an die Normierung der Features mit Gl. 5.10 erinnert. Weitere Features wie die Amplitude, Symmetrie-Features, die RT-Zeit und einige statistische Momente zeigten ebenfalls signifikante Veränderungen zwischen den Stress-Levels 1 und 2. Zwischen den Stress-Levels 2 und 3 konnte nur ein Feature (Energie links von T_{peak}) signifikante Veränderungen aufweisen. Für die Interpretation von Veränderungen der Morphologie-Eigenschaften ist es besonders wichtig diese genauer zu untersuchen und nachzuweisen, da die Morphologie durch zahlreiche Einflüsse wie der Atmung oder Bewegungen verändert sein könnte. Daher wurden die T-Wellen der Probanden genauer untersucht. Es wurde für jede Phase des Stress-Tests ein Template gebildet. In den Templates sollten die morphologischen Veränderungen sichtbar gemacht werden. Die Template-Bildung erfolgte erneut wie in Abschnitt 5.2.1 bereits beschrieben wurde. Jedoch wurde die Normierung auf das Maximum der T-Welle nicht durchgeführt. Die Templates von 2 Probanden sind in Abb. 6.7 dargestellt. Man erkennt eine deutliche Abflachung der T-Wellen während der Stress-Level gegenüber den T-Wellen der beiden Ruhephasen. Zwischen den verschiedenen Stress-Levels sind dagegen keine Unterschiede sichtbar. In [Heslegrave & Furedy, 1979] wurde ebenfalls eine Abflachung der T-Welle

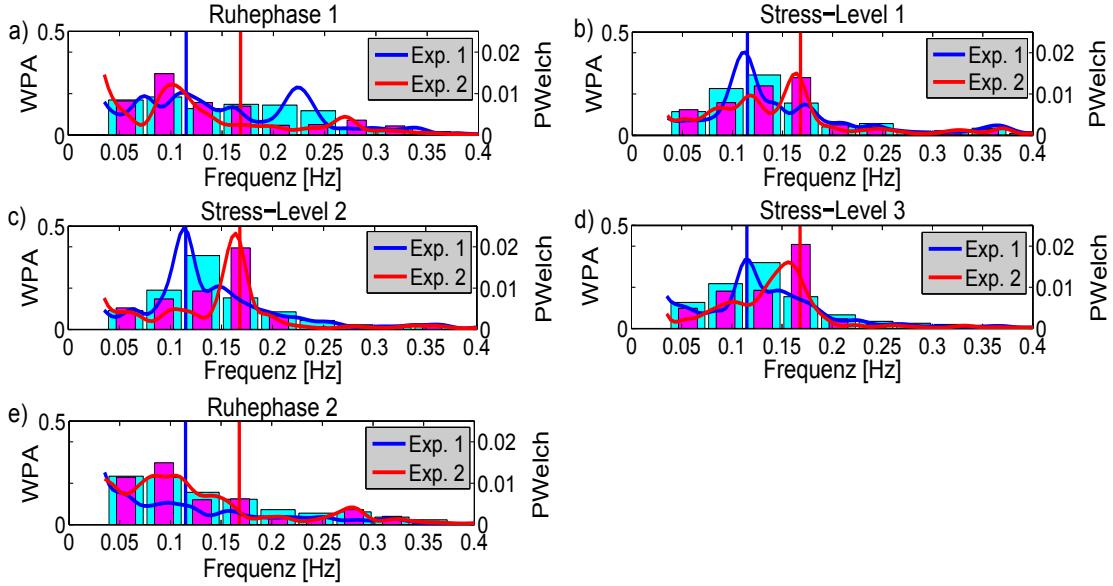


Abb. 6.4. Gegenüberstellung der beiden Experimente zur Untersuchung des Einflusses des Spurwechsels auf die HRV. Die normierten WPA-Spektren aller Phasen sind als Balkendiagramm dargestellt. Die normierten Welch-Spektren sind als Kurven dargestellt. Weiterhin wurden die beiden Spurwechsel-Frequenzen markiert. In den Ruhephasen in a) und e) sind bei beiden Experimenten nur gewöhnliche Maxima bei etwa 0.1 Hz zu sehen. In den Stress-Levels ist im ersten Experiment (blau) ein klares Maximum bei etwa 0.1 Hz zu erkennen. Beim zweiten Experiment (rot) wird dieses Maximum zur Frequenz 0.16 Hz verschoben.

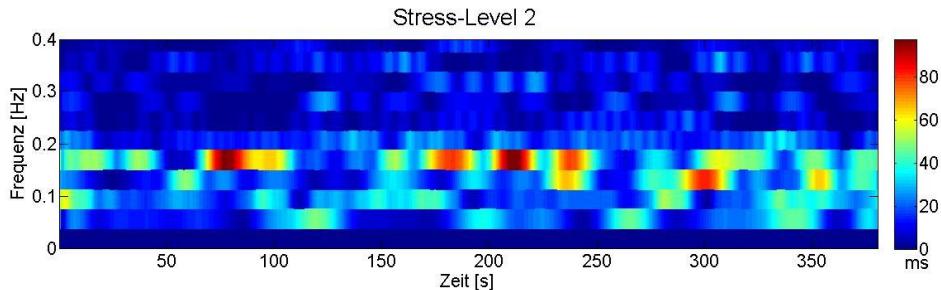


Abb. 6.5. Zeit-Frequenz-Ebene des zweiten Experiments im Stress-Level 2. Das Frequenzband 5 um die 0.16 Hz herum weist die größten Amplituden auf.

während eines Versuchs festgestellt, in dem die Probanden einige Rechenaufgaben lösen mussten. Es wurde angenommen, dass unter kognitiver Belastung der Sympathikus dominiert und somit die Abflachung der T-Welle verursacht. In [von Leupoldt & Ritz, 2008, S. 116] wurde ebenfalls angegeben, dass die Amplitude der T-Welle ein Index für die mentale Belastung sein könnte, da die Abflachung auf der Dominanz des Sympathikus beruht. Da es aus den bisherigen Ergebnissen keine Features gab, die zwischen allen Phasen des Stress-Tests signifikante Veränderungen feststellen konnten, wurde ansatzweise untersucht, ob es möglich ist, eine Untermenge von Parametern zu finden, die gemeinsam in der Lage sind, zwischen den einzelnen Phasen zu unterscheiden. Für diesen Zweck wurde ein Entscheidungsbaum angewendet, wie er in [Menges, 2013] beschrieben wurde. Der Entscheidungsbaum sucht dabei für jedes Feature Schwellwerte der Art, dass eine Phase des Stress-Tests möglichst gut von den anderen Phasen des Tests getrennt werden kann. Ein Maß für den Erfolg der Trennung ist die Reinheit, die hier mit dem Gini-Diversity-Index

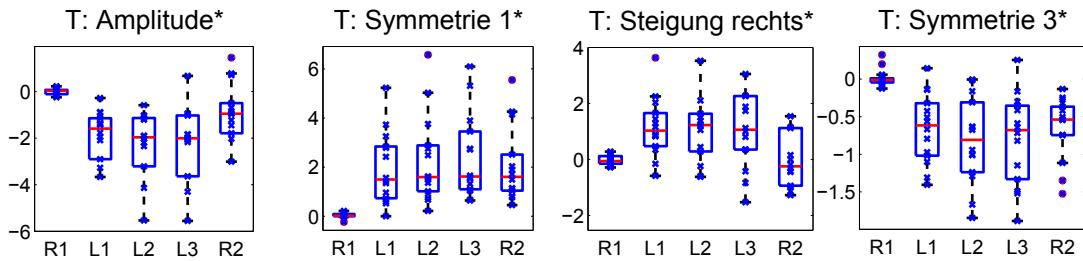


Abb. 6.6. Darstellung ausgewählter Features zur Veränderung der T-Welle während der Stress-Level. Dabei sind die Werte der Features auf die Standardabweichung normierte Werte nach Gl. 5.10. (R1 und R2 sind die Ruhephasen. L1, L2 und L3 sind die Stress-Level. * Signifikante Veränderung zwischen mindestens 2 Phasen.)

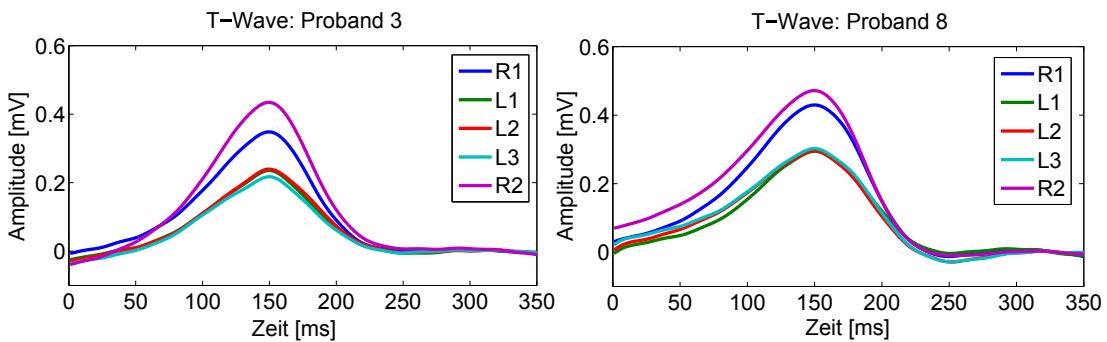


Abb. 6.7. Darstellung der T-Wellen (Templates) aller Phasen von 2 Probanden. Die Abflachung der T-Welle während der Stress-Level ist deutlich zu erkennen. (R1 und R2 sind die Ruhephasen. L1, L2 und L3 sind die Stress-Level.)

berechnet wurde. Der Entscheidungsbaum sollte hier nicht als Klassifikator angesehen werden. Der Entscheidungsbaum besitzt auch keine allgemeine Gültigkeit. Er sollte lediglich zeigen, ob eine Trennung der einzelnen Phasen generell möglich ist. Daher wurde auf eine Kreuzvalidierung verzichtet, sodass die hier generierten Entscheidungsbäume und die ermittelten Trefferquoten auf den Daten aller 14 Probanden basieren. Ein auf diese Weise erzeugter Entscheidungsbaum ist in Abb. 6.8 zu sehen. Dabei wurden in diesem Fall alle Features aus der HRV-Analyse verwendet. Die Trefferquoten des Entscheidungsbäums wurden in Tab. 6.2 aufgelistet. Der gefundene Entscheidungsbaum wies sehr hohe Trefferquoten auf. Erneut konnten besonders die Ruhephasen sehr gut von den Stress-Levels trennen. Das Feature $pRec50_2$ konnte bereits 24 Ruhephasen von 34 Stress-Levels trennen. 16 Ruhephasen wurden dem Knoten $K10$ zugeordnet. 11 von 14 Phasen des Stress-Levels 2 wurden dem Knoten $K6$ zugewiesen. Weiterhin erkennt man, dass 8 der 10 verwendeten Features aus der WPA stammen, die offenbar eine bessere Trennbarkeit der Phasen ermöglichen als die "Standard"-Parameter der HRV. Ähnliche Ergebnisse haben sich für einen Entscheidungsbaum ergeben, der auf Basis der Morphologie-Features und aller HRV-Features erzeugt wurde. Der gefundene Entscheidungsbaum ist in Abb. 6.9 zu sehen. Die Trefferquoten dieses Entscheidungsbäums wurden in Tab. 6.3 aufgelistet. Das oberste Feature hierbei war ein Feature aus der T-Welle. Die maximale Steigung rechts von T_{peak} konnte bereits 26 Ruhephasen von 33 Stress-Levels trennen. 25 von 28 Ruhephasen wurden dem Knoten $K1$ zugewiesen. Weiterhin wurden 9 Phasen vom Stress-Level 2 dem Knoten $K6$ und 9 Phasen vom Stress-Level 3 dem Knoten $K8$ zugewiesen.

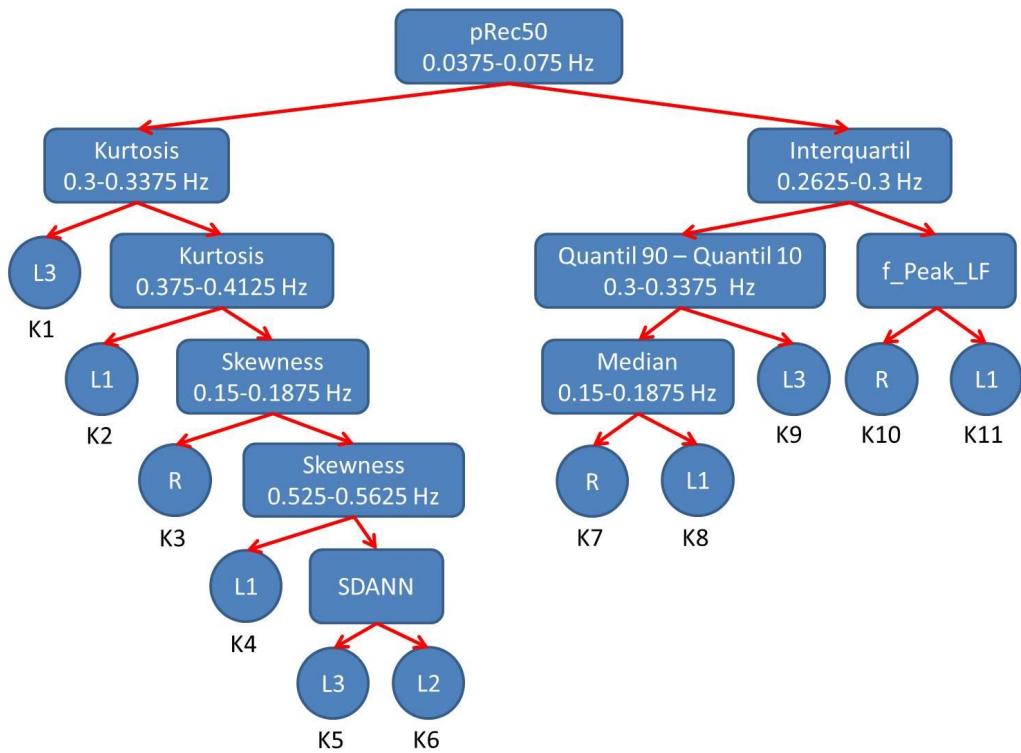


Abb. 6.8. Darstellung des gefundenen Entscheidungsbaums auf der Basis aller HRV-Features. (R: Ruhephase, L1, L2 und L3: Stress-Level.)

Ruhrphase	Stress-Level 1	Stress-Level 2	Stress-Level 3
26/28	13/14	11/14	12/14

Tabelle 6.2. Trefferquoten des Entscheidungsbaums aus Abb. 6.8

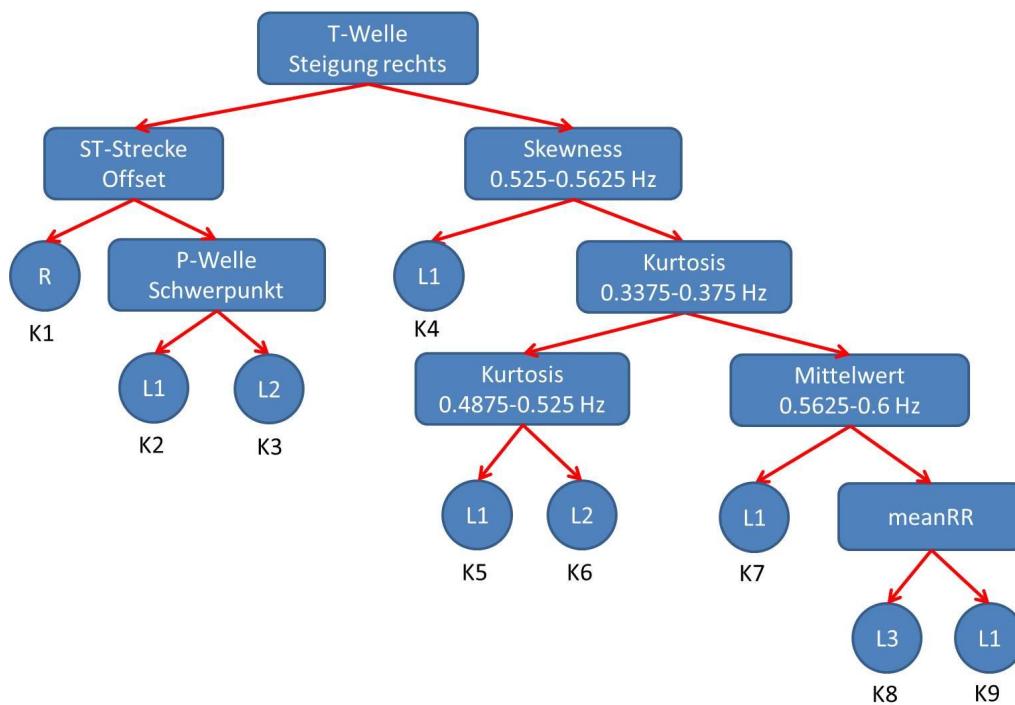


Abb. 6.9. Darstellung des gefundenen Entscheidungsbaums auf der Basis aller Morphologie-Features und aller HRV-Features. (R: Ruhephase, L1, L2 und L3: Stress-Level.)

Ruhrphase	Stress-Level 1	Stress-Level 2	Stress-Level 3
25/28	14/14	12/14	9/14

Tabelle 6.3. Trefferquoten des Entscheidungsbaums aus Abb. 6.9

6.2 Auswertung des MSE-Experiments

Im folgenden Abschnitt werden die Ergebnisse des MSE-Experiments vorgestellt. Für das MSE-Experiment wurde zwischen 3 Arten von Zeitsegmenten unterschieden: den Referenz-Segmenten, den Segmenten vor den MSEs und den Segmenten nach den MSEs. Für den Vergleich der verschiedenen Segmente wurde der Wilcoxon-Rangsummentest verwendet. Es handelt sich dabei um einen nichtparametrischen Signifikanztest, der untersucht, ob sich zwei unabhängige Stichproben in ihrem Median unterscheiden. Die Stichproben können sich dabei in ihrem Umfang unterscheiden. Der Signifikanztest wurde zwischen allen unterschiedlichen Segmenttypen durchgeführt. Veränderungen der Mediane wurden als signifikant bewertet, wenn für die Irrtumswahrscheinlichkeit $p < 0.05$ galt [Büning & Trenkler, 1994, Kapitel 5].

Für das MSE-Experiment wurden Zeitsegmente von 30 s und 120 s Dauer extrahiert. Die 30 s-Segmente sollten eher kurzfristige Veränderungen nahe des MSEs detektieren, während die 120 s-Segmente eher langfristige Veränderungen untersuchen sollten. Bei der Auswertung der Segmente gab es jedoch einige Einschränkungen, die im folgenden erläutert werden. Ein großes Problem war die hohe Dichte der MESs, was dazu führte, dass in einem Zeitsegment mehr als ein MSE auftreten konnte. Dieser Fall wurde als Kollision bezeichnet (Abb. 6.10). Zeitsegmente, in welchen eine Kollision vorkam, wurden bei der Auswertung nicht weiter berücksichtigt, da dadurch eine Charakterisierung der Auswirkungen eines einzelnen MSEs auf die Morphologie und die HRV nicht möglich ist. Im Fall der 120 s-Segmente konnten von 4070 MSE-Segmenten nur 256 Segmente berücksichtigt werden, was nur 6.3 % entspricht. Es konnten also nur etwa 128 MSEs untersucht werden. Im Falle der 30 s-Segmente konnten von 4253 MSE-Segmenten 1963 Segmente berücksichtigt werden, was 46.2 % entspricht. Hier konnten demnach etwa 1000 MSEs untersucht werden. Der Grund für die unterschiedliche Anzahl der MSE-Segmente liegt unter anderem daran, dass auch Zeitsegmente, die über den Beobachtungszeitraum des Signals hinaus gingen, nicht berücksichtigt werden konnten. Für die Referenz-Segmente erhielten wir 70 Segmente im Falle der 120 s-Segmente und 266 Referenz-Segmente im Falle der 30 s-Segmente.

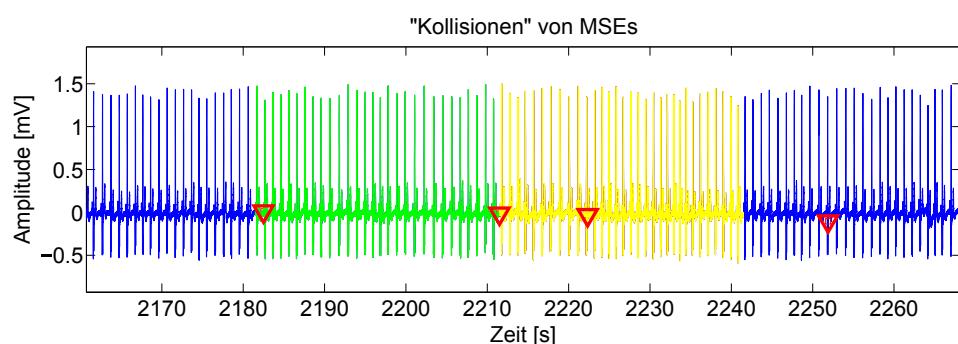


Abb. 6.10. EKG-Signal mit den markierten Zeitsegmenten „vor MSE“ (grün) und „nach MSE“ (gelb) und den Zeitpunkten einiger MSEs (rot). Man erkennt das Problem, dass mehr als ein MSE in ein Zeitsegment fallen kann („Kollision“).

Bei der Auswertung der HRV-Parameter ergaben sich sowohl bei den 120 s- Segmenten als auch bei den 30 s-Segmenten die signifikantesten Veränderungen zwischen den Referenz-Segmenten und den MSE-Segmenten bei Features, die die langsamen Variationen der

RR-Zeitreihe charakterisieren. Die Parameter TP , VLF , $SD2$, $TINN$ und $SDNN$ verzeichneten hier einen signifikanten Anstieg (Abb. 6.11). Dabei verhielten sich die Parameter für die unterschiedlichen Zeitdauern der Segmente recht ähnlich. Der Parameter $SDNN$ stieg beispielsweise bei den 120 s-Segmenten von 51 ms (Referenz) auf 76 ms (vor MSE) bzw. 80 ms (nach MSE). Für die 30 s-Segmente stieg $SDNN$ von 46 ms auf 71 ms bzw. 73 ms an. Dieser Anstieg langsamer Komponenten wurde durch einige WPA-Features des 2. Frequenzbandes (0.0375 Hz - 0.075 Hz) gestützt. Features aus den entsprechenden Koeffizienten wie der Mittelwert, die Energie, die Entropie, die Standardabweichung oder das Quantil $Q_{90,2}$ stiegen signifikant an. Auch das Feature $pRec50_2$ aus den rekonstruierten Signalen des zweiten Frequenzbandes stieg signifikant an. Ein solcher Anstieg der HRV kann mit der zunehmenden Müdigkeit und der damit verbundenen Dominanz des Parasympathikus in Verbindung gebracht werden [Massin et al., 2000].

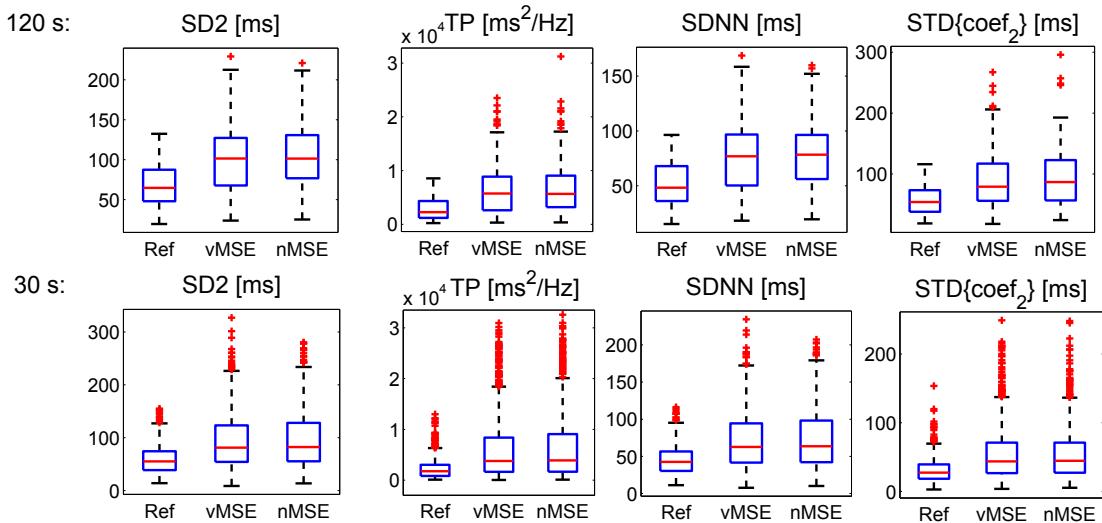


Abb. 6.11. HRV-Parameter für langsame Variationen der RR-Zeitreihe aus dem MSE-Experiment. Alle dargestellten Parameter zeigten signifikante Veränderungen zwischen den Referenz-Segmenten (Ref) und den MSE-Segmenten (vMSE: vor MSE, nMSE: nach MSE, STD: Standardabweichung).

Das mittlere RR-Intervall $meanRR$ stieg für beide Zeitdauern signifikant von 788 ms, was einer Herzrate von 76 bpm entspricht, auf etwa 880 ms, was einer Herzrate von 68 bpm entspricht. Weiterhin zeigten die Parameter für schnelle Variationen einen signifikanten Anstieg. Sowohl für 120 s-Segmente als auch für 30 s-Segmente stiegen $pNN50$, $rMSSD$, $pNN50$ und $SD1$ signifikant an, was ebenfalls für eine erhöhte Aktivität des Parasympathikus spricht (Abb. 6.12).

Im Gegensatz dazu zeigte sich für den Parameter HFn sowohl aus dem WPA-Spektrum als auch aus dem Welch-Spektrum ein Rückgang. LFn stieg dagegen an. Für $\frac{LF}{HF}$ führte dies zu einem signifikanten Anstieg (Abb. 6.13). Generell zeigte sich zwischen den Parametern der WPA und des Welch-Spektrums ein sehr ähnliches Verhalten zwischen den verschiedenen Segmenten. Das wirft die Frage auf, wie gut die Frequenzbereiche LF und HF die Aktivitäten von Sympatikus und Parasympathikus bei kurzen Zeitsegmenten noch wiedergeben. Der Parameter $f_{peak,HF}$, der die Frequenz des lokalen Maximums im HF -Band angibt, lässt noch eine andere Interpretation zu. Die Ursache für ein lokales Maximum im HF -Band ist oft die respiratorische Sinusarrhythmie [Pomeranz et al., 1985].

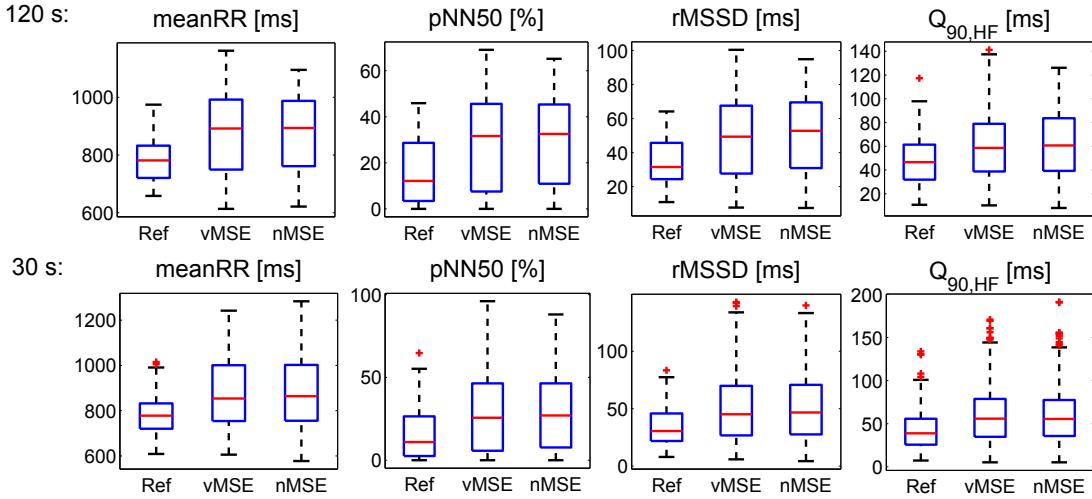


Abb. 6.12. Mittleres RR-Intervall *meanRR* und HRV-Parameter für schnelle Variationen der RR-Zeitreihe aus dem MSE-Experiment. Alle dargestellten Parameter zeigten signifikante Veränderungen zwischen den Referenz-Segmenten (Ref) und den MSE-Segmenten (vMSE: vor MSE, nMSE: nach MSE).

Die Frequenz sank für beide Zeitdauern signifikant von 0.26 Hz auf 0.23 Hz. Möglicherweise ist das ein Anzeichen für die Synchronisation der Herzrate mit der Atemfrequenz, die man während des Schlafens feststellen kann [Cabiddu et al., 2012]. Dies wird noch durch den signifikanten Rückgang der normierten Energien aller Frequenzbänder oberhalb von 0.2625 Hz und der normierten Energie *VHF_n* unterstützt. Diese Veränderungen zwischen den Referenz-Segmenten und den MSE-Segmenten lassen die Hypothese zu, dass die Features vielleicht in der Lage sind, die Müdigkeit der Probanden zu messen. Es gab kein HRV-Feature, dass sowohl für die 120 s-Segmente als auf für die 30 s-Segmente zwischen vor und nach dem MSE signifikante Veränderungen feststellen konnte. Für die 30 s-Segmente konnten 2 Features des Frequenzbandes 3 (0.075 Hz - 0.1125 Hz) und insgesamt 7 Features des Frequenzbandes 13 (0.45 Hz - 0.4875 Hz) sowie *VHF_n* signifikant zwischen vor und nach dem MSE unterscheiden. Bei der bisherigen Betrachtung der dazugehörigen Signale konnte nicht festgestellt werden, ob es sich dabei um eine Information zu den MSEs handelt oder andere Ursachen diese Veränderungen bewirken. Für alle anderen Features gab es keine signifikanten Unterschiede zwischen vor und nach dem MSE.

Die signifikantesten Veränderungen zwischen den Referenz-Segmenten und den MSE-Segmenten zeigten sich in den Morphologie-Eigenschaften *PR*, *RTc* und deren Dispersionsen *PRdisp1* und *RTc-disp1* (Abb.6.14). Aber auch auffällig viele andere Morphologie-Eigenschaften zeigten hier signifikante Veränderungen an. Die Ursache dafür ist in Abb. 6.15 zusehen, in dem das EKG-Signal eines Probanden und die dazugehörigen Zeitreihen *PR* und *RTc* dargestellt sind. Zudem sind die aufgetretenen MSEs eingetragen. Neben den Zeitpunkten der MSEs wurde auch eine Stärke der MSEs auf einer Skala von 1 bis 6 angegeben. Zu Beginn des ersten Durchgangs waren die Zeitreihen sehr stabil. Die PR-Zeit lag bei diesem Beispiel recht konstant bei etwa 164 ms. Dies ist eine grobe Abschätzung der Erregungsüberleitungszeit vom Beginn der Erregung der Vorhöfe bis zur Erregung der Kammern, die sich aus physiologischer Hinsicht nicht verändern sollte. Ähnliches gilt für die *RTc*-Zeit, die eine auf die Herzfrequenz korrigierte Abschätzung der *QT*-Zeit darstellen sollte. Diese lag zu Beginn des ersten Durchgangs bei etwa 272 ms. Mit zunehmender Dauer des Experiments und somit mit zunehmender Müdigkeit konnte am EKG-Signal

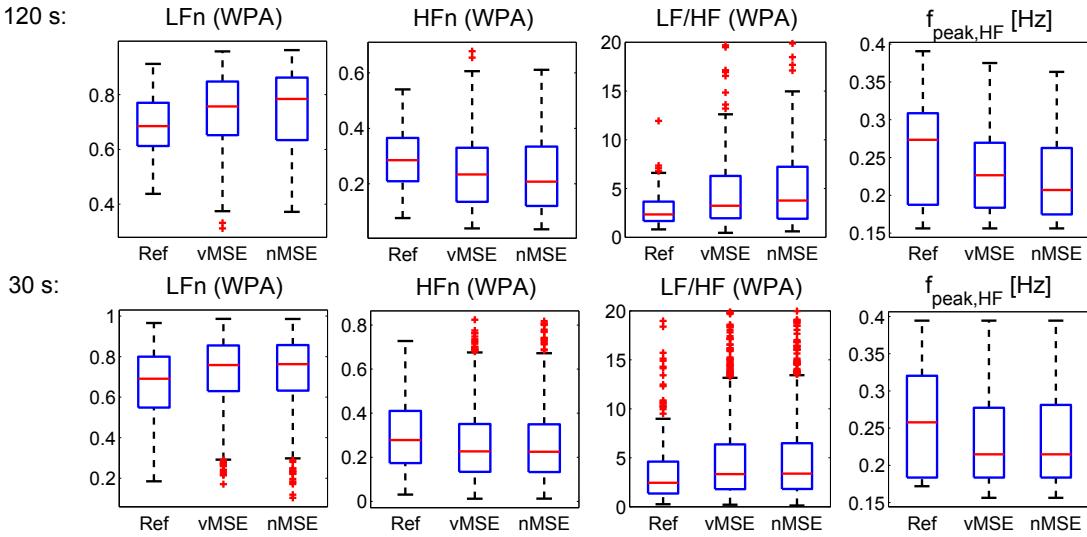


Abb. 6.13. HRV-Parameter aus dem Frequenzbereich aus dem MSE-Experiment. Alle dargestellten Parameter zeigten signifikante Veränderungen zwischen den Referenz-Segmenten (Ref) und den MSE-Segmenten (vMSE: vor MSE, nMSE: nach MSE).

ein erhöhtes Aufkommen von Artefakten festgestellt werden. Diese führten dazu, dass die beiden Zeitreihen einen Wertebereich von über 1000 ms aufwiesen. Ein solcher Wertebereich ist für diese Zeitreihen physiologisch nicht erklärbar. Es konnte festgestellt werden, dass die Ausreißer der Zeitreihen zu den gleichen Zeitpunkten stattfanden wie die Artefakte des EKG-Signals. Zudem erkennt man besonders an den Durchgängen 6 und 7, dass bei häufiger auftretenden MSEs deutlich häufigere und stärkere Artefakte auftraten. Der Grund dafür könnte der bereits im Abschnitt 4.2 beschriebene Effekt sein, dass bei zunehmender Müdigkeit und einsetzendem MSE der Kopf des Probanden sich nach vorne neigt und am Ende des MSEs eine plötzliche Bewegung des Probanden erfolgt. Demnach würden mit zunehmender Müdigkeit im EKG-Signal mehr Bewegungsartefakte auftauchen. Diese Bewegungsartefakte haben zur Folge, dass die Morphologie-Parameter nicht ohne weiteres ausgewertet werden können. Ansonsten zeigten sich bei den Morphologie-Parametern ähnliche Sachverhalte wie bei den HRV-Parametern. Kein Parameter konnte zwischen vor und nach MSE unterscheiden. Die Parameter verhielten sich für die unterschiedlichen Zeittauern sehr ähnlich. Sowohl bei den Parametern der HRV als auch bei den Parametern der Morphologie zeigten sich bei den 30 s-Segmenten deutlich mehr Ausreißer, als das noch bei den Parametern der 120 s-Segmente der Fall war.

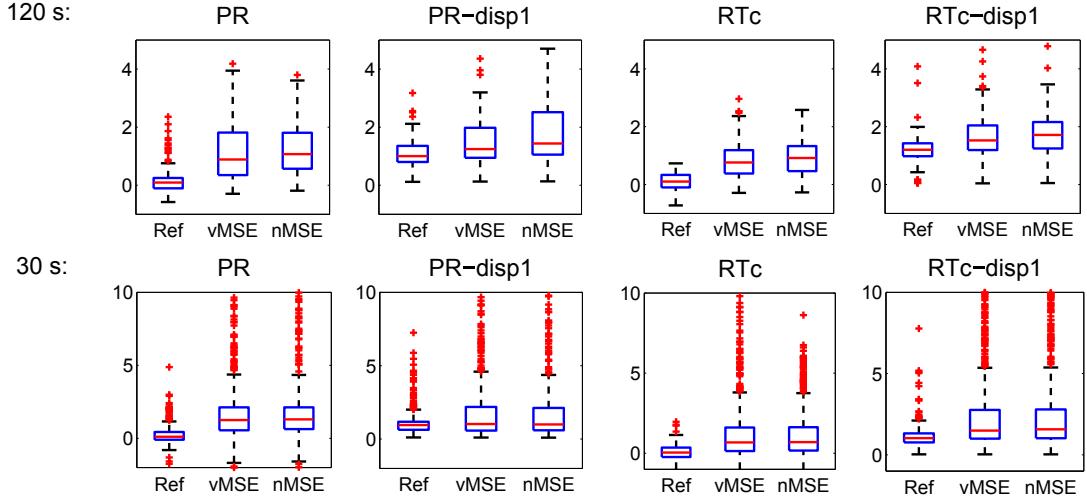


Abb. 6.14. Die Morphologie-Parameter PR , RTc und deren Dispersionen zeigten signifikante Veränderungen zwischend den Referenz-Segmenten (Ref) und den MSE-Segmenten (vMSE: vor MSE, nMSE: nach MSE). Dabei sind die Werte der Parameter auf die Standardabweichung normierte Werte nach Gl. 5.10.

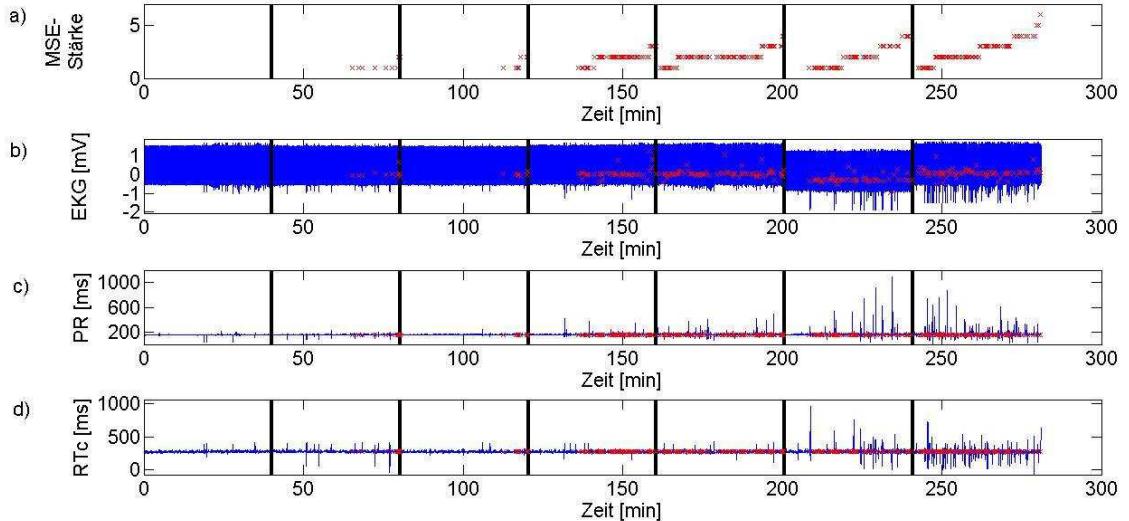


Abb. 6.15. Darstellung der Ursache für die signifikanten Veränderungen der Morphologie-Features. In a) sind die auftretenden MSEs inklusive ihrer Stärke zu sehen. In b) ist das EKG-Signal aller 7 Durchläufe des MSE-Experiments dargestellt. Mit zunehmender Dauer des Experiments nehmen die Artefakte im EKG-Signal zu. In c) ist die Zeitreihe der PR-Zeit und in d) die Zeitreihe der RTc-Zeit zu sehen. Die Ausreißer der beiden Zeitreihen nehmen mit den auftretenden Artefakten und der Dichte der starken MSEs zu.

Zusammenfassung und Ausblick

Im Rahmen dieser Arbeit wurden Methoden der Signalverarbeitung entwickelt, um die Morphologie des EKG-Signals und die HRV anhand der aus dem EKG generierten RR-Zeitreihe zu analysieren. Für die Untersuchung der Morphologie wurden bereits zuvor am IBT entwickelte Methoden verwendet und angepasst, um die verschiedenen Segmente der EKG-Kurve automatisch zu detektieren. Im Anschluss wurden die P-Welle, der QRS-Komplex, die ST-Strecke und die T-Welle extrahiert und analysiert. Dazu wurde das EKG durch das Tiefpassfilter von hochfrequenten Rauschanteilen befreit. Das Hochpassfilter reduzierte den Einfluss durch Baseline-Wander, das unter anderem durch die Atmung erzeugt wird. Gleichzeitig durften die Filter die Morphologie des EKG-Signals nicht zu stark verändern. Anschließend wurden aus Referenz-Segmenten sogenannte Templates gebildet. Beispielsweise handelt es sich bei einem Template des QRS-Komplexes um einen gemittelten QRS-Komplex. Für die P-Welle, den QRS-Komplex, die ST-Strecke und die T-Welle wurden schließlich Features generiert, die die verschiedenen morphologischen Eigenschaften der Segmente charakterisieren. Diese Features wurden mit Hilfe der Features aus den Templates normiert, sodass relative Veränderungen gegenüber den Templates aus den Referenzphasen analysiert werden konnten. Für jede Ableitung wurden auf diese Weise über 100 Features generiert.

Für die auf der RR-Zeitreihe basierende HRV-Analyse wurden zunächst die bereits von Morath implementierten Methoden adaptiert und verwendet [Morath, 2014]. Dabei wurde die RR-Zeitreihe durch ein Filter zunächst von Artefakten befreit. Unter Artefakten versteht man in diesem Fall beispielsweise Extrasystolen. Es wurden dabei aber auch RR-Intervalle entfernt, die kleiner als 300 ms oder größer als 2000 ms waren oder deren aufeinanderfolgende RR-Intervalle mehr als 20 % Abweichung voneinander hatten. Aus der bereinigten RR-Zeitreihe wurden Parameter im Zeit- und im Frequenzbereich generiert, die in der Literatur weit verbreitet sind und zu deren Bestimmung es bereits festgelegte Standards und Empfehlungen gibt [Malik et al., 1996]. Die Parameter im Frequenzbereich wurden dabei mit der Welch-Methode bestimmt. Die verschiedenen Parameter charakterisieren die Variationen der RR-Zeitreihe. Einige Parameter beschreiben eher langsame Variationen der RR-Zeitreihe, wohingegen andere Parameter schnelle Variationen zwischen aufeinanderfolgenden RR-Intervallen beschreiben. Der Anstieg der HRV wird dabei mit einer erhöhten Aktivität des Parasympathikus interpretiert. Umgekehrt wird eine reduzierte HRV mit der dominierenden Aktivität des Sympathikus in Verbindung gebracht. Die HRV-Analyse versucht also die Balance zwischen Sympathikus und Parasympathikus zu beschreiben [Malik et al., 1996]. Die HRV-Analyse wurde schließlich durch die Wavelet Packet Analyse (WPA) ergänzt. Die WPA transformiert die RR-Zeitreihe in ei-

ne Zeit-Frequenz-Darstellung. Da die verschiedenen Frequenz-Parameter LF_n und HF_n vielfach direkt mit den Aktivitäten des vegetativen Nervensystems in Verbindung gebracht werden, erhoffte man sich aus einer Zeit-Frequenz-Darstellung diese Aktivitäten zeitlich aufgelöst messen zu können. Anstatt der zwei Frequenzbänder LF und HF wurden innerhalb der WPA 16 Frequenzbänder betrachtet. Mit Hilfe der WPA wurden sehr viele Features generiert, welche einen genaueren Einblick in die HRV liefern sollten. Insgesamt wurden auf diese Weise über 200 HRV-Features generiert.

Die Methoden zur Analyse der Morphologie und der HRV wurden im Rahmen zweier Studien angewendet. Beim Mental-Stress-Test sollte untersucht werden, ob mentale Beanspruchung während einer Fahrsimulation anhand der EKG-Signale und der RR-Zeitreihe messbar ist. Bei einem Experiment zur Untersuchung von Mikroschlaf-Episoden (MSE) wurde untersucht, welchen Einfluss MSEs auf das EKG und die RR-Zeitreihe haben. Die Ergebnisse der beiden Studien werden in den folgenden Abschnitten nochmals kurz zusammengefasst und diskutiert.

7.1 Mental-Stress-Test

7.1.1 Zusammenfassung und Diskussion der Ergebnisse

Beim Mental-Stress-Test wurde eine Fahrsimulation durchgeführt, in der die Probanden in regelmäßigen Abstand die Fahrspur wechseln mussten. Gleichzeitig wurde den Probanden eine mentale Aufgabe gestellt, in welcher sich die Probanden Zahlen merken und diese wiedergeben mussten. Der Versuch begann mit einer Ruhephase von 15 Minuten. Es folgten 3 Phasen, in welchen die Fahrsimulation durchgeführt wurde. Dabei wurde der Schwierigkeitsgrad der mentalen Aufgabe sukzessive gesteigert. Die 3 Phasen wurden daher mit Stress-Level 1, Stress-Level 2 und Stress-Level 3 bezeichnet. Jede dieser Phasen dauerte 6 Minuten. Schließlich wurde zum Schluss erneut eine Ruhephase durchgeführt. An dem Versuch nahmen insgesamt 14 Personen teil. Für die Untersuchung der EKG-Signale wurden aus allen 5 Phasen Segmente von 6 Minuten Dauer extrahiert. Für die Untersuchung der Morphologie wurde die erste Ruhephase als Referenz verwendet.

Aus der HRV-Analyse zeigte sich ein signifikanter Rückgang der langsamen Variationen der RR-Zeitreihe zwischen der ersten Ruhephase und Stress-Level 1. Insbesondere der Parameter TP , der die gesamte Leistung des Leistungsdichtespektrums angibt, ging signifikant zurück. Dieser Rückgang wurde durch einige Zeit-Parameter und Parametern aus der WPA gestützt. Die schnellen Variationen zeigten eher signifikante Veränderungen zwischen den Stress-Levels 1 und 2. Allerdings war kein HRV-Feature in der Lage, zwischen allen Phasen des Mental-Stress-Tests signifikante Veränderungen festzustellen. Insbesondere die vielversprechenden Parameter LF_n und HF_n konnten nicht zwischen allen Phasen des Stress-Tests unterscheiden. Aus der WPA ging weiterhin hervor, dass die Betrachtung der Frequenzbänder LF und HF nicht ausreicht. Die 3 Frequenzbänder der WPA, die gemeinsam wieder LF bilden, entwickelten sich während der Phasen unterschiedlich, sodass die Veränderungen in LF nur noch schwach sichtbar waren. Weiterhin zeigte sich, dass eine Betrachtung des Leistungsdichtespektrums über ein Zeitsegment von 6 Minuten Dauer zu fehlerhaften Interpretationen führen kann. Zeitliche Veränderungen während des Zeitsegments gehen durch die Integration und Mittelung über die Zeit bei der Generierung des Leistungsdichtespektrums verloren. So hat die Zeit-Frequenz-Ebene aufgezeigt, dass das regelmäßige Lenken mit einer Frequenz von etwa 0.1 Hz während des Versuchs eine Modulation der RR-Zeitreihe mit der Frequenz von 0.1 Hz bewirkt. Dies

wurde durch einen zweiten Versuch bestätigt, in welchem eine Spurwechsel-Frequenz von etwa 0.16 Hz ebenfalls zu einer Modulation der RR-Zeitreihe mit 0.16 Hz führte. Aus der Morphologie wurde weiterhin festgestellt, dass sich die T-Welle während der Stress-Level deutlich veränderte. Gegenüber der Ruhephasen konnte eine Abflachung der T-Welle beobachtet werden.

Aus den Ergebnissen ging hervor, dass die Features in der Lage waren, Veränderungen zwischen den Ruhephasen und den Stress-Leveln festzustellen. Zwischen den einzelnen Stress-Leveln konnten nur einzelne Features unterscheiden. Die Feststellung, dass der regelmäßige Spurwechsel die RR-Zeitreihe moduliert, wirft die Frage auf, ob diese Modulation durch die körperliche Beanspruchung oder durch die mentale Beanspruchung beim Spurwechsel verursacht wird und ob der Einfluss der mentalen Beanspruchung durch die Konzentration auf die genannten Zahlen dadurch überlagert wird. Die signifikanten Veränderungen der Features für langsame Variationen und auch die Abflachung der T-Welle könnten ebenfalls durch den Einfluss des regelmäßigen Spurwechsels verursacht worden sein.

Während einzelne Features offenbar nicht ausreichen, um die mentale Beanspruchung zu messen, wurde in einem ersten Ansatz mit Hilfe von einfachen Entscheidungsbäumen untersucht, ob mehrere Features die Phasen des Mental-Stress-Tests trennen können. Dabei zeigte sich sowohl in einem Baum aus 10 HRV-Parametern als auch in einem Baum aus 3 Morphologie- und 5 HRV-Parametern eine gute Trennbarkeit der einzelnen Phasen. Auch hier konnten die Ruhephasen besonders gut von den Stress-Leveln getrennt werden.

7.1.2 Ausblick

Die Frage, ob mentale Beanspruchung während der Autofahrt anhand von wenigen Parametern gemessen werden kann, kann aus der hier durchgeführten Studie noch nicht abschließend beantwortet werden, da der regelmäßige Spurwechsel die HRV-Features maßgeblich beeinflusst. Unter den Laborbedingungen des Mental-Stress-Test wurde die körperliche Beanspruchung durch die Fahrsimulation eigentlich für gering gehalten. Es stellt sich daher die Frage, ob die signifikanten Veränderungen zwischen Ruhephase und Stress-Level von der körperlichen Beanspruchung herrühren oder ob die Konzentration auf den Spurwechsel und die gleichzeitige Konzentration auf die genannten Zahlen diese Veränderungen verursachen. Die signifikanten Veränderungen einiger Features zwischen den einzelnen Stress-Leveln und die Ergebnisse der Entscheidungsbäume sprechen dafür, dass auch die mentale Beanspruchung einen entscheidenden Einfluss auf die Features haben könnte. Weiterhin kann auch die Abflachung der T-Welle nicht eindeutig auf die körperliche oder die mentale Beanspruchung während des Versuchs zurückgeführt werden. Um diese Frage zu beantworten, wird mit dem IFAB bereits eine weitere Studie geplant. Dabei soll der Test unter den gleichen Bedingungen durchgeführt werden. Als einzige Veränderung wurde angedacht, den Spurwechsel anstatt mit einem Lenkrad durch die Bedienung einer Tastatur durchzuführen. Unter diesen Bedingungen wäre die körperliche Beanspruchung nochmals deutlich geringer. Werden bei diesem Versuch die gleichen Ergebnisse festgestellt, so können diese Veränderungen auf die mentale Beanspruchung zurückgeführt werden. Unter diesen Voraussetzungen könnte man dann weiter untersuchen, welche der Parameter sich am besten für die Messung mentaler Beanspruchung eignen.

Für die reale Anwendung der Messung von Stress während der Autofahrt scheint das EKG als alleinige Beobachtungsgröße nicht auszureichen. Sollte sich herausstellen, dass die körperliche Beanspruchung unter den einfachen Laborbedingungen bereits den domi-

nierenden Einfluss auf das EKG und die HRV hat, so wird die deutlich komplexere körperliche Beanspruchung im realen Straßenverkehr umso mehr den Einfluss der mentalen Beanspruchung überlagern. Zudem wird die Morphologie bei den komplexeren Bewegungen während der realen Autofahrt stark von Bewegungsartefakten beeinflusst, was eine Verwendung der Morphologie-Features aus der T-Welle stark erschwert. Aber auch wenn die mentale Beanspruchung während der Fahrt aus der HRV gemessen werden kann, so kann daraus nicht direkt geschlossen werden, dass die mentale Beanspruchung allein durch Stress verursacht wird. Denn gerade im realen Straßenverkehr ist eine hohe Konzentration auf das gesamte eigene Umfeld notwendig, die sicherlich deutlich höher ist, als bei einem einfachen Spurwechsel unter Laborbedingungen. In diesem Fall könnte jedoch untersucht werden, ob das EKG gemeinsam mit weiteren Beobachtungsgrößen messen kann, ob der Fahrer gestresst ist. Eine parallele Analyse der Lenkbewegungen, die Präzision beim Halten oder Wechseln der Fahrspur oder auch Zitterbewegungen am Lenkrad könnten die Messung von Stress während der Autofahrt weiter stützen.

7.2 MSE-Experiment

7.2.1 Zusammenfassung und Diskussion der Ergebnisse

Beim Experiment zur Untersuchung der MSEs wurde eine Fahrsimulation durchgeführt. Die Gestaltung des Experiments war darauf ausgelegt das Auftreten von MSEs zu provozieren. Die Probanden fuhren zwischen 0 Uhr und 7 Uhr morgens in einem Fahrsimulator auf einer sehr monotonen Straße mit monotoner Landschaft. Die Probanden durften 16 Stunden vor dem Experiment nicht schlafen. Jeder Durchlauf dauerte dabei 40 Minuten. Während des Experiments wurden zahlreiche Messgrößen erfasst um zu entscheiden, wann MSEs aufgetreten sein könnten. Ein Klassifikator entschied dann, ob es sich um ein MSE gehandelt hat oder nicht. Zur Anwendung der in dieser Arbeit verwendeten Methoden wurden uns die aufgezeichneten EKG-Signale und die Zeitpunkte der aufgetretenen MSEs von 14 Probanden zur Verfügung gestellt. Für die Auswertung wurden Zeitsegmente vor und nach einem MSE aus dem EKG extrahiert. Die Dauer der Segmente betrug in einem ersten Schritt 120s und im zweiten Schritt 30s. Als Referenz-Segmente wurden in den ersten 20 Minuten des ersten Durchlaufs Segmente extrahiert, in welchen keine MSEs aufgetreten sind.

Bei der Auswertung der Ergebnisse kam es zu dem Problem, dass mehrere MSEs in das gleiche Zeitsegment fallen konnten. Diese Segmente konnten hier nicht weiter berücksichtigt werden. Aus der Analyse der HRV-Features zeigten sich signifikante Veränderungen der Features für langsame Variationen der RR-Zeitreihe zwischen den Referenz-Segmenten und den MSE-Segmenten. Besonders das Feature *TP* konnte hier einen signifikanten Anstieg aufzeigen. Weiterhin konnten auch die Parameter für schnelle Variationen zwischen aufeinanderfolgenden RR-Intervallen wie *rMSSD* einen signifikanten Anstieg zwischen den Referenz-Segmenten und den MSE-Segmenten feststellen. Diese Ergebnisse wurden durch einige Features aus entsprechenden Frequenzbändern der WPA noch unterstützt. Aus diesem Anstieg der HRV lässt sich eine erhöhte Aktivität des Parasympathikus während der MSE-Segmente ablesen [Malik et al., 1996]. Betrachtet man jedoch die Frequenz-Parameter *LFn* und *HFn*, die in der Literatur häufig direkt mit den Aktivitäten des vegetativen Nervensystems in Verbindung gebracht werden, so stellt man hier ein widersprüchliches Verhalten fest. *HFn*, der häufig als Parameter für die Aktivität des Parasympathikus verwendet wird, ging signifikant zurück, obwohl die Parameter aus dem

Zeitbereich wie $rMSSD$ anstiegen. Für die Messung der Aktivität des Sympathikus wird häufig der Parameter LFn verwendet, der hier ebenfalls anstieg. Dies widerspricht ebenfalls dem Anstieg der HRV. Das Verhalten der Parameter in den Frequenzbändern LF und HF war bei der Welch-Methode und bei der WPA sehr ähnlich. Es zeigten sich auch ähnliche Ergebnisse zwischen den verschiedenen Zeitdauern der Segmente. Dies lässt vermuten, dass die Methoden diese Parameter richtig schätzen. Eine mögliche mathematische Erklärung für dieses widersprüchliche Verhalten zwischen den Zeit- und Frequenz-Parametern könnte der Anstieg der Amplituden der in der RR-Zeitreihe enthaltenen Frequenzkomponenten sein, der sich auch aus einigen Parametern der WPA, wie beispielsweise $pRec50_{LF}$, feststellen lässt. Wie bereits angedeutet wurde, wird die Schätzung von LF für kurze Zeitsegmente nicht empfohlen. Aus diesen Beobachtungen lässt sich schließen, dass aus den Parametern LFn und HFn für das hier durchgeführte Experiment keine verlässlichen Aussagen über die Aktivitäten von Sympathikus und Parasympathikus getroffen werden können. Hierfür sollten die Parameter aus dem Zeitbereich und die Features einzelner Frequenzbänder aus der WPA verwendet werden. Insbesondere der Parameter TP könnte ein verlässlicher Parameter für die HRV sein. Der Anstieg der HRV und die damit verbundene erhöhte Aktivität des Parasympathikus in den MSE-Segmenten könnte mit der zunehmenden Müdigkeit der Probanden zusammenhängen [Massin et al., 2000]. Die signifikante Verschiebung des Maximums im HF -Band, die anhand der Frequenz $f_{peak,HF}$ und dem Rückgang der Energien der Frequenzbänder oberhalb von $f_{peak,HF}$ festgestellt wurde, könnte mit der Synchronisation der Atmung während zunehmender Müdigkeit in Zusammenhang stehen [Cabiddu et al., 2012]. Dies weist darauf hin, dass mit den hier verwendeten Parametern Müdigkeit gemessen werden kann. Da weiterhin das lokale Maximum im HF -Band durch den atmungsabhängigen Einfluss des Parasympathikus bewirkt wird, könnte eine Messung der Leistung bzw. der Energie dieses lokalen Maximums ein verlässlicherer Parameter zur Messung der Aktivität des Parasympathikus sein als HFn . Aus den Ergebnissen konnten keine charakteristischen Veränderungen zwischen den Segmenten vor den MSEs und nach den MSEs festgestellt werden. Die Features zeigten hier weitestgehend identische Ergebnisse. Der Grund dafür könnte sein, dass die Unsicherheit über den tatsächlichen Zeitpunkt eines MSEs zu groß ist. Die Unterscheidung in Segmente vor und nach dem MSE macht in diesem Fall keinen Sinn mehr.

Ein kritischer Punkt bei der Generierung der Features war die Verwendung von kurzen Zeitsegmenten von 30 s. Die meisten Features konnten zunächst noch mathematisch berechnet werden. Jedoch musste die Verlässlichkeit der einzelnen Features in Frage gestellt werden, was hier bereits durch die Diskussion der Frequenz-Parameter gezeigt wurde. Die Features verhielten sich für die verschiedenen Zeitdauern von 30 s und 120 s visuell sehr ähnlich. Bei den 30 s konnte jedoch ein deutlich erhöhtes Auftreten von Ausreißern beobachtet werden. Die Robustheit der Features ist demnach für diese Zeitsegmente in Frage zu stellen und muss für jedes Feature separat betrachtet werden.

Bei der Untersuchung der Morphologie-Features stellte sich heraus, dass diese zu stark von Bewegungsartefakten beeinflusst sein könnten. Die Zunahme der Bewegungsartefakte könnte mit der Zunahme der MSEs zusammenhängen. Bei der Durchführung des Experiments wurde auch das Phänomen beobachtet, dass das Ende eines MSEs häufig mit einer ruckartigen Bewegungen des Probanden einhergeht. Auf Grund der Bewegungsartefakte können die Features der Morphologie nicht ohne weiteres ausgewertet werden.

7.2.2 Ausblick

Eine direkte Detektion von MSEs während der Autofahrt auf Basis des EKGs erscheint nach den Erkenntnissen dieser Arbeit sehr schwierig. Die Bewegungsartefakte, die während der Autofahrt deutlich stärker auftreten, als das unter Laborbedingungen der Fall ist, lassen eine Auswertung der Morphologie nicht zu. Die Unsicherheit über das zeitliche Auftreten der MSEs verhindert eine Charakterisierung der MSEs mit Hilfe der HRV-Analyse. Weiterhin nimmt die Robustheit der Methoden der HRV-Analyse mit der kürzer werdenenden Beobachtungsdauer ab. Eine genaue Detektion der MSEs während der Autofahrt verlangt Echtzeit-Anforderungen, die die HRV-Analyse vielleicht nicht erfüllen kann. Die benötigte Beobachtungsdauer für die Generierung der HRV-Features ist in der Literatur sehr umstritten. Daher könnte eine Untersuchung der HRV-Features zeigen, für welche Beobachtungsdauern die einzelnen Features noch verlässliche Ergebnisse liefern. Die Ergebnisse haben jedoch auch gezeigt, dass mit den HRV-Parametern möglicherweise die Müdigkeit der Fahrer gemessen werden kann. Um dies nachzuweisen, wäre eine andere Strategie zur Analyse der Parameter notwendig. Eine Untersuchung der zeitlichen Entwicklung der HRV-Parameter könnte hier weiterhelfen. Aus einer solchen Untersuchung könnte hervorgehen, dass einige HRV-Parameter mit dem Auftreten der MSEs korrelieren. Zudem könnte ein Abgleich mit weiteren Messgrößen aus dem MSE-Experiment und den Ergebnissen der Wachsamkeitstests nachweisen, ob die HRV-Parameter die Müdigkeit robust messen können. Somit könnte aus den HRV-Parametern zumindest eine Wahrscheinlichkeit für das Auftreten von MSEs angegeben werden.

A

Liste der HRV-Parameter

Im Folgenden werden die in der Literatur häufig verwendeten HRV-Parameter kurz beschrieben. Dabei wird unter $E\{\cdot\}$ der Mittelwert und unter $STD\{\cdot\}$ die Standardabweichung verstanden. Für detailliertere Beschreibungen der Parameter sei auf [Morath, 2014], [Malik et al., 1996] und [Rajendra Acharya et al., 2006] verwiesen.

meanRR: Mittelwert aller RR-Intervalle

$$meanRR = \sum_{i=1}^N RR(i) = E\{RR\} \quad (A.1)$$

SDNN: Standardabweichung aus allen RR-Intervallen

$$SDNN = \frac{1}{N-1} \sum_{i=1}^N RR(i) = STD\{RR\} \quad (A.2)$$

SDANN: Standardabweichung aller Mittelwerte der RR-Intervalle aus Zeitsegmenten der Dauer Δt

$$SDANN = STD \left\{ \underbrace{E\{RR\}}_{\text{für } \Delta t} \right\} \quad (A.3)$$

SDNN index: Mittelwert aller Standardabweichungen der RR-Intervalle aus Zeitsegmenten der Dauer Δt

$$SDNN_index = E \left\{ \underbrace{STD\{RR\}}_{\text{für } \Delta t} \right\} \quad (A.4)$$

rMSSD: Quadratisches Mittel der Differenzen aufeinanderfolgender RR-Intervalle

$$rMSSD = \sqrt{\frac{1}{N} \sum_{j=1}^N \Delta RR_j^2} = \sqrt{E\{\Delta RR^2\}} \quad (A.5)$$

mit

$$\Delta RR_j = RR(i+1) - RR(i) \quad (\text{A.6})$$

SDSD: Standardabweichung aller Differenzen aufeinanderfolgender RR-Intervalle

$$SDSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^N [\Delta RR_i - E\{\Delta RR\}]^2} \quad (\text{A.7})$$

pNN20 und pNN50: prozentualer Anteil der Differenzen aufeinanderfolgender RR-Intervalle, die größer als 20 ms bzw. 50 ms sind

$$pNN20 = \frac{\sum_{i=1}^N (|\Delta RR_i| > 20 \text{ ms})}{N} \cdot 100 \% \quad (\text{A.8})$$

$$pNN50 = \frac{\sum_{i=1}^N (|\Delta RR_i| > 50 \text{ ms})}{N} \cdot 100 \% \quad (\text{A.9})$$

HRV triangular index: Der Parameter wird aus dem Histogramm der RR-Intervalle bestimmt. Aus einer Zeitreihe von N RR-Intervallen erhält man

$$HRV \text{ triangular index} = \frac{N}{\max(\text{Histogramm})}, \quad (\text{A.10})$$

wobei $\max(\text{Histogramm})$ das Maximum des Histogramms, also der Modalwert, ist. Damit ist $HRV \text{ triangular index}$ der Kehrwert der relativen Häufigkeit des am häufigsten vorkommenden RR-Intervalls.

TINN: Der Parameter wird aus dem Histogramm der RR-Intervalle bestimmt. Dabei wird das Histogramm links und rechts vom Modalwert jeweils mit einer Geraden approximiert. Der Abstand der beiden Nullstellen dieser Geraden stellen die “Basislänge” $TINN$ des Histogramms dar.

SD1: Der Parameter wird aus dem Poincaré-Plot der RR-Intervalle bestimmt. $SD1$ ist die Standardabweichung der Punkte $[RR(i), RR(i+1)]$ von der Geraden $y = x$. Es gilt weiterhin:

$$SD1 = \frac{SDSD}{\sqrt{2}}. \quad (\text{A.11})$$

SD2: Der Parameter wird aus dem Poincaré-Plot der RR-Intervalle bestimmt. $SD2$ ist die Standardabweichung der Punkte $[RR(i), RR(i+1)]$ von der Geraden $y = -x + 2 \cdot E\{RR\}$. Es gilt weiterhin:

$$SD2 = \sqrt{2SDNN^2 - \frac{1}{2}SDSD^2}. \quad (\text{A.12})$$

SD1/SD2: Aus $SD1$ und $SD2$ wird das Verhältnis $\frac{SD1}{SD2}$ als Parameter verwendet.

ApEn: Die Approximate Entropy $ApEn$ ist ein nichtlinearer Parameter, der ein Maß für die Irregularität oder Komplexität der RR-Zeitreihe angibt. Höhere Werte von $ApEn$ werden mit einer höheren Irregularität der Zeitreihe assoziiert.

SampEn: Die Sample Entropy $SampEn$ ist ein nichtlinearer Parameter, der ein Maß für die Irregularität oder Komplexität der RR-Zeitreihe angibt. Höhere Werte von

SampEn werden mit einer höheren Irregularität der Zeitreihe assoziiert. *SampEn* ist eine modifizierte Variante von *ApEn*.

DFA: Bei der Detrended Fluctuation Analysis wird die Rauigkeit der RR-Zeitreihe untersucht. Dabei wird der Trend der RR-Zeitreihe entfernt und anschließend die Variabilität bzw. die Fluktuation der RR-Zeitreihe innerhalb von Zeifenstern verschiedener Länge analysiert. Daraus werden die Parameter α_1 für kurze Zeitfenster und α_2 für lange Zeitfenster bestimmt. Höhere Werte für α_1 und α_2 werden mit einer “glatteren” RR-Zeitreihe assoziiert.

TP: gesamte Leistung aus der PSD der RR-Zeitreihe

$$TP = \int_{0 \text{ Hz}}^{\infty} PSD(f) df \quad (\text{A.13})$$

VLF: Leistung im Frequenzbereich unterhalb von 0.04 Hz

$$VLF = \int_{0 \text{ Hz}}^{0.04 \text{ Hz}} PSD(f) df \quad (\text{A.14})$$

LF: Leistung im Frequenzbereich zwischen 0.04 Hz und 0.15 Hz

$$LF = \int_{0.04 \text{ Hz}}^{0.15 \text{ Hz}} PSD(f) df \quad (\text{A.15})$$

LFn: normierte Leistung im Frequenzbereich zwischen 0.04 Hz und 0.15 Hz

$$LFn = \frac{LF}{TP - VLF} \quad (\text{A.16})$$

HF: Leistung im Frequenzbereich zwischen 0.15 Hz und 0.4 Hz

$$HF = \int_{0.15 \text{ Hz}}^{0.4 \text{ Hz}} PSD(f) df \quad (\text{A.17})$$

HFn: normierte Leistung im Frequenzbereich zwischen 0.15 Hz und 0.4 Hz

$$HFn = \frac{HF}{TP - VLF} \quad (\text{A.18})$$

LF/HF: Aus *LF* und *HF* wird das Verhältnis $\frac{LF}{HF}$ als Parameter verwendet.

B

Liste der Features aus dem QRS-Komplex

Feature	Beschreibung des Features
Q1	Minimum der Amplitude
Q2	Maximum der Amplitude
Q3	Minimum der ersten Ableitung
Q4	Maximum der ersten Ableitung
Q5	Minimum der zweiten Ableitung
Q6	Maximum der zweiten Ableitung
Q7	Integral über den gesamten QRS-Komplex
Q8	Integral über die positiven Anteile des QRS-Komplexes
Q9	Integral über die negativen Anteile des QRS-Komplexes
Q10	Energie des gesamten QRS-Komplexes
Q11	Linearer Korrelationskoeffizient zwischen dem QRS-Komplex und dem Template der QRS-Komplexe
Q12	Minimum der Kreuzkorrelationsfunktion zwischen dem QRS-Komplex und dem Template der QRS-Komplexe
Q13	Maximum der Kreuzkorrelationsfunktion zwischen dem QRS-Komplex und dem Template der QRS-Komplexe
Q14	Schwerpunkt (QRS-Komplex als Wahrscheinlichkeitsdichtefunktion)
Q15	Varianz (QRS-Komplex als Wahrscheinlichkeitsdichtefunktion)
Q16	Skewness (QRS-Komplex als Wahrscheinlichkeitsdichtefunktion)
Q17	Kurtosis (QRS-Komplex als Wahrscheinlichkeitsdichtefunktion)
Q18	Maximum des Betrags der FFT des QRS-Komplexes zwischen 5 Hz und 10 Hz
Q19	Mittelwert des Betrags der FFT des QRS-Komplexes zwischen 10 Hz und 20 Hz
Q20	Maximum des Betrags der FFT des QRS-Komplexes zwischen 20 Hz und 50 Hz

Tabelle B.1. Auflistung der Features aus dem QRS-Komplex (Teil 1). Genauere Beschreibungen der Features finden sich in [Lenis et al., 2012] und [Menges, 2013].

Q21	Schwerpunkt des “Aktivitätsintervalls” (basierend auf den Hermiteschen Basisfunktionen und einer Wavelet-Transformation)
Q22	Varianz des “Aktivitätsintervalls” (basierend auf den Hermiteschen Basisfunktionen und einer Wavelet-Transformation)
Q23	Erster Koeffizient der Linearkombination der Hermiteschen Basisfunktionen
Q24	Zweiter Koeffizient der Linearkombination der Hermiteschen Basisfunktionen
Q25	Dritter Koeffizient der Linearkombination der Hermiteschen Basisfunktionen
Q26	Median der Amplitudenverteilung des QRS-Komplexes
Q27	Varianz der Amplitudenverteilung des QRS-Komplexes
Q28	Skewness der Amplitudenverteilung des QRS-Komplexes
Q29	Kurtosis der Amplitudenverteilung des QRS-Komplexes
Q30	Maximale relative Häufigkeit aus einem Histogramm der Amplitudenverteilung des QRS-Komplexes
Q31	Klasse der maximalen relativen Häufigkeit im Histogramm der Amplitudenverteilung des QRS-Komplexes

Tabelle B.2. Auflistung der Features aus dem QRS-Komplex (Teil 2). Genauere Beschreibungen der Features finden sich in [Lenis et al., 2012] und [Menges, 2013].

Abbildungsverzeichnis

2.1	Anatomischer Aufbau des Herzens	4
2.2	Erregungsleitungssystem des Herzens	5
2.3	Potentialverläufe der Schrittmacherzellen und der Herzmuskelzellen	6
2.4	Erregungsausbreitung und Entstehung der EKG-Kurve	7
2.5	Bezeichnungen der einzelnen Abschnitte der EKG-Kurve	8
2.6	Periodische Wiederholung des Spektrums durch die Zeitdiskretisierung	13
2.7	Realisierung der DWT als Filterbank	19
2.8	Signalrekonstruktion bei der DWT als Filterbank	19
2.9	Illustration der WPA im Frequenzbereich	20
2.10	Darstellung der WPA-Struktur in Form des WPA-Baums	21
2.11	Darstellung der Zeit-Frequenz-Ebene der WPA	21
4.1	Fahrimulator des Mental-Stress-Tests	29
4.2	Darstellung des Mental-Stress-Tests	30
4.3	Zeitlicher Ablauf des Mental-Stress-Tests	31
4.4	Fahrimulator des MSE-Experiments	31
4.5	Zeitlicher Ablauf des MSE-Experiments	32
4.6	EKG-Signal mit MSE-Label	33
4.7	Definition der Zeitsegmente des MSE-Experiments	33
5.1	Darstellung der Prozessierung des EKG-Signals	36
5.2	EKG-Signal nach Detektion der P-Welle, des QRS-Komplexes und der T-Welle	36
5.3	EKG-Signale nach der Filterung für die Untersuchung der Morphologie	37
5.4	Auswahlstufen bei der Template-Bildung	38
5.5	Poincaré-Plot für die Template-Bildung	39
5.6	Template des QRS-Komplexes	40
5.7	Template der T-Welle	41
5.8	Template der ST-Strecke	43
5.9	Algorithmus zur Generierung von Templates und Features aus der P-Welle	44
5.10	Template der P-Welle	44
5.11	Generierung der RR-Zeitreihe aus dem EKG-Signal	46
5.12	Algorithmus zur Generierung des Welch-Spektrums aus der RR-Zeitreihe	48
5.13	Beispiel einer mit der Welch-Methode bestimmten PSD	48
5.14	Modifikation des Welch-Spektrums durch periodische Wiederholung der RR-Zeitreihe	50

5.15 Algorithmus zur Feature-Generierung mit Hilfe der WPA.	51
5.16 Darstellung des Symlet 12	52
5.17 Darstellung des verwendeten WPA-Baums.	53
5.18 Demonstration der WPA anhand eines synthetischen Signals.	54
5.19 Qualitativer Vergleich der normierten Spektren aus der Welch-Methode und aus der WPA	56
5.20 Signalrekonstruktion der RR-Zeitreihe.	57
5.21 Qualitativer Vergleich des Welch-Spektrums mit dem WPA-Spektrum für ein 30 s-Segment der RR-Zeitreihe.....	58
6.1 Ergebnisse einiger ausgewählter HRV-Parameter zum Mental-Stress-Test...	60
6.2 Vergleich der normierten Energien LFn (WPA) mit den 3 dazugehörigen Frequenzbändern aus der WPA.	61
6.3 Vergleich der Zeit-Frequenz-Ebenen zwischen Ruhephase und Stress-Level 2.	61
6.4 Auswirkungen des Spurwechsels die Frequenzspektren	63
6.5 Zeit-Frequenz-Ebene des zweiten Experiments im Stress-Level 2.	63
6.6 Darstellung ausgewählter Features zur Veränderung der T-Welle während der Stress-Level.	64
6.7 Abflachung der T-Welle beim Mental-stress-Test	64
6.8 Darstellung des gefundenen Entscheidungsbaums auf der Basis aller HRV-Features.....	65
6.9 Darstellung des gefundenen Entscheidungsbaums auf der Basis aller Morphologie-Fearue und aller HRV-Features	66
6.10 „Kollisionen“ von MSEs im EKG-Signal	67
6.11 HRV-Parameter für langsame Variationen der RR-Zeitreihe aus dem MSE-Experiment.	68
6.12 Mittleres RR-Intervall und HRV-Parameter für schnelle Variationen der RR-Zeitreihe aus dem MSE-Experiment.	69
6.13 HRV-Parameter aus dem Frequenzbereich aus dem MSE-Experiment.	70
6.14 Morphologie-Parameter aus dem MSE-Experiment.	71
6.15 Darstellung der Ursache für die signifikanten Veränderungen der Morphologie-Features.	71

Tabellenverzeichnis

4.1	Zusammenfassung der Versuchsdaten zum Mental-Stress-Test.	30
5.1	Frequenzbänder der hier verwendeten WPA	53
6.1	Parameter der beiden Experimente des Mental-Stress-Tests	62
6.2	Trefferquoten des Entscheidungsbaums aus Abb. 6.8	65
6.3	Trefferquoten des Entscheidungsbaums aus Abb. 6.9	66
B.1	Auflistung der Features aus dem QRS-Komplex (Teil 1)	83
B.2	Auflistung der Features aus dem QRS-Komplex (Teil 2)	84

Literaturverzeichnis

- [Addison 2002] ADDISON, P.: *The Illustrated Wavelet Transform Handbook*. Bristol, Philadelphia : Institute of Physics Publishing, 2002
- [Bazett 1920] BAZETT, H. C.: An analysis of time-relations of electrocardiograms. In: *Heart* 7 (1920), S. 353?370
- [Büning & Trenkler 1994] BÜNING, Herbert ; TRENKLER, G.: *Nichtparametrische statistische Methoden*. Bod Third Party Titles, 1994 (de Gruyter Lehrbuch)
- [Cabiddu et al. 2012] CABIDDU, Ramona ; CERUTTI, Sergio ; VIARDOT, Geoffrey ; WERNER, Sandra ; BIANCHI, Anna M.: Modulation of the sympatho-vagal balance during sleep: frequency domain study of heart rate variability and respiration. In: *Frontiers in physiology* 3 (2012)
- [Gamero et al. 2002] GAMERO, L. G. ; VILA, J. ; PALACIOS, F.: Wavelet transform analysis of heart rate variability during myocardial ischaemia. In: *Med Biol Eng Comput* 40 (2002), S. 72–78
- [Ginopoulos et al. 2003] GINOPoulos, Dimitrios C. ; MAVREPIS, Ioannis M. ; STAMPOULIDIS, Konstantinos T. ; LEFKOS, Nikolaos P.: QT dispersion and mental stress testing. In: *Hellenic J Cardiol* 44 (2003), S. 180–186
- [Golz et al. 2007] GOLZ, Martin ; SOMMER, David ; CHEN, Mo ; TRUTSCHEL, Udo ; MANDIC, Danilo: Feature fusion for the detection of microsleep events. In: *The Journal of VLSI Signal Processing Systems for Signal, Image, and Video Technology* 49 (2007), Nr. 2, S. 329–342
- [Golz et al. 2011] GOLZ, Martin ; SOMMER, David ; KRAJEWSKI, Jarek ; TRUTSCHEL, Udo ; EDWARDS, Dave: Microsleep episodes and related crashes during overnight driving simulations. In: *Proceedings of the Sixth International Driving Symposium on Human Factors in Driver Assessment, Training and Vehicle Design*, 2011
- [Gottdiener et al. 1994] GOTTDIENER, John S. ; KRANTZ, David S. ; HOWELL, Robert H. ; HECHT, Gabriela M. ; KLEIN, Jacob ; FALCONER, Jennifer J. ; ROZANSKI, Alan: Induction of silent myocardial ischemia with mental stress testing: Relation to the triggers of ischemia during daily life activities to ischemic functional severity. In: *Journal of the American College of Cardiology* 24 (1994), Nr. 7, S. 1645–1651
- [Grabitz & Wisdorff 2013] GRABITZ, I. ; WISDORFF, F.: 1800 Prozent mehr Krankentage durch Burn-out. In: <http://www.welt.de/wirtschaft/article113159916/1800-Prozent-mehr-Krankentage-durch-Burn-out.html> (2013), Januar
- [Henze 2008] HENZE, N.: *Stochastik für Einsteiger : Eine Einführung in die faszinierende Welt des Zufalls*. Wiesbaden : Friedr. Vieweg & Sohn Verlag / GWV Fachverlage GmbH, Wiesbaden, 2008

- [Heslegrave & Furedy 1979] HESLEGRAVE, Ronald J. ; FUREDY, John J.: Sensitivities of HR and T-wave amplitude for detecting cognitive and anticipatory stress. In: *Physiology & behavior* 22 (1979), Nr. 1, S. 17–23
- [Kammeyer & Kroschel 2009] KAMMEYER, K. D. ; KROSCHEL, Kristian: *Digitale Signalverarbeitung: Filterung und Spektralanalyse*. Wiesbaden : Vieweg + Teubner, 2009 (Studium)
- [Kammeyer et al. 2011] KAMMEYER, Karl-Dirk ; BOSSERT, Martin ; FLIEGE, Norbert: *Nachrichtenübertragung*. Vieweg+Teubner Verlag, 2011
- [Kiencke & Eger 2008] KIENCKE, U. ; EGER, R.: *Messtechnik, Systemtheorie für Elektrotechniker*. Berlin, Heidelberg : Springer Berlin Heidelberg, 2008
- [Kiencke & Jäkel 2008] KIENCKE, U. ; JÄKEL, H.: *Signale und Systeme*. München : Oldenbourg-Verl., 2008
- [Kiencke et al. 2008] KIENCKE, U. ; SCHWARZ, Michael ; WEICKERT, Thomas: *Signalverarbeitung: Zeit-Frequenz-Analyse und Schätzverfahren*. München : Oldenbourg, 2008
- [Kim et al. 2008a] KIM, Desok ; SEO, Yunhwan ; CHO, Jaeggeol ; CHO, Chul-Ho: Detection of subjects with higher self-reporting stress scores using heart rate variability patterns during the day. In: *Engineering in Medicine and Biology Society, 2008. EMBS 2008. 30th Annual International Conference of the IEEE IEEE*, 2008, S. 682–685
- [Kim et al. 2008b] KIM, Desok ; SEO, Yunhwan ; KIM, Sook-hyun ; JUNG, Suntae: Short term analysis of long term patterns of heart rate variability in subjects under mental stress. In: *BioMedical Engineering and Informatics, 2008. BMEI 2008. International Conference on* Bd. 2 IEEE, 2008, S. 487–491
- [Klinke et al. 2005] KLINKE, R. ; PAPE, H.-C. ; SILBERNAGL, S.: *Physiologie*. Stuttgart : Georg Thieme Verlag Stuttgart, 2005
- [Kvernmo et al. 1998] KVERNMO, Hebe D. ; STEFANOVSKA, Aneta ; BRACIC, Maja ; KIRKEBØEN, Knut A. ; KVERNEBO, Knut: Spectral analysis of the laser Doppler perfusion signal in human skin before and after exercise. In: *Microvascular research* 56 (1998), Nr. 3, S. 173–182
- [Lenis 2010] LENIS, G.: *Automatic detection and classification of ectopic beats in the ECG using a Support-Vector-Machine*. Kaiserslautern, Institut für Biomedizinische Technik, Karlsruher Institut für Technologie (KIT), Studienarbeit, 2010
- [Lenis et al. 2012] LENIS, G. ; BAAS, T. ; DÖSSEL, O.: Rhythmic and morphological features of the ECG following a premature ventricular contraction. In: *46. Jahrestagung der DGBMT im VDE. Proceedings BMT 2012*. Jena, Deutschland, 19-22 Sep. 2012 : 46. Jahrestagung der DGBMT - Deutschen Gesellschaft für Biomedizinische Technik im VDE, 2012
- [von Leupoldt & Ritz 2008] LEUPOLDT, A. von ; RITZ, T.: *Verhaltensmedizin: Psychobiologie, Psychopathologie und klinische Anwendung*. Kohlhammer, 2008
- [Malik et al. 1996] MALIK, M. ; BIGGER, J. T. ; CAMM, A. J. ; KLEIGER, R. E. ; MALLIANI, A. ; MOSS, A. J. ; SCHWARTZ, P. J.: Heart rate variability. Standards of measurement, physiological interpretation, and clinical use. Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology. In: *Eur Heart J* 17 (1996), S. 354–381
- [Mallat 1989] MALLAT, Stephane G.: A theory for multiresolution signal decomposition: the wavelet representation. In: *Pattern Analysis and Machine Intelligence, IEEE Transactions on* 11 (1989), Nr. 7, S. 674–693
- [Mantaras et al. 2006] MANTARAS, MC ; MENDEZ, MO ; VILLIANTIERI, O ; MONTANO, N ; PATRUNO, V ; BIANCHI, AM ; CERUTTI, S: Non-parametric and parametric time-

- frequency analysis of heart rate variability during arousals from sleep. In: *Computers in Cardiology, 2006 IEEE*, 2006, S. 745–748
- [Massin et al. 2000] MASSIN, Martial M. ; MAEYNS, Krystel ; WITHOFS, Nadia ; RAVET, Françoise ; GÉRARD, Paul: Circadian rhythm of heart rate and heart rate variability. In: *Archives of disease in childhood* 83 (2000), Nr. 2, S. 179–182
- [Menges 2013] MENGES, R.: *Selecting the best rhythmical and morphological features for a QRS complex classification system*. Karlsruhe, Institute of Biomedical Engineering, Karlsruhe Institute of Technology (KIT), Bachelor Thesis, 2013
- [Morath 2014] MORATH, I.: *Comparing the standard parameters of heart rate variability and deceleration capacity with the ARMA modeled time series of RR intervals obtained from the electrocardiogram*, Institute of Biomedical Engineering, Karlsruhe Institute of Technology (KIT), Bachelor Thesis, 2014
- [Panigrahi & Pandi 2009] PANIGRAHI, BK ; PANDI, V R.: Optimal feature selection for classification of power quality disturbances using wavelet packet-based fuzzy k-nearest neighbour algorithm. In: *IET generation, transmission & distribution* 3 (2009), Nr. 3, S. 296–306
- [Pichot et al. 1999] PICHOT, Vincent ; GASPOZ, Jean-Michel ; MOLLIEX, Serge ; ANTONIADIS, Anestis ; BUSSO, Thierry ; ROCHE, Frédéric ; COSTES, Frédéric ; QUINTIN, Luc ; LACOUR, Jean-René ; BARTHÉLÉMY, Jean-Claude: Wavelet transform to quantify heart rate variability and to assess its instantaneous changes. In: *Journal of Applied Physiology* 86 (1999), Nr. 3, S. 1081–1091
- [Pilia 2013] PILIA, N. A.: *A robust method to detect and characterise the P wave in the electrocardiogram*, Institute of Biomedical Engineering, Karlsruhe Institute of Technology (KIT), Bachelor Thesis, 2013
- [Pomeranz et al. 1985] POMERANZ, B. ; MACAULAY, R. J. ; CAUDILL, M. A. ; KUTZ, I. ; ADAM, D. ; GORDON, D. ; KILBORN, K. M. ; BARGER, A. C. ; SHANNON, D. C. ; COHEN, R. J.: Assessment of autonomic function in humans by heart rate spectral analysis. In: *The American Journal of Physiology* 248 (1985), S. H151–3
- [Rajendra Acharya et al. 2006] RAJENDRA ACHARYA, U. ; PAUL JOSEPH, K. ; KANNATHAL, N. ; LIM, C. M. ; SURI, J. S.: Heart rate variability: a review. In: *Medical & Biological Engineering & Computing* 44 (2006), S. 1031–1051
- [Rani et al. 2002] RANI, Pramila ; SIMS, Jared ; BRACKIN, Robert ; SARKAR, Nilanjan: Online stress detection using psychophysiological signals for implicit human-robot cooperation. In: *Robotica* 20 (2002), Nr. 06, S. 673–685
- [Salahuddin et al. 2007] SALAHUDDIN, Lizawati ; CHO, Jaegeol ; JEONG, Myeong G. ; KIM, Desok: Ultra short term analysis of heart rate variability for monitoring mental stress in mobile settings. In: *Engineering in Medicine and Biology Society, 2007. EMBS 2007. 29th Annual International Conference of the IEEE IEEE*, 2007, S. 4656–4659
- [Schwegler & Lucius 2011] SCHWEGLER, J.S. ; LUCIUS, R.: *Der Mensch - Anatomie und Physiologie*. Thieme, 2011
- [Silbernagl 2012] SILBERNAGL, S.: *Taschenatlas Physiologie*. Stuttgart [u.a.] : Thieme, 2012
- [Specchia et al. 1984] SPECCHIA, Giuseppe ; SERVI, Stefano de ; FALCONE, Colomba ; GAVAZZI, Antonello ; ANGOLI, Luigi ; BRAMUCCI, Ezio ; ARDISSINO, Diego ; MUSSINI, Antonio: Mental arithmetic stress testing in patients with coronary artery disease. In: *American heart journal* 108 (1984), Nr. 1, S. 56–63
- [Stein & Kleiger 1999] STEIN, P. K. ; KLEIGER, R. E.: Insights from the study of heart rate variability. In: *Annual Review of Medicine* 50 (1999), S. 249–261

- [Takeuchi et al. 2001] TAKEUCHI, H ; ENZO, A ; MINAMITANI, H: Circadian rhythm changes in heart rate variability during chronic sound stress. In: *Medical and Biological Engineering and Computing* 39 (2001), Nr. 1, S. 113–117
- [Tanaka & Hargens 2004] TANAKA, Kunihiko ; HARGENS, Alan R.: Wavelet packet transform for RR interval variability. In: *Medical engineering & physics* 26 (2004), Nr. 4, S. 313–319
- [Vetterli & Kovačević 1995] VETTERLI, Martin ; KOVAČEVIĆ, Jelena: *Wavelets and subband coding*. Bd. 87. Prentice Hall PTR Englewood Cliffs, New Jersey, 1995
- [Wiklund et al. 1997] WIKLUND, U ; AKAY, M ; NIKLASSON, U: Short-term analysis of heart-rate variability of adapted wavelet transforms. In: *Engineering in Medicine and Biology Magazine, IEEE* 16 (1997), Nr. 5, S. 113–118
- [Wilhelm et al. 2010] WILHELM, B. ; E., Stephan ; DITTMANN, V.: Tagesschlafigkeit – Gefahren und Konsequenzen für den Straßenverkehr. In: <http://www.dgvm-verkehrsmedizin.de/> (2010), Oktober
- [Wu et al. 2009] WU, Wanqing ; LEE, Jungtae ; CHEN, Haifeng: Estimation of Heart Rate Variability Changes during Different Visual Stimulations Using Non-invasive Continuous ECG Monitoring System. In: *Bioinformatics, Systems Biology and Intelligent Computing, 2009. IJCBs'09. International Joint Conference on IEEE*, 2009, S. 344–347